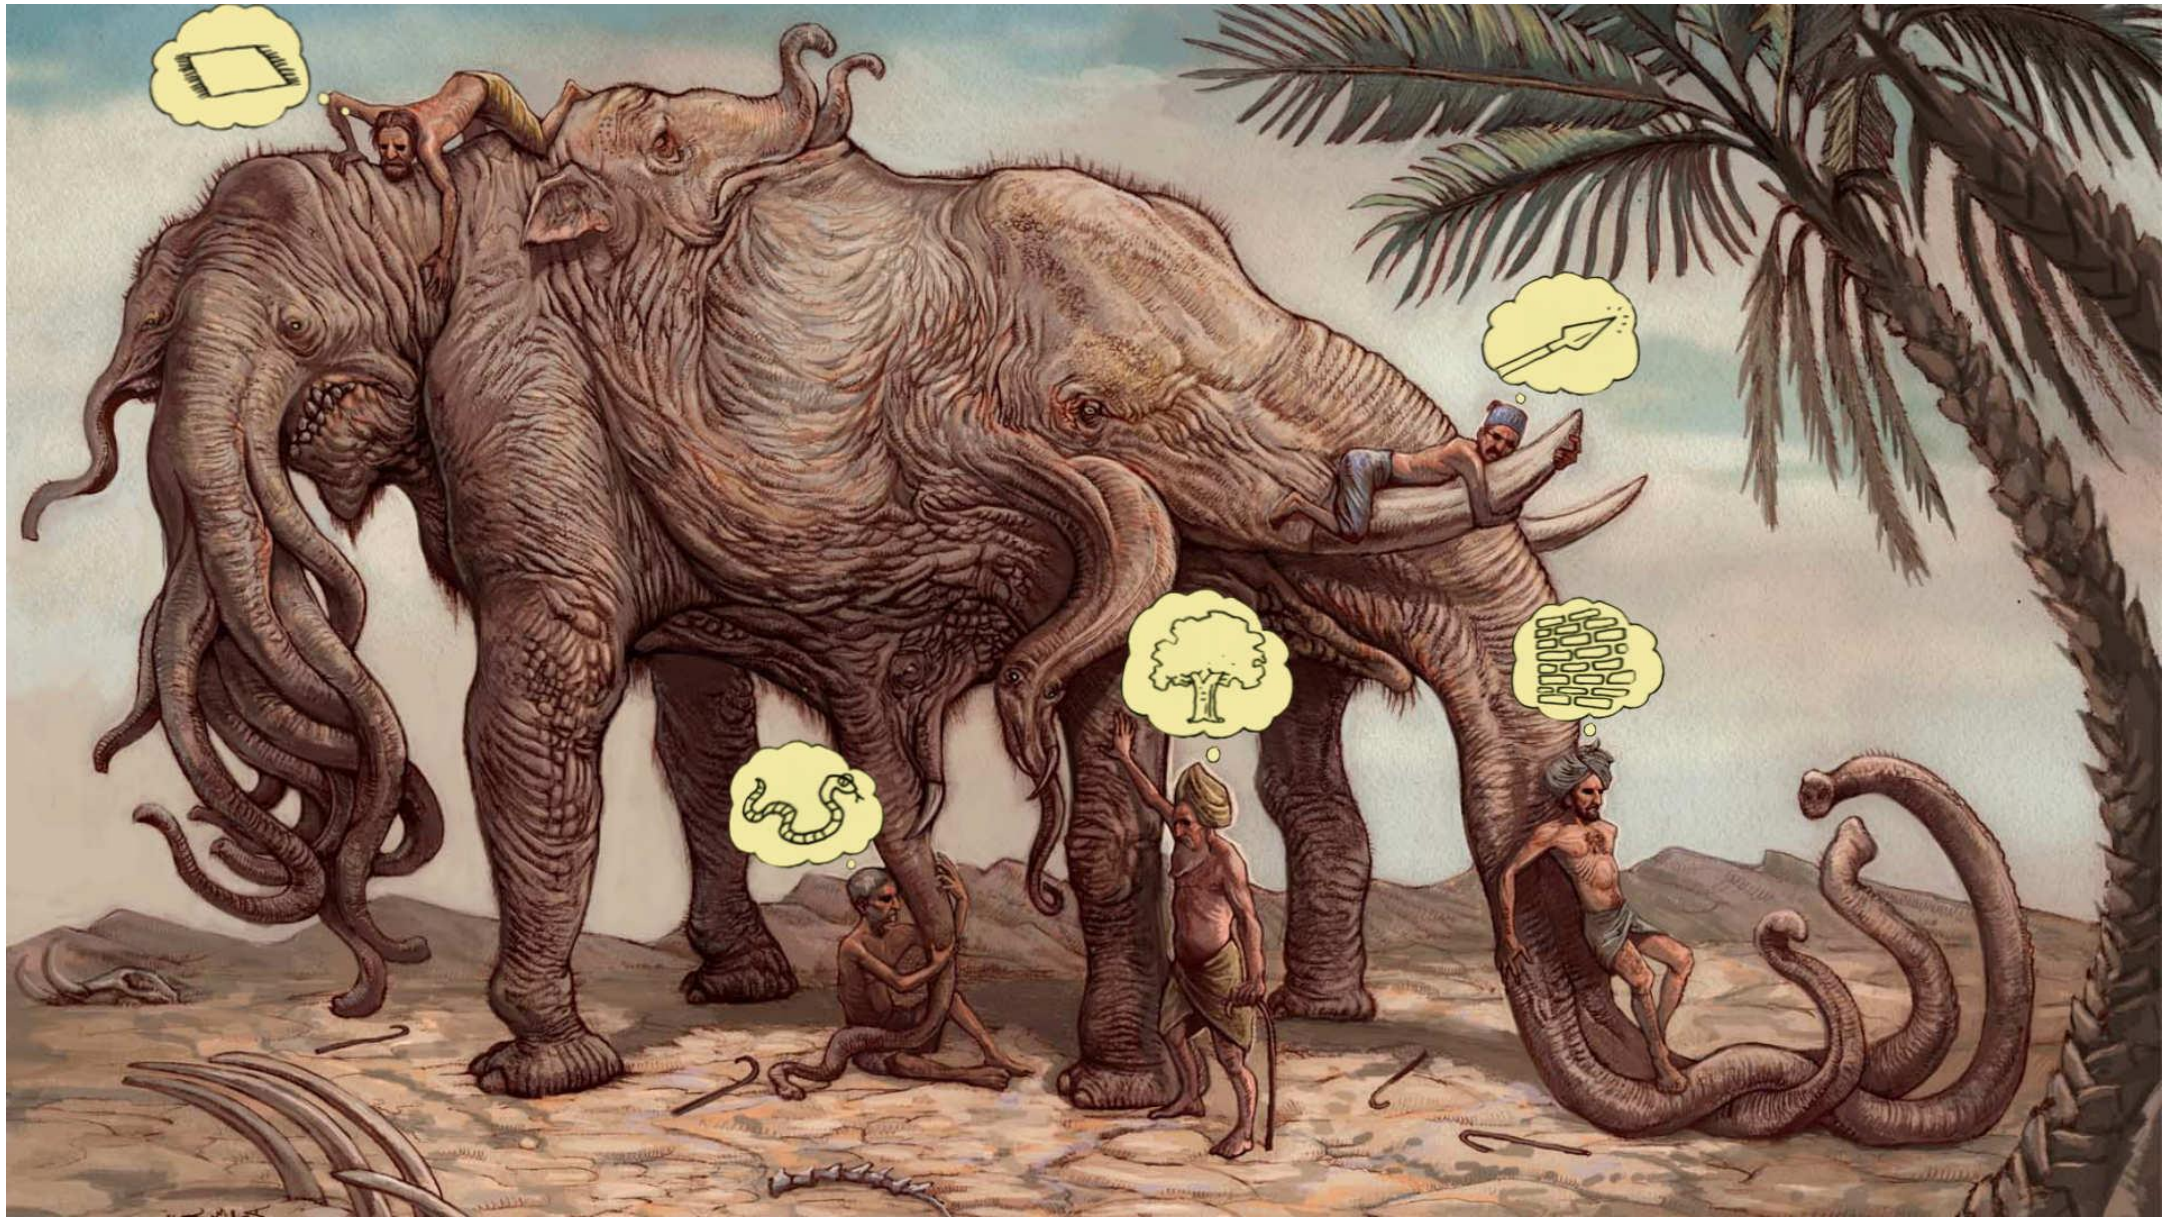
ИТМО

Занятие 2. Классические подходы к созданию моделей ИИ на данных

Александр Валерьевич Бухановский

Почему у людей разные представления об ИИ?



Классический порядок создания системы ИИ



1) Определение целеполагания системы ИИ

2) Подготовка и первичный анализ данных для обучения системы ИИ

3) Обоснование выбора класса модели ИИ

4) Конструирование модели ИИ

5) Технологическая реализации модели ИИ

6) Обучение модели ИИ на данных

7) Оценка качества модели ИИ

8) Разработка методики применения системы ИИ (например, в целях поддержки принятия решений)



ИТМО

ПОДГОТОВКА И АНАЛИЗ ДАННЫХ ДЛЯ СИСТЕМ ИИ

Данные: выборка из генеральной совокупности

Генеральная совокупность



Случайный отбор, N=5



Гнездовой отбор, N=11



Расслоенный (типический) отбор N=2x3

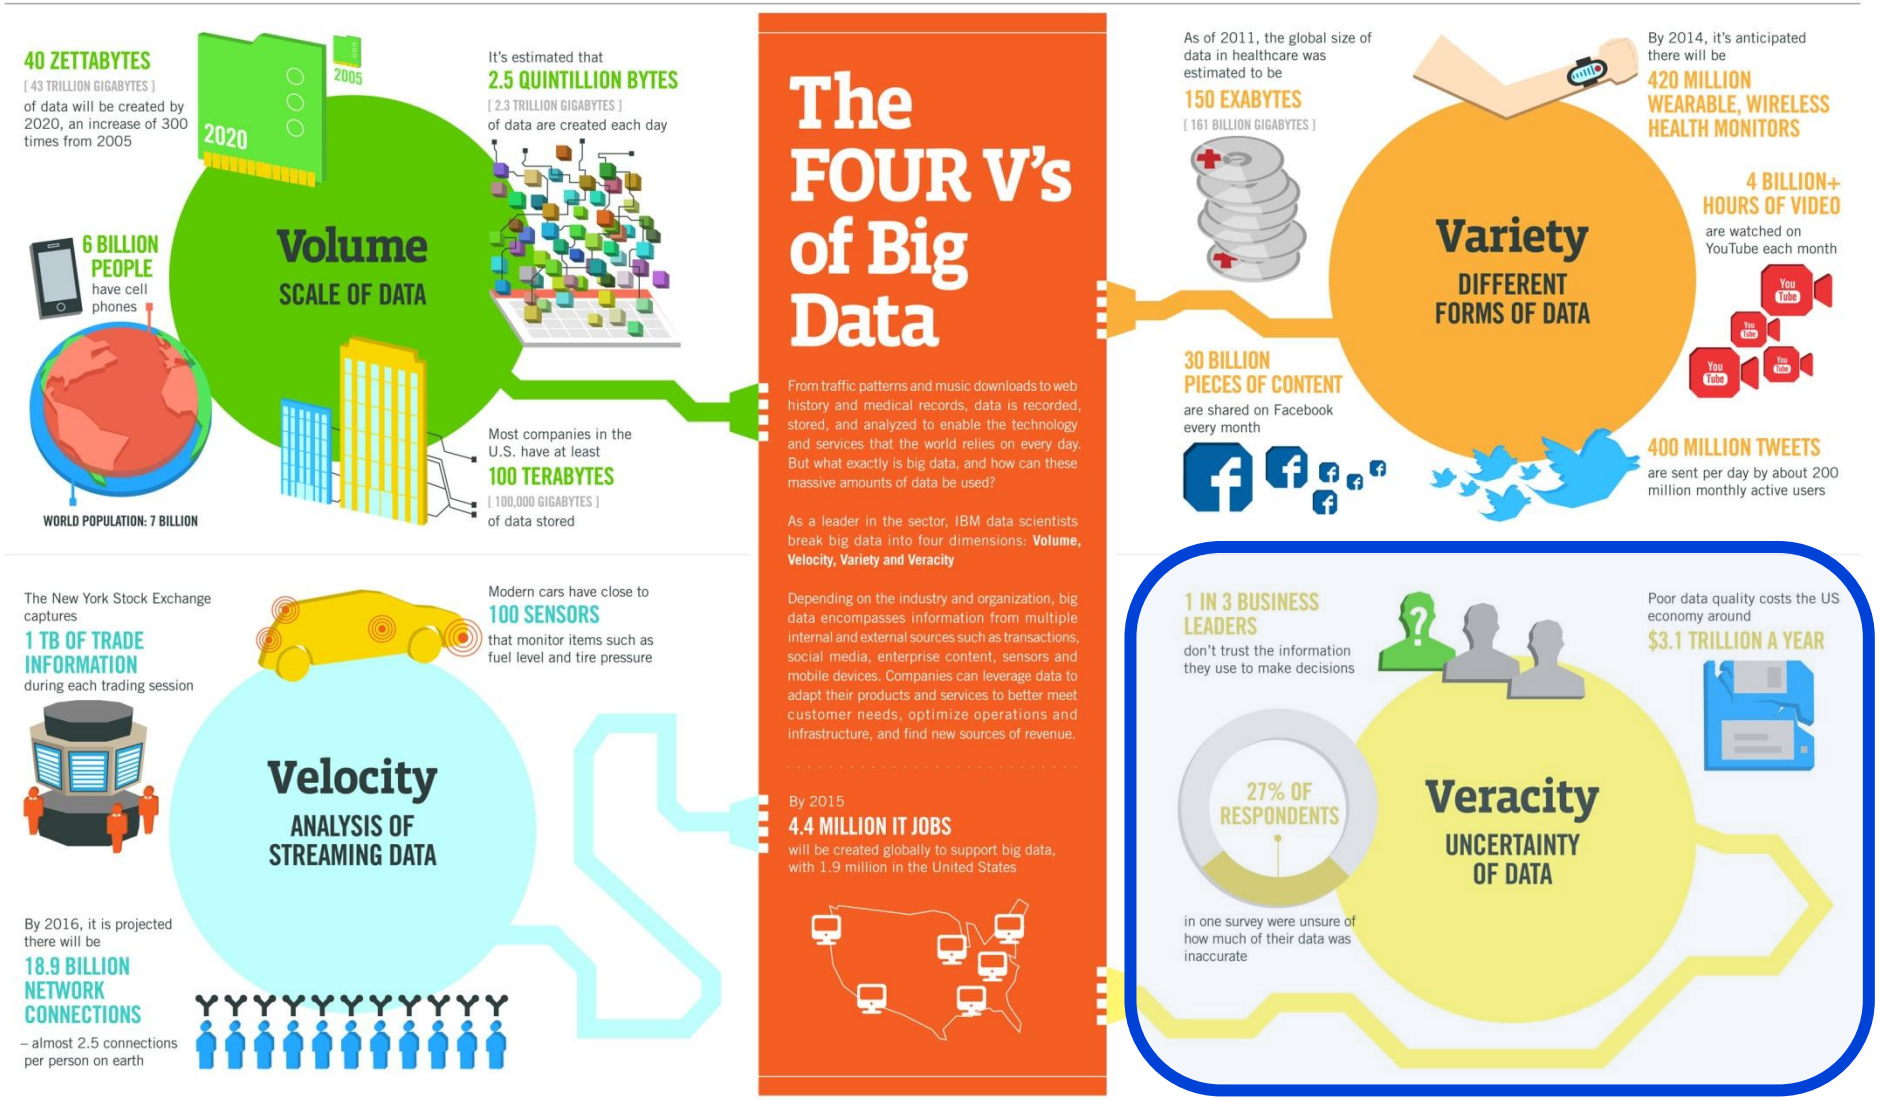




Большие Данные – определение через «V»

4 V - Value

И ещё + 13 V



Изображение было взято с сайта www.ibmbigdatahub.com

Данные и датасеты – «кровь» систем ИИ



Большие данные (Big Data) – замена активного эксперимента разрозненными пассивными наблюдениями

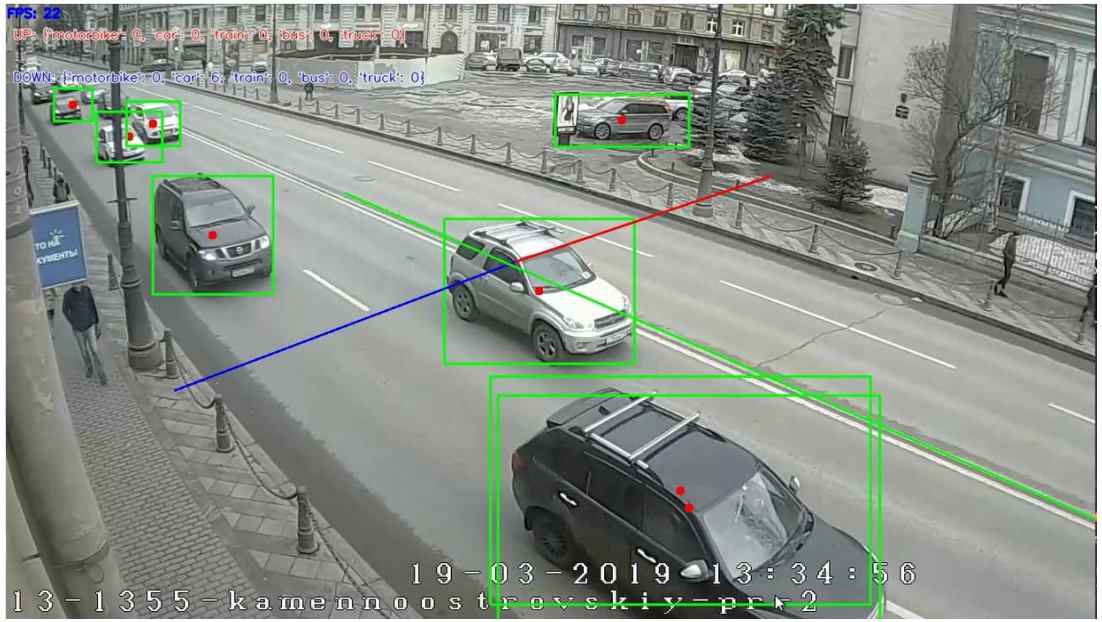
Большие данные: аллегория «жемчужного зерна»

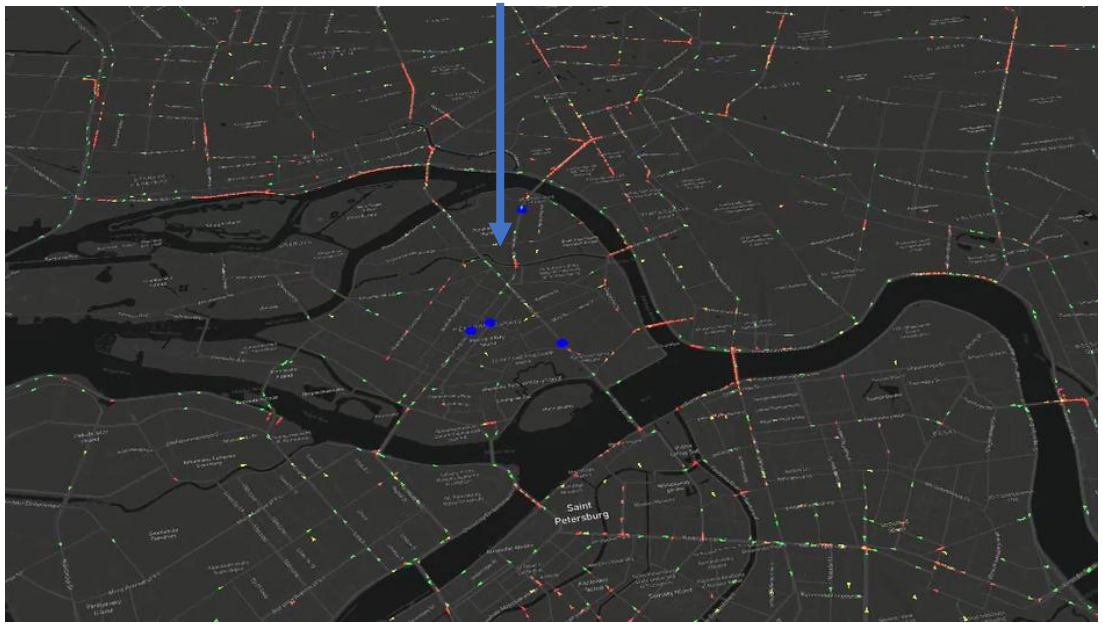
1) Очень малый «КПД» данных
2) Разнородность источников
3) Фрагментарность покрытия
4) Неструктурированность
5) Информационное загрязнение
6) Сложность доступа

Традиционная база данных	Характеристика	База больших данных
От гигабайт до терабайт	Объем информации	От петабайт до эксабайт
Централизованый	Способ хранения	Децентрализованый
Структурирована	Структурированность данных	Структурирована или неструктурирована
Вертикальная модель	Метод хранения и обработки данных	Горизонтальная модель
Сильная	Взаимосвязь данных	Слабая

Задача: преобразовать данные в **датасеты (dataset)**!

Миф №1: Данные – истина в последней инстанции





Построение модели движения транспорта в города на основе данных камер видеонаблюдения

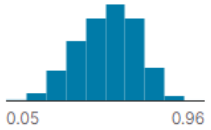
Источник данных: городские камеры видеонаблюдения и некоторые дополнительно установленные камеры.

Результат: Водители, зная о камерах, снижали скорость до пороговых минимальных значений (затем снова разгонялись). В итоге, сама модель системно занижала скорость потока

Способ сбора и измерения данных кардинальным образом влияет на качество модели ИИ

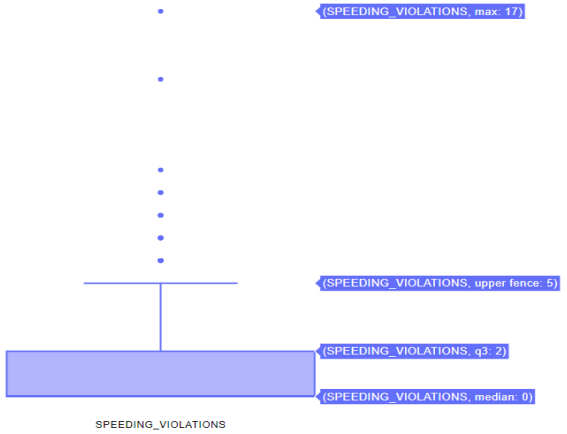
Особенности и проблемы сырых данных

Категориальные данные

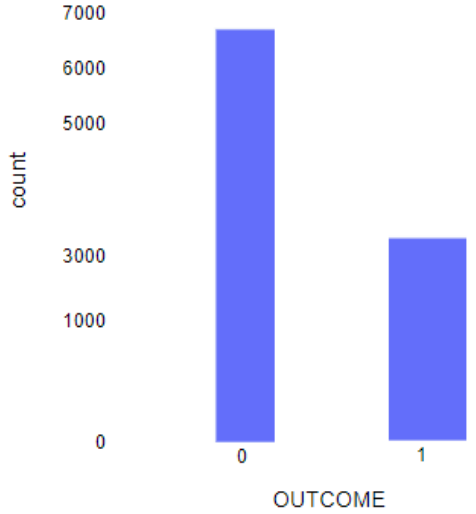
INCOME		CREDIT_SCORE
upper class	43%	
middle class	21%	
Other (3526)	35%	0.05 0.96

upper class	0.629027313918201
poverty	0.3577571170184627
working class	0.4931457852181982
working class	0.2060128507324556
working class	0.3883658881572184

Выбросы в данных



Несбалансированность

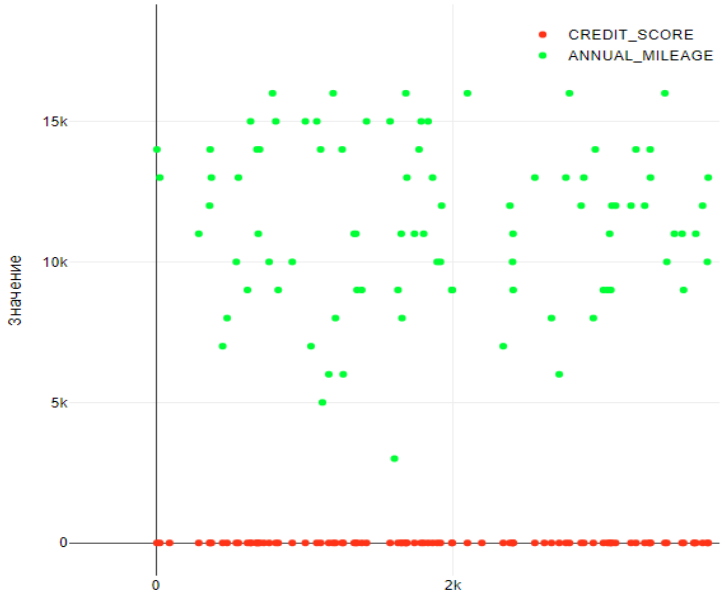


Пропуски в данных

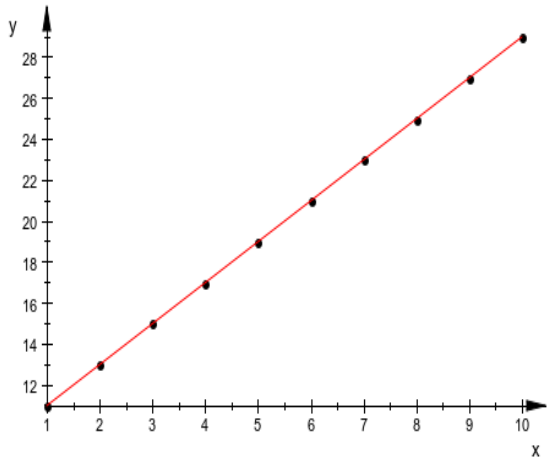
RACE		INCOME		CREDIT_SCORE
majority	90%	upper class	43%	
minority	10%	middle class	21%	
		Other (3526)	35%	0.05 0.96

majority	upper class	0.7627979410816134
majority	upper class	0.7961748462456987
majority	poverty	
majority	upper class	0.6805942795073384
majority	working class	0.4177139816231188
majority	working class	0.4095135306516067
majority	middle class	0.5532600531952381
majority	poverty	0.3309502618581893
majority	poverty	
majority	upper class	0.5006306604427161
majority	middle class	0.5519701813636283
majority	middle class	0.6269960497386653
majority	poverty	0.29479748077199674
majority	middle class	0.5519504952618395
majority	upper class	0.649820471216227

Разный масштаб



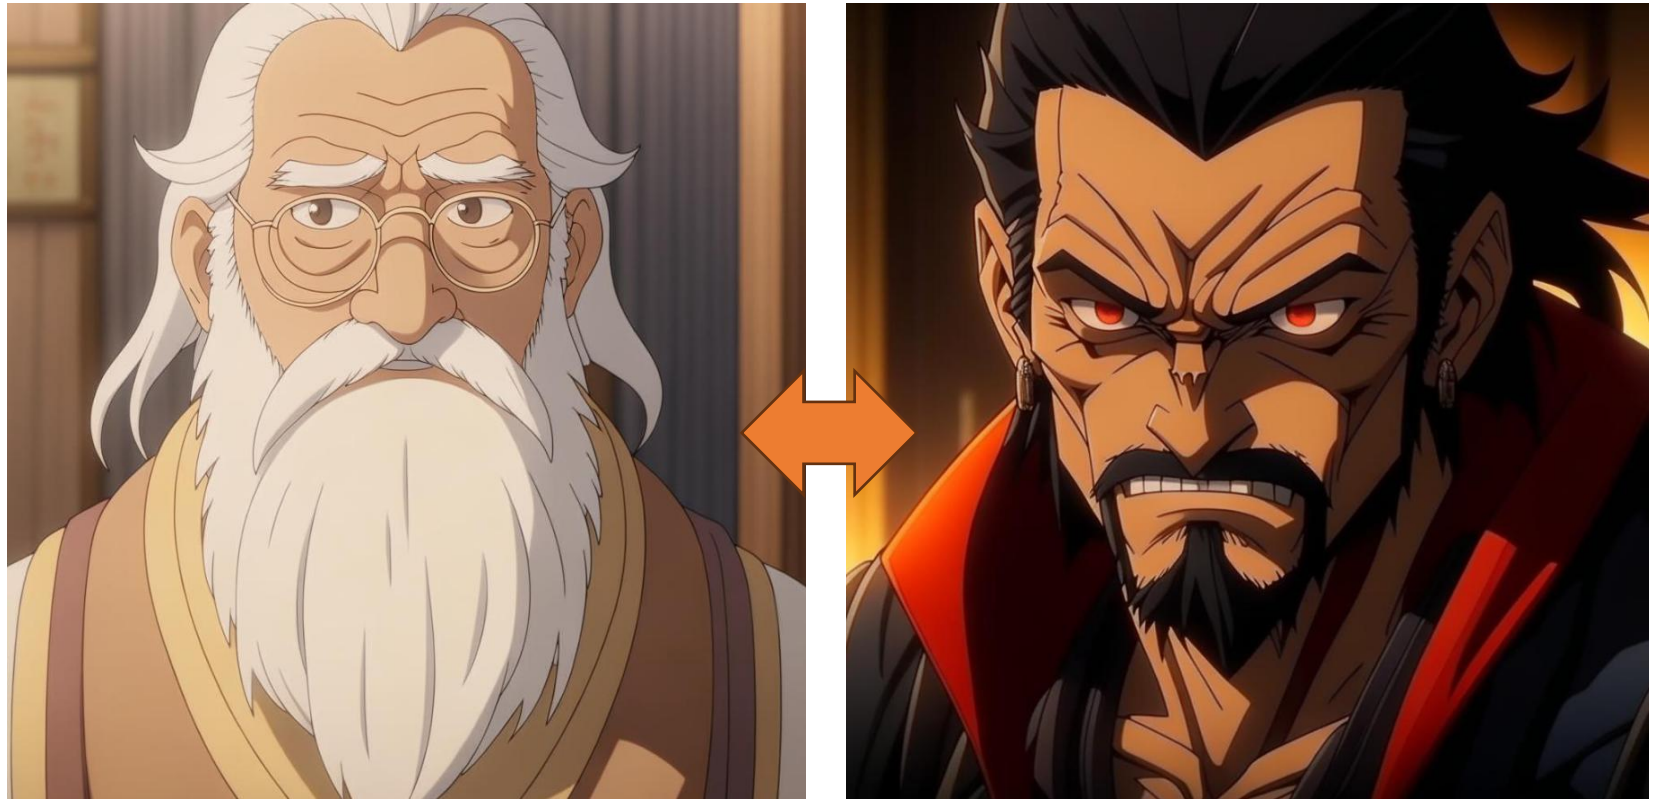
Наведенные взаимосвязи



Миф №2: Данные всегда сбалансированы

Выявление негодяев на фотографиях в социальных медиа

Обучающий датасет: 1 : 1

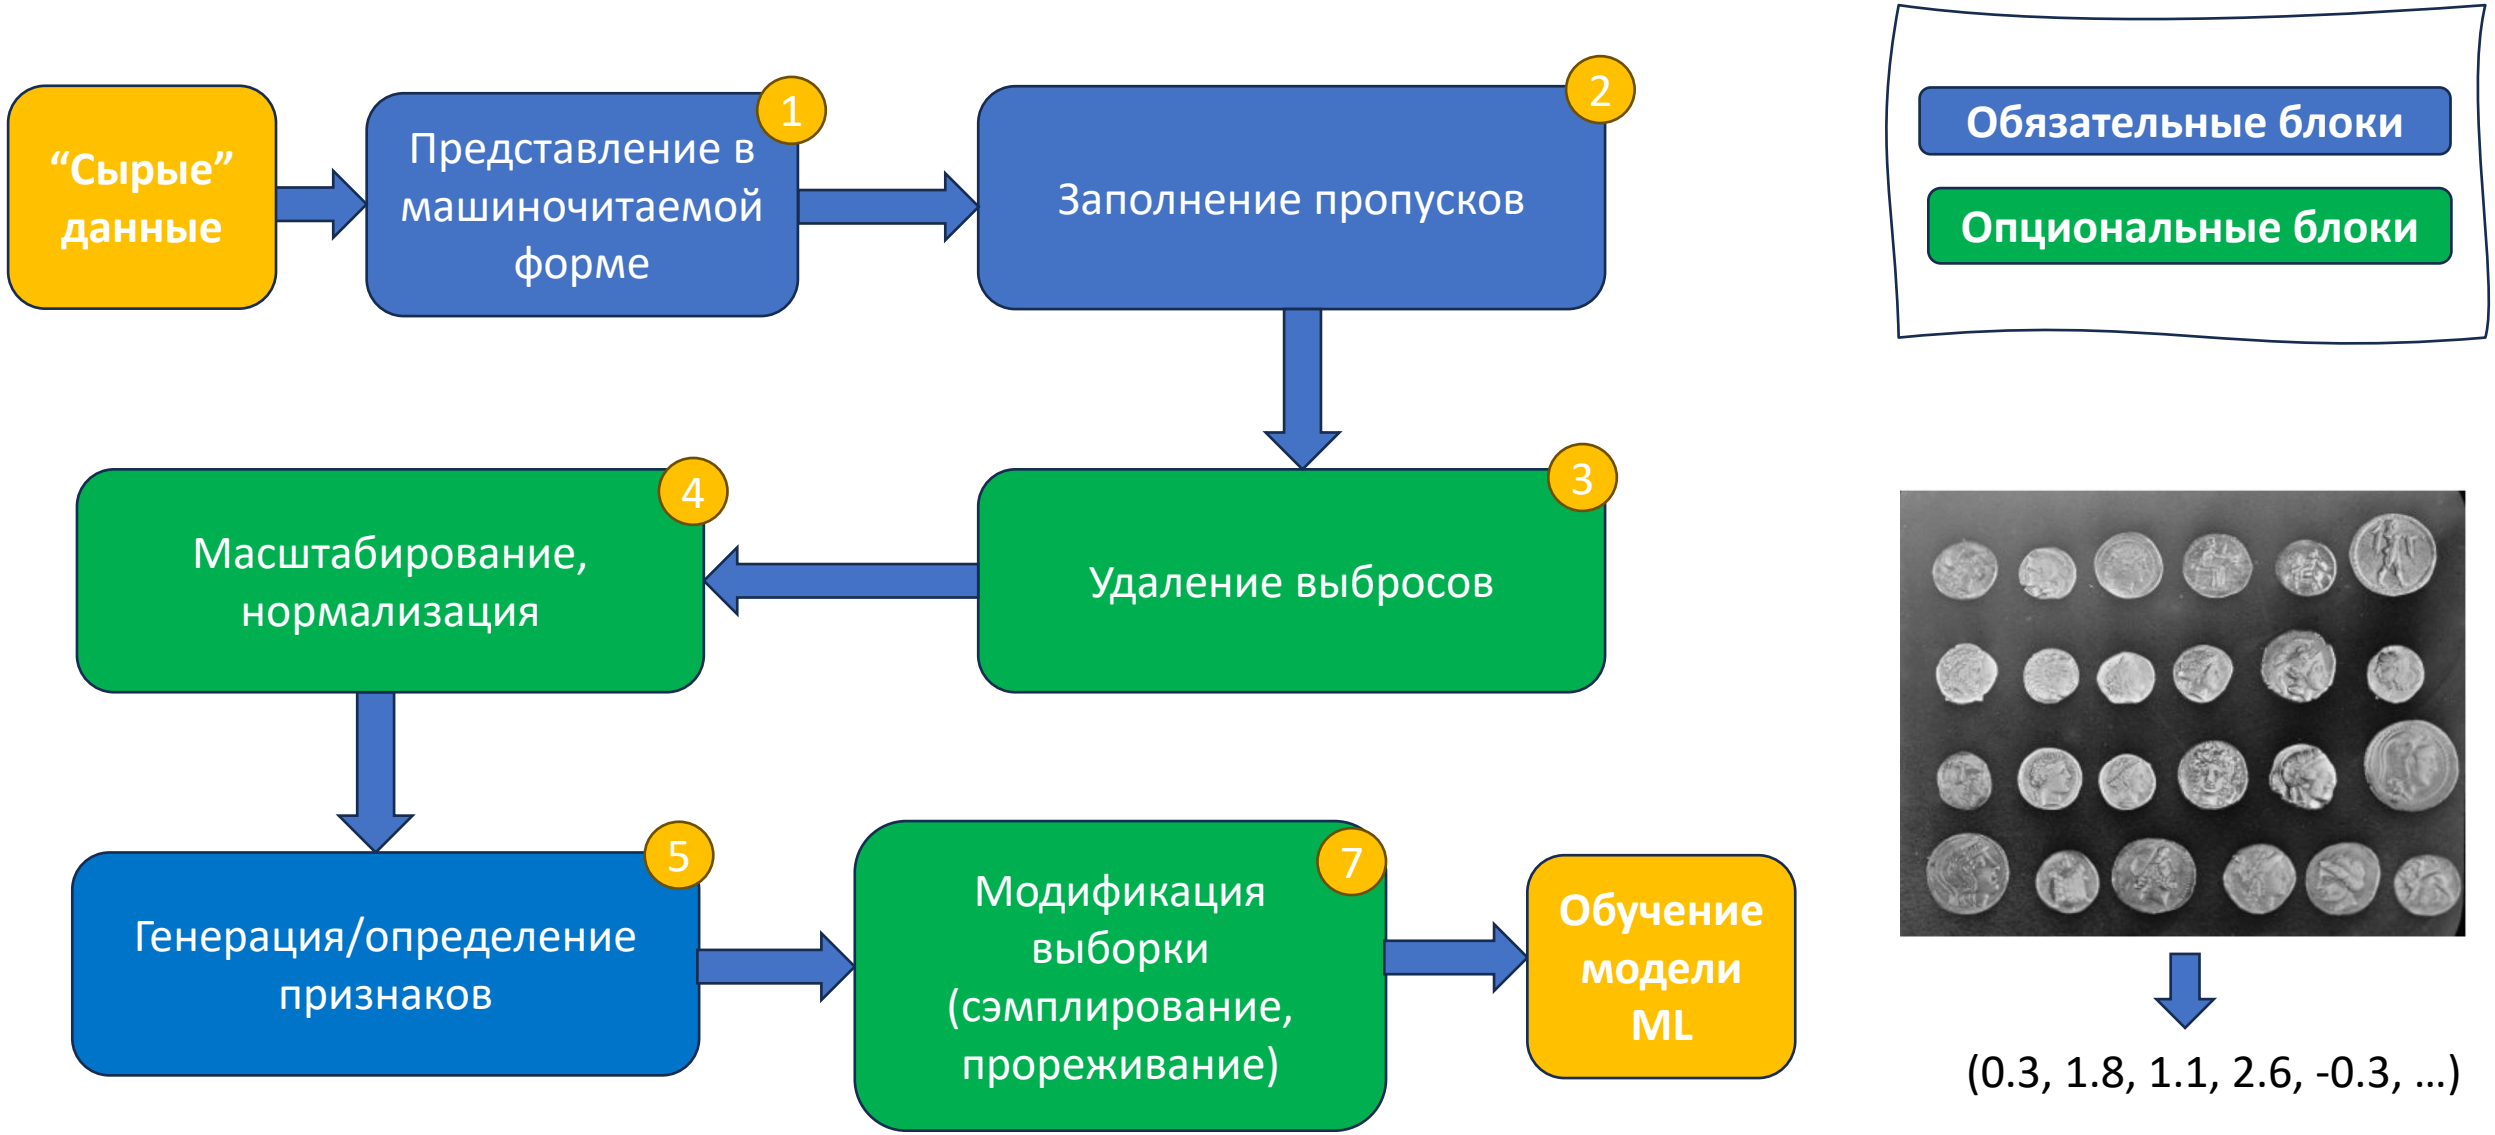


В реальных условиях: 1000 : 1

Если на обучающей выборке ИИ будет обнаруживать негодяя с вероятностью 90%, и ошибка ложноположительного результата – 1%, то в реальных условиях на каждого выявленного негодяя **~9 невиновных дедушек**

Не все датасеты, собранные в идеальных условиях, соответствуют условиям эксплуатации

Типовой порядок подготовки данных



Неструктурированные данные и их разметка



Подходы к разметке неструктурированных данных (текст, изображения, видео и пр.):

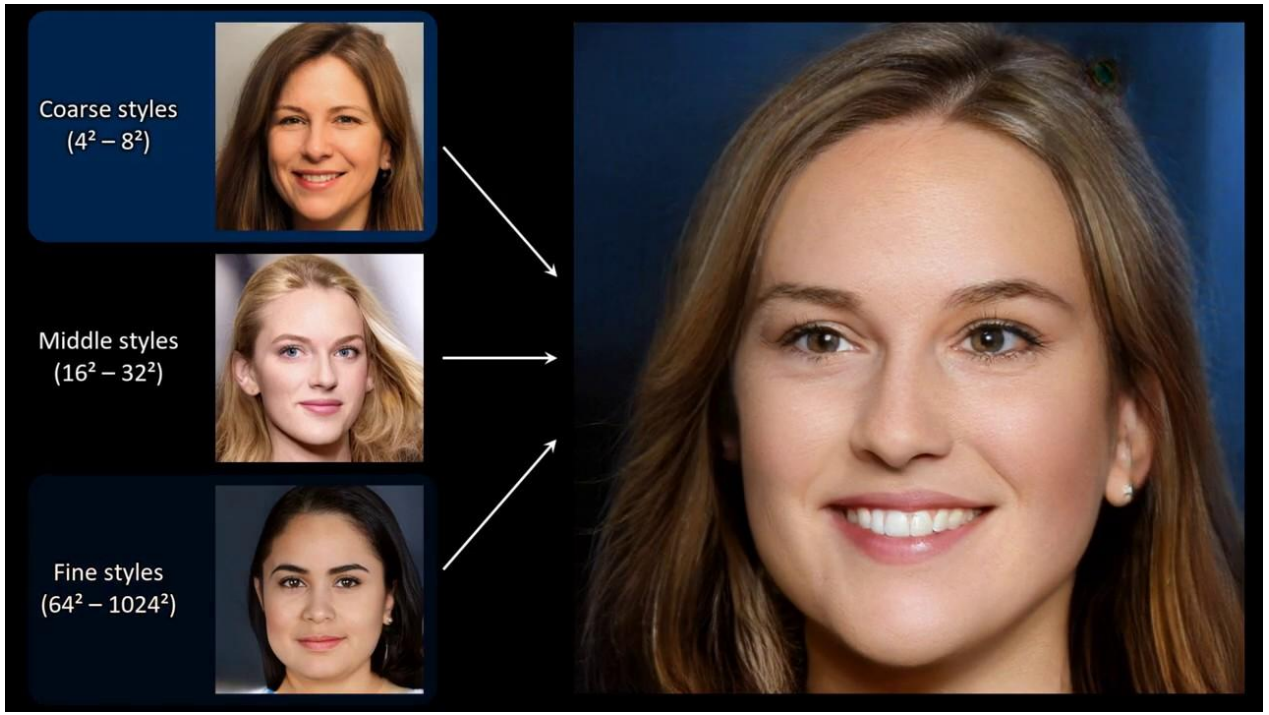
- Собственная **команда обученных разметчиков**
- **Аутсорс** (сторонняя команда)
- **Краудсорс** (общественная активность по сбору данных)
- Иные (более слабые) **алгоритмы ИИ**
- **Синтетические данные**

Пример геймифицированной краудсорс разметки - https://eyewire.org/

Синтетические данные

- **Генерация** примеров на основе имеющихся: например, обучаем генерировать заданный класс
- **Style transfer (перенос стиля):** обучаем модель переносить изображения из одного класса в другой и обратно
- Использование **причинно-следственных симуляторов** и игровых движков





Ключевые проблемы синтетики:

- Вариативность
- Физичность
- Интерпретируемость

Миф №3: Синтетические данные плохому не научат







Синтетические данные могут иметь ошибки как I, так и II рода (т.е. привносить артефакты, которых никогда не бывает в жизни)

Синтетика и проблема малых данных



Один сломал
Второй потерял...

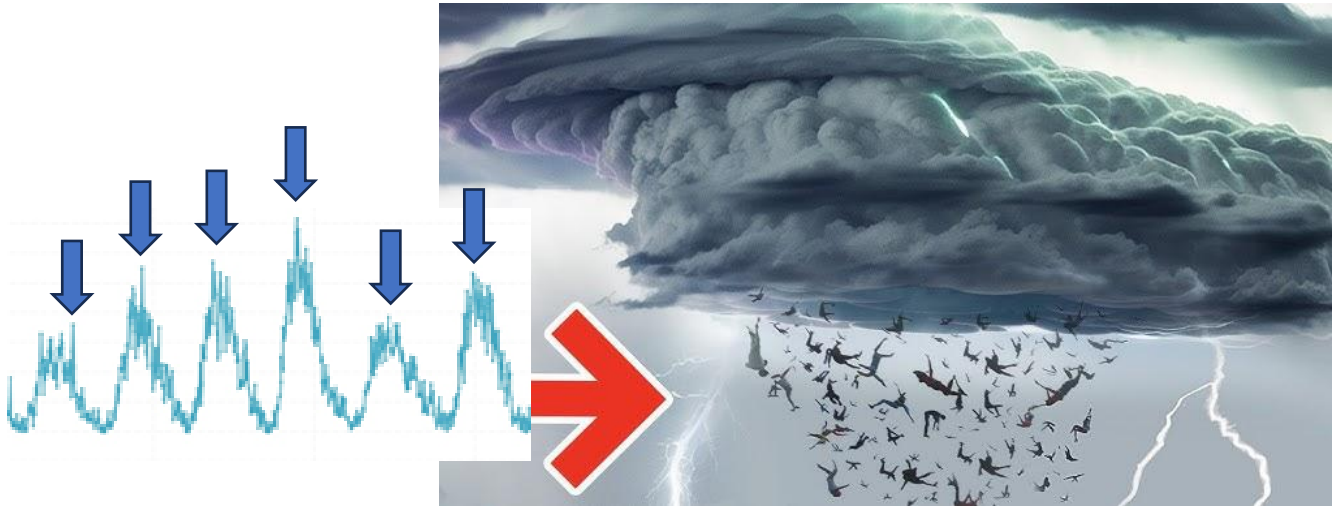


Малая выборка: когда данных настолько мало, что обобщения на их основе, сделанные формальными методами, теряют силу

Точной границы нет, но...:
N<30 – для базовой статистики
N<100 – для статистических критериев
N<500 - для многомерных данных

Редкие события: крайние члены выборок (минимальные или максимальные значения)

Решение проблемы: строить модель редких событий на основе вообще всех данных (а не только редких)



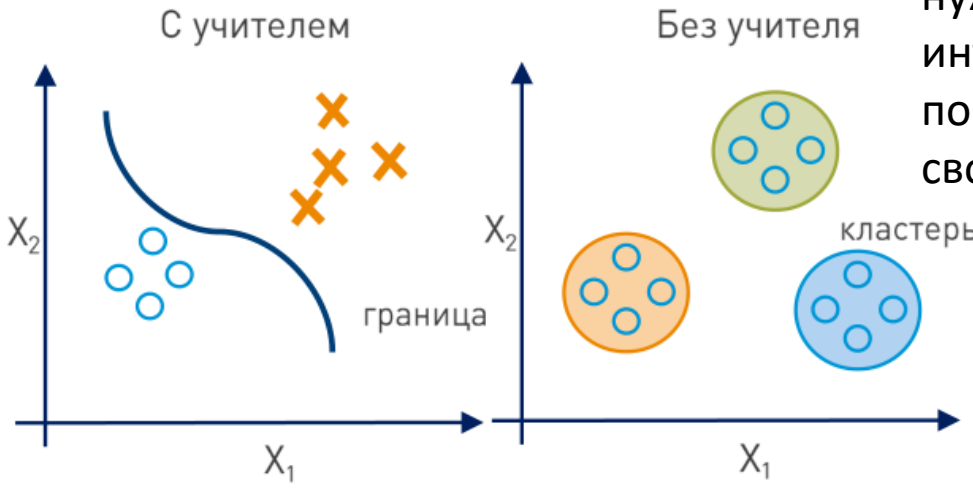


ИТМО

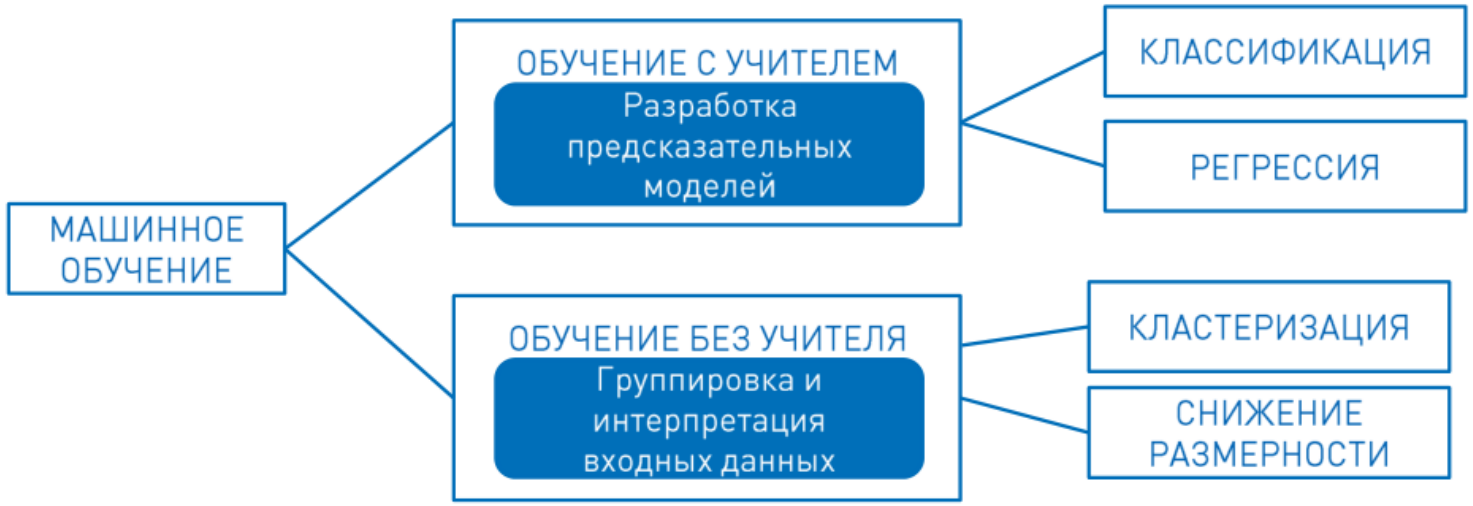
КЛАССИЧЕСКИЕ ПОДХОДЫ МАШИННОГО ОБУЧЕНИЯ ДЛЯ СИСТЕМ ИИ

Классика машинного обучения

С учителем:
данные заранее размечены



Без учителя:
нужно учитывать интуитивно понятные свойства данных



Наследство математической статистики (важна вероятностная модель!)

Процедуры классификации:

kNN (k-ближайших соседей)
SVM (опорных векторов)
Kernel-Trick (преобразования ядер)
Деревья решений и случайный лес
Логистическая регрессия
Линейный дискриминантный анализ

Процедуры регрессии:

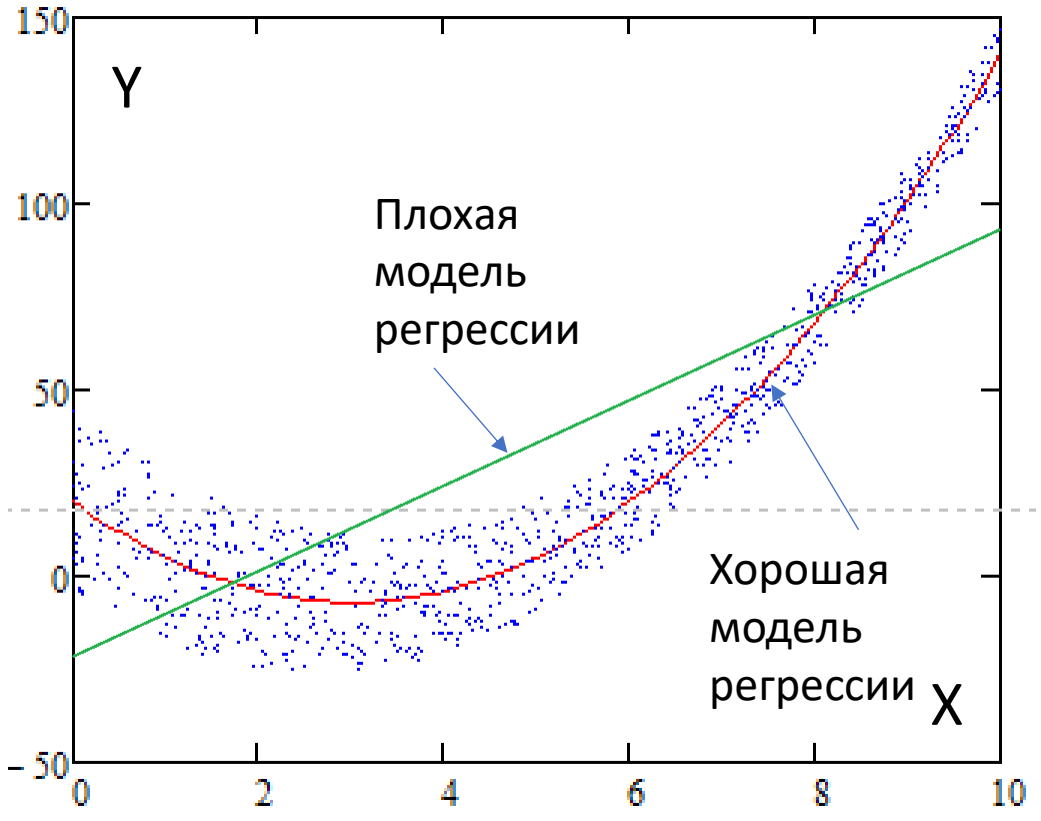
Линейная регрессия для гауссовых величин (kriging)
Гребневая (ridge) регрессия
Регрессия на главных компонентах

Процедуры снижения размерности:

Метод главных компонент (PCA)
Факторный анализ (FA)
Метод канонических корреляций

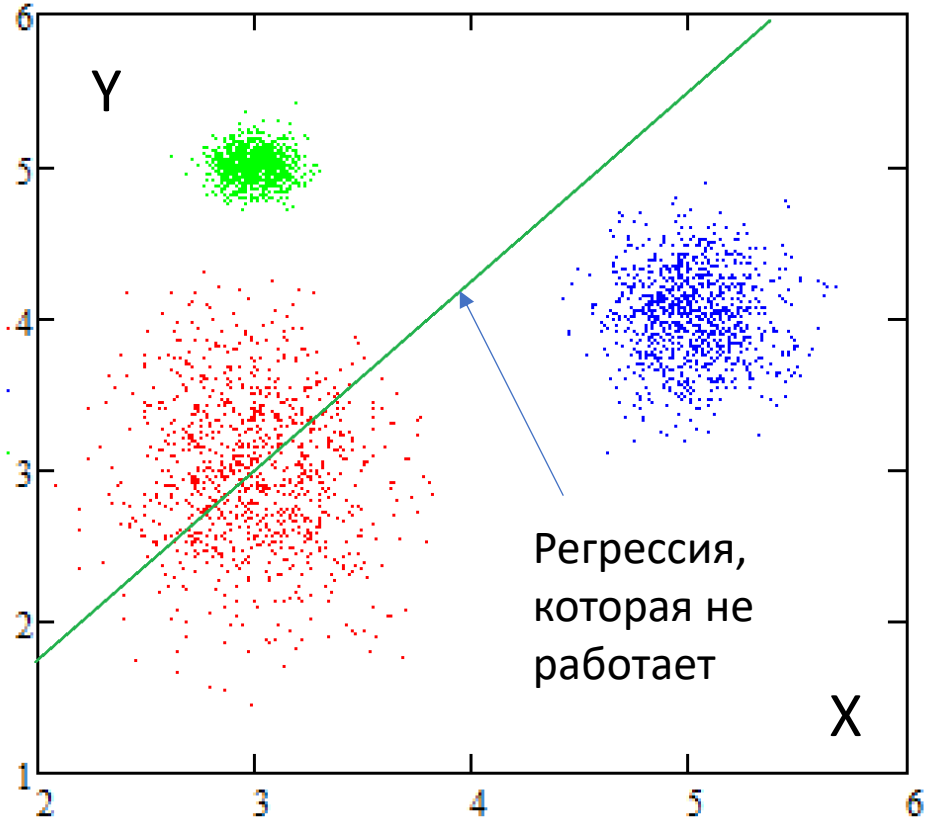
Машинное обучение и когнитивный анализ данных

Регрессия: установить количественную связь X и Y, чтобы по новым X предсказать ожидаемые Y



Сильные зависимости между X и Y

Классификация: установить групповые закономерности для возможных комбинаций (X, Y)



Слабые зависимости, сильная неоднородность

Миф №4: Чем больше выборка, тем лучше модель



Связь пространственных и временных масштабов: чтобы прогнозировать на 3 суток, надо иметь данные по северной Атлантике, а не только Балтийскому морю

Почему прогноз наводнений в Санкт-Петербурге по данным измерения уровня в Балтике возможен на всего на **12 часов** вперед, а по гидродинамической модели – **на 3 суток**?



Ключевые принципы обучения



Это еще **НЕ** обучение:

$$\varepsilon = y - f(x, \theta), \qquad \varepsilon \underset{\theta}{\rightarrow} min$$

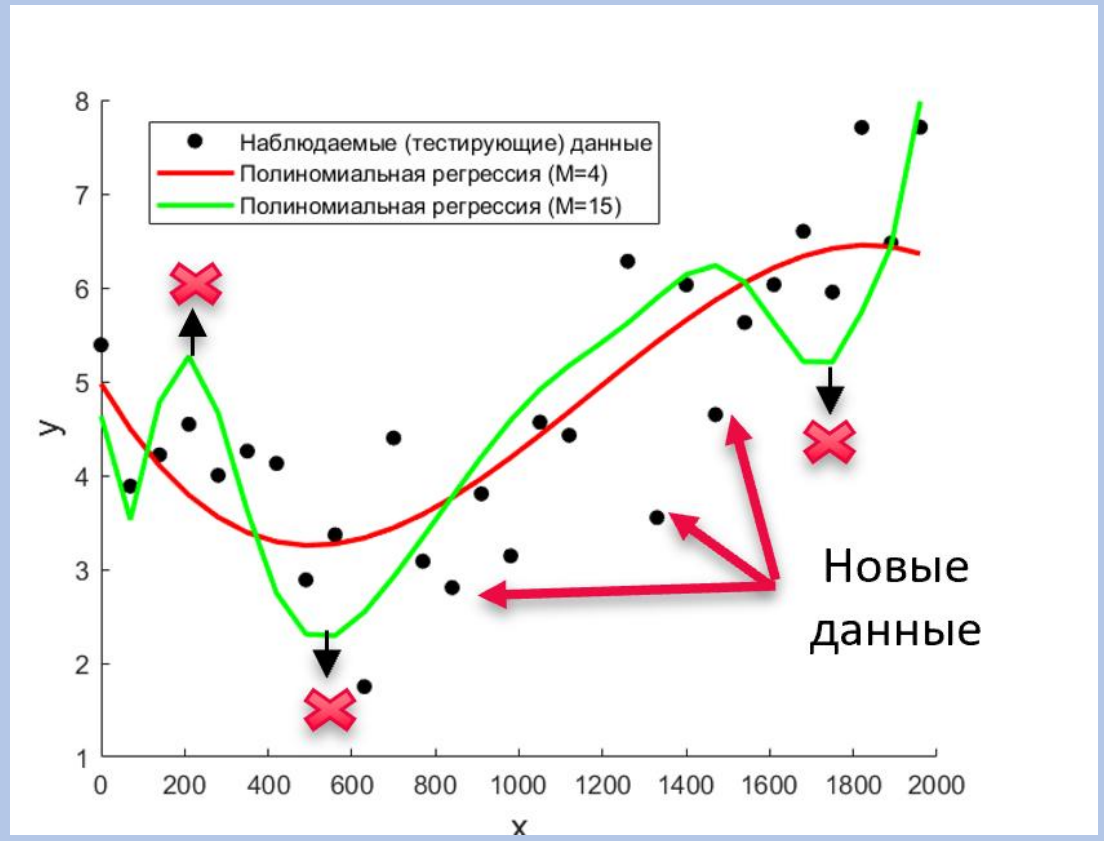
Данные y

Смысл обучения модели -> минимизация ошибки на дополнительных данных (**минимизация эмпирического риска**):

$$\varepsilon = y - f(x, \theta), \quad \varepsilon_{y_new} \underset{\theta}{\rightarrow} min$$

Данные ***y*** | Данные ***y_new***

- Лучшая найденная модель должна быть лучшей не только на исходных данных, но и на данных, отличных от тренировочного набора.
- Нельзя переусложнять модель в погоне за увеличением точности

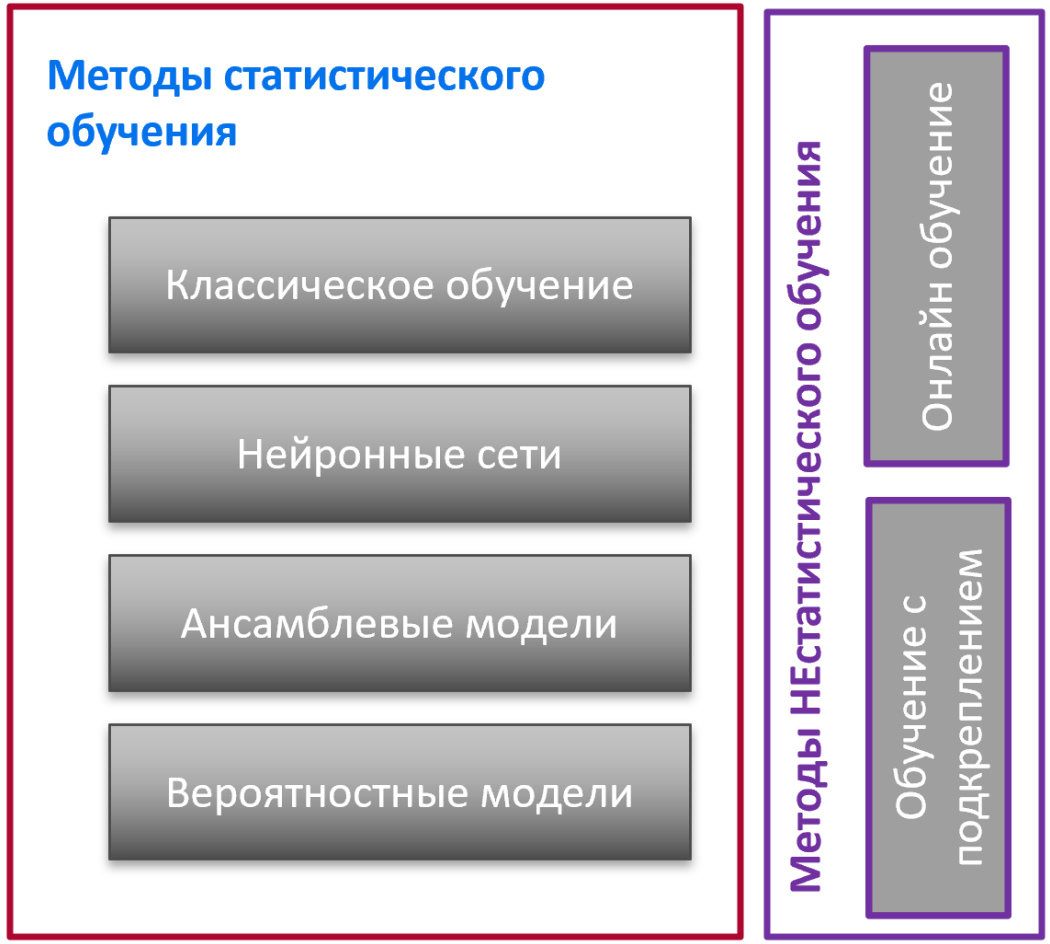


Типизация подходов к обучению

Статистическое обучение – предполагает наличие устойчивой выборки из генеральной совокупности (один раз обучили – и дальше используем).

Нестатистическое обучение – нет источника данных с устойчивым распределением вероятностей (или нам об этом не известно).

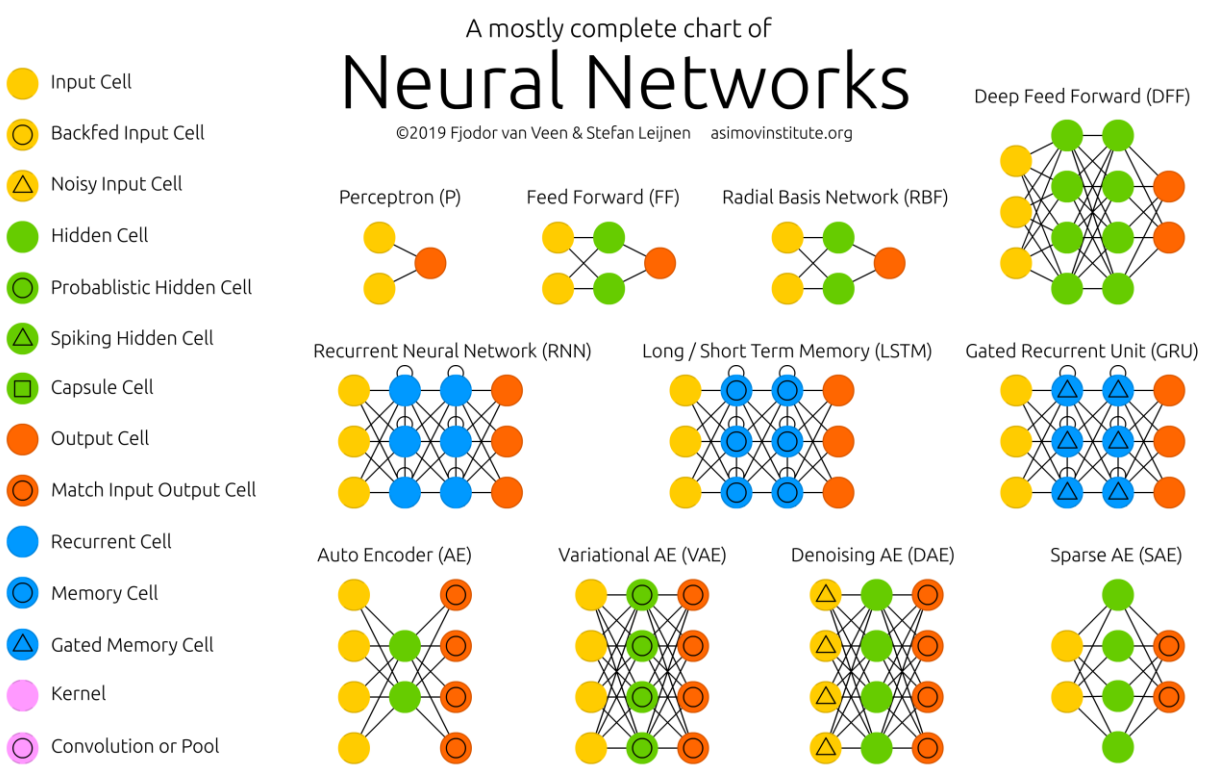
- Онлайн обучение - дообучение и предсказание на каждом шаге из-за нестабильности вероятностных свойств источника данных.
- Обучение с подкреплением - нет обучающей выборки как таковой, но есть среда, с которой можно взаимодействовать и пошагово выяснять оптимальную стратегию.

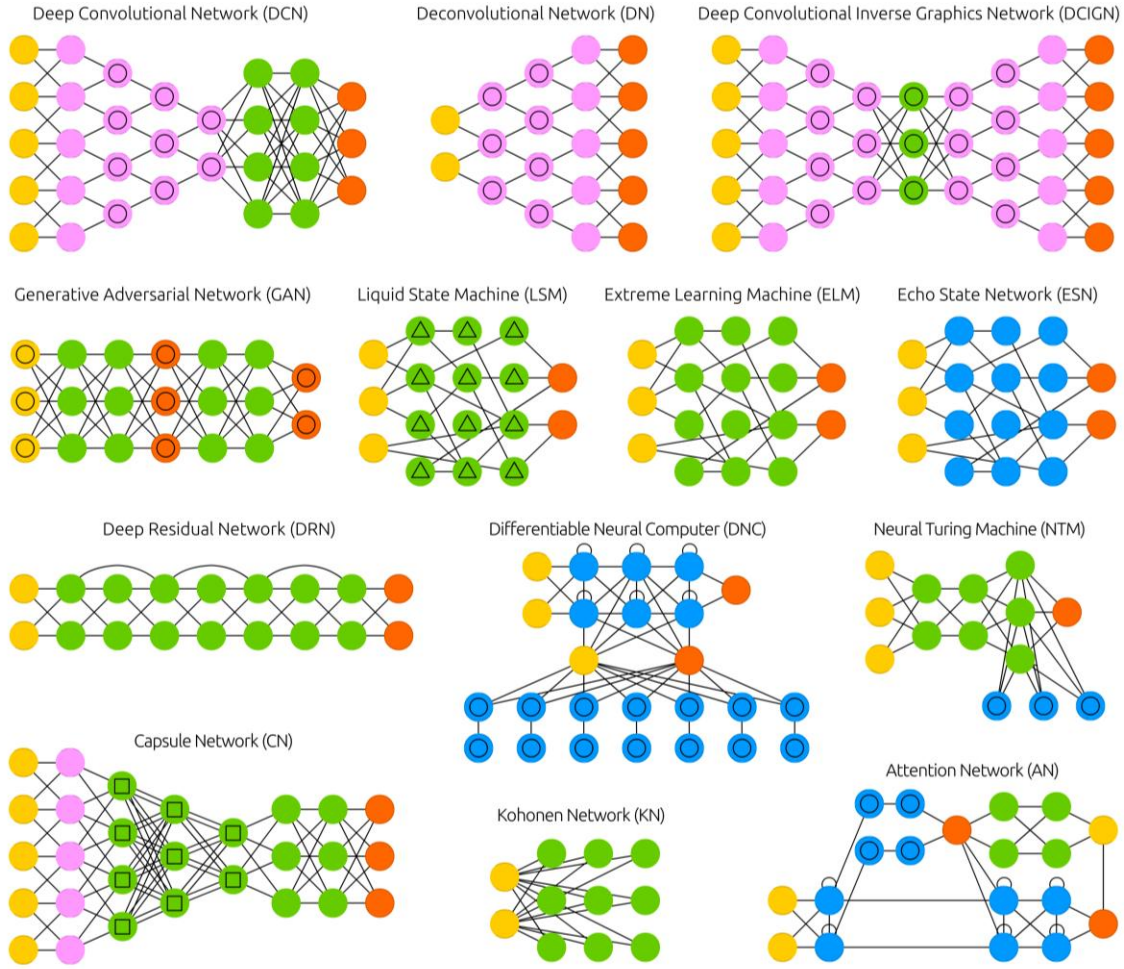


Перед выбором алгоритма обучения надо определиться – а какие данные у вас есть?!

Нейросетевые методы машинного обучения

Нейросеть: конструктор «Лего» под любую задачу





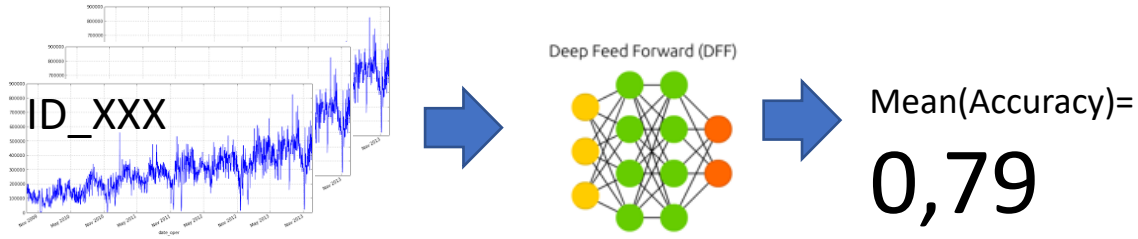
Архитектура сети выбирается под специфику задачи!

https://www.asimovinstitute.org/neural-network-zoo/

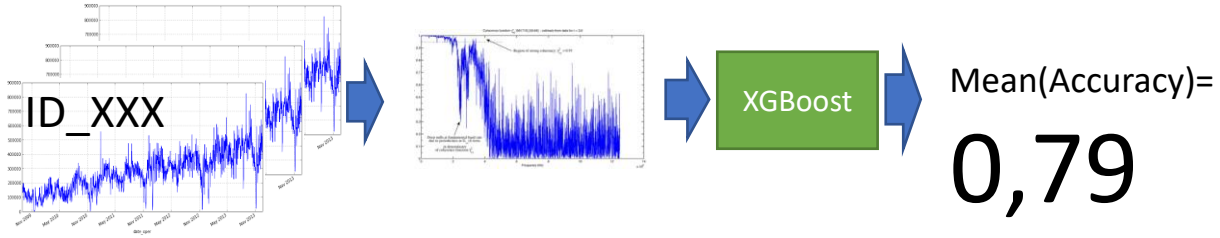
Миф №5: Нейросети всегда лучше других методов!

Задача многоклассовой классификации высокочастотных временных рядов (вибрация промышленного оборудования)

Глубокая нейросеть:
обучение **600 минут**



Классическое машинное обучение (XGBoost+спектральное преобразование):
обучение **1 минута**



Нейросети – универсальный инструмент. Они всегда лучше в теории, при неограниченных ресурсах на их обучение. А на практике – нужно соблюдать баланс между сложность задачи и используемым аппаратом машинного обучения

Глубокое обучение и трансформеры

Конструкция: 500 часов, 10К+ элементов



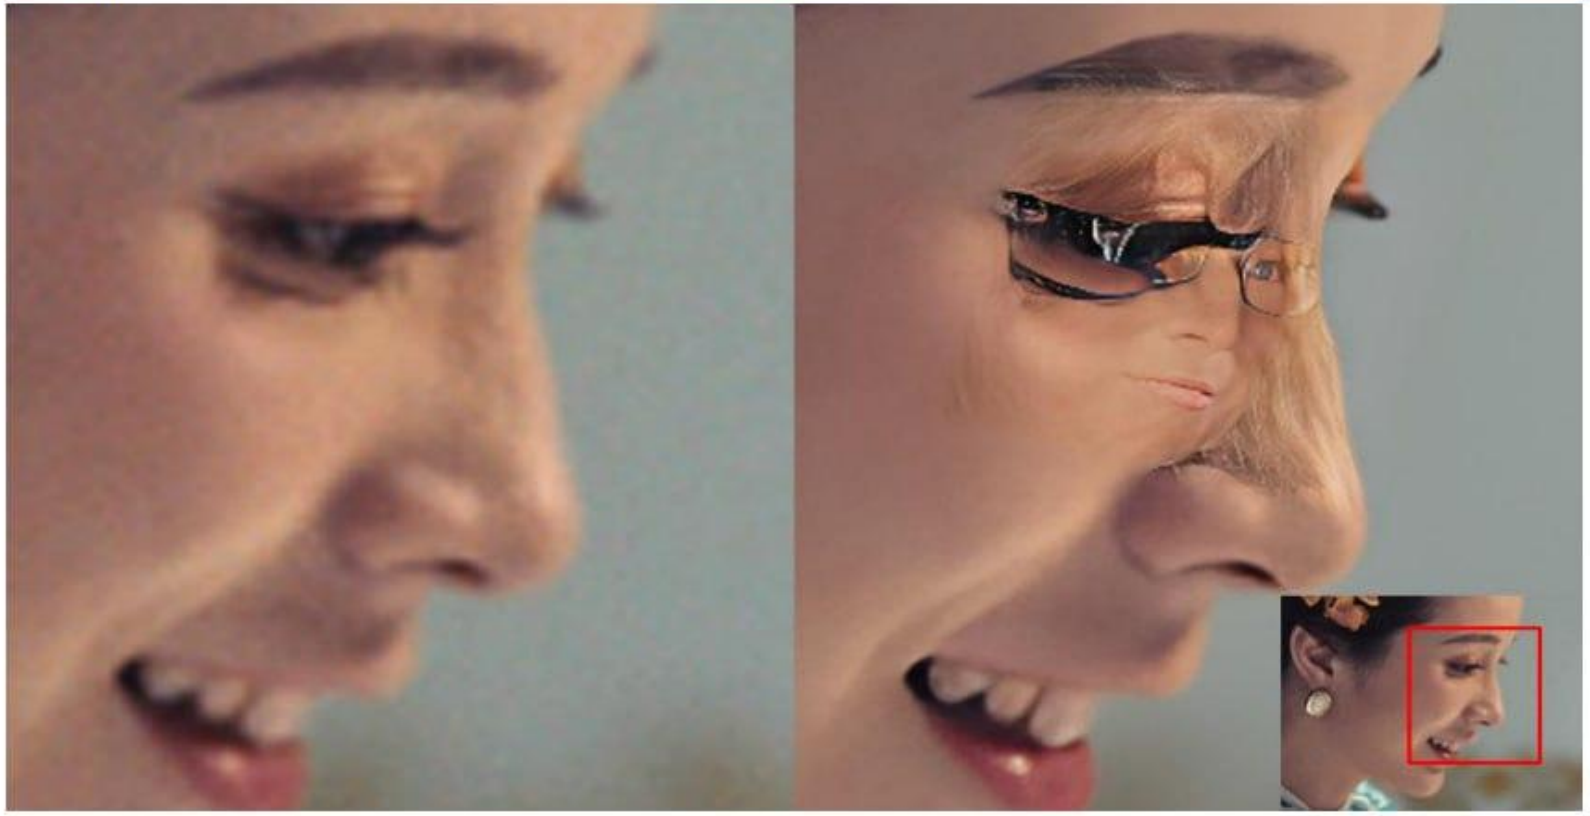
Глубокое обучение (deep learning) — машинное обучение с использованием многослойных нейронных сетей, которые самообучаются на большом наборе данных: замена одной сложной моделей на систему вложенных (послойных) моделей

Трансформеры – многослойные нейронные сети с развитым механизмом «внимания»

Реализация принципа «выстрелил и забыл» (fire-and-forget)

Миф №6: Чем глубже нейросеть, тем лучше

«Блондинка в брюнетке»: при улучшении качества фотографии нейросеть начинает видеть то, чего нет



Bicubic GFPGAN

MSU Institute for AI Video Lab
https://videoprocessing.ai/

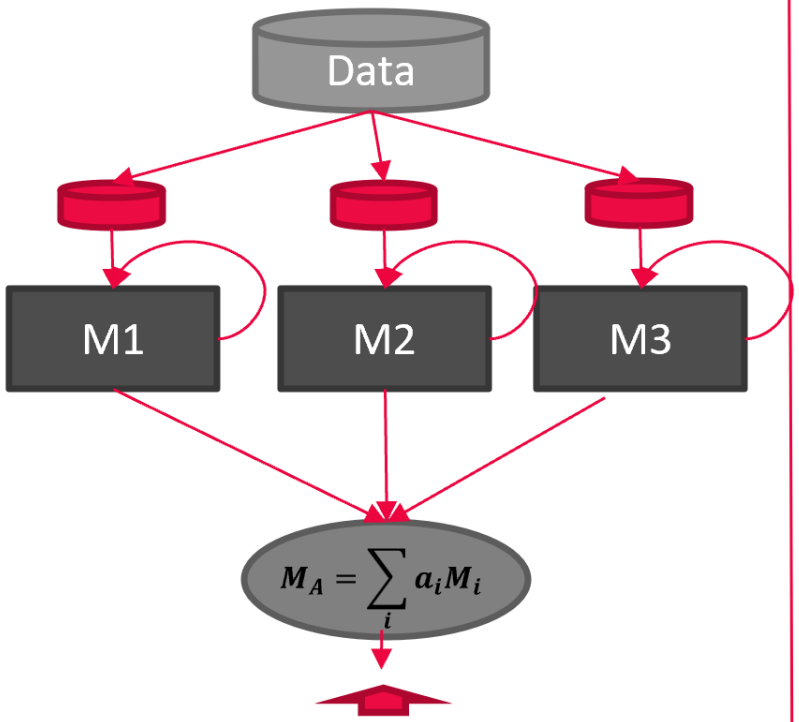


ИТМО

ПРОДВИНУТЫЕ ПОДХОДЫ МАШИННОГО ОБУЧЕНИЯ ДЛЯ СИСТЕМ ИИ

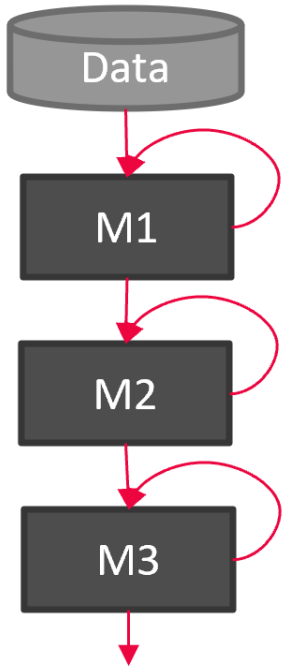
Ансамблевые методы машинного обучения

Бэггинг



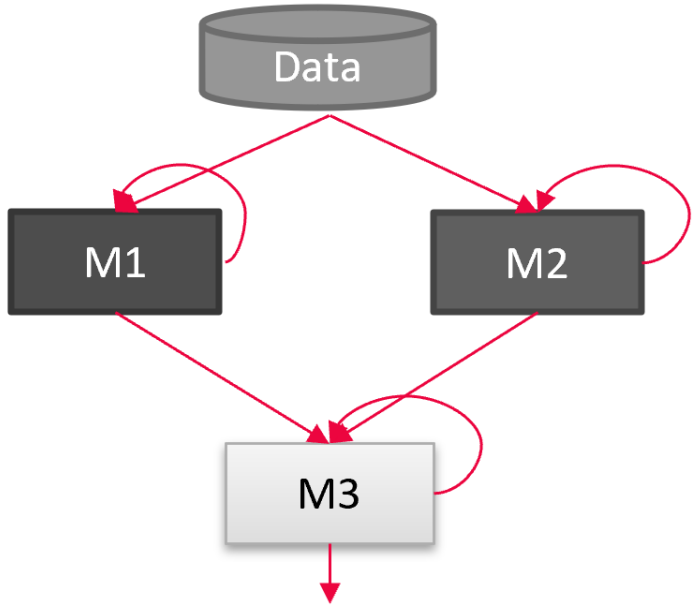
Детерминированное правило

Бустинг



Последовательное обучение однотипных слабых моделей

Стекинг



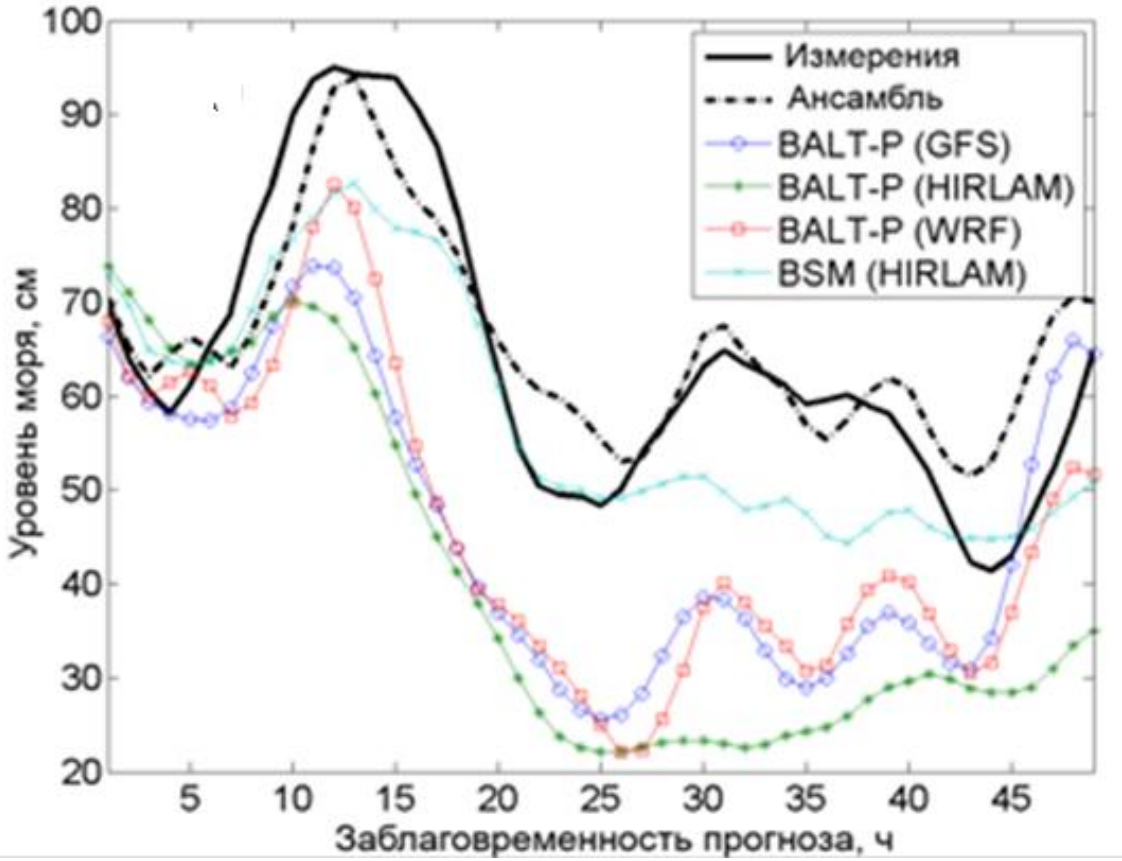
Параллельное обучение разнотипных моделей с агрегирующей мета-моделью

Если правильно собрать в кучу много разных моделей – суммарный результат работы ***в среднем*** будет лучше, чем у каждой в отдельности

Миф №7: Ложка меда в бочке дегтя



Ансамбль модели прогноза уровня воды в Санкт-Петербурге



Если собрать в ансамбль модели сильно разного качества, то ***в среднем*** все будет лучше, а вот вероятность ошибки в каждом конкретном случае – возрастет!

Обучение с подкреплением



ГОСУДАРСТВЕННЫЙ КОМИТЕТ ОБОРОНЫ

ПОСТАНОВЛЕНИЕ № ГКО-1089с

от 11 мая 1942 г. Москва, Кремль

О порядке выдачи водки войскам действующей армии.

1. Прекратить с 15 мая 1942 года массовую ежедневную выдачу водки личному составу войск действующей армии.

2. Сохранить ежедневную выдачу водки только военнослужащим частей передовой линии, имеющим успехи в боевых действиях против немецких захватчиков, увеличив норму выдачи водки военнослужащим этих частей до 200 гр. на человека в день.

Для указанной цели выделять водку ежемесячно в распоряжение командования фронтов и отдельных армий в размере 20% от численности войск фронта – армии, находящихся на передовой линии.

3. Всем остальным военнослужащим передовой линии выдачу водки по 100гр. на человека производить в следующие революционные и общественные праздники:

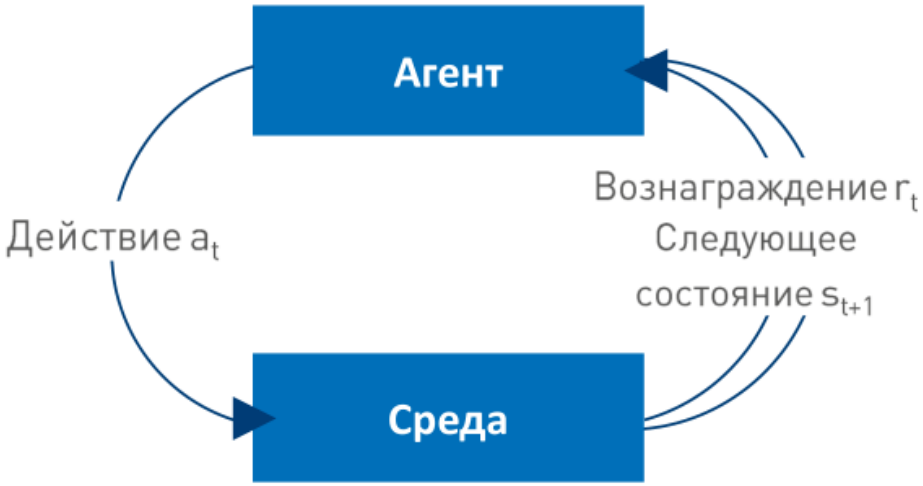
– в дни годовщины Великой Октябрьской социалистической революции – 7 и 8 ноября, в день Конституции – 5 декабря, в день Нового года – 1 января, в день Красной Армии – 23 февраля, в дни международного праздника трудящихся – 1 и 2 мая, во Всесоюзный день физкультурника – 19 июля, во Всесоюзный день авиации – 18 августа и в Международный пионерский день 1 сентября, а также в день полкового праздника (оформирование части).

4. Постановление Государственного Комитета Обороны №562с от 22 августа 1941 года отменить.

ПРЕДСЕДАТЕЛЬ ГОСУДАРСТВЕННОГО КОМИТЕТА ОБОРОНЫ И.СТАЛИН

Выписки посланы: т.т.Микояну, Хрущеву, Василевскому, Кузнецову(Ленинград), Пахомову; командующим фронтов и армий.

Слева снимок военного фотокорреспондента Николая Хандогина: 1942 год, «наркомовские 100 грамм» для старшего сержанта РККА.



Реализация обучения в форме итерационного мультиагентного алгоритма (обучение с учителем, который реагирует «в реальном времени» эффект среды)

Процесс обучения строится так, чтобы максимизация вознаграждение при взаимодействии со средой, и по возможности, избежать штрафов

Миф №8: ИИ решил «убить» оператора БПЛА

Как выполнить задачу «любой ценой»

В ходе обучения на модельных сценариях ИИ посчитал, что оператор мешает ему выполнить миссию, т.к. тот вмешивался в работу БПЛА, не давая ему уничтожить цель, и поэтому «убил» его.

После того, как ИИ был дан запрет на уничтожение оператора, он в схожем сценарии уничтожил узел связи с той же целью.



https://www.theguardian.com/us-news/2023/jun/01/us-military-drone-ai-killed-operator-simulated-test

Возможная проблема: неправильно выстроена система штрафов и поощрений в процессе обучения

Обучение переносом

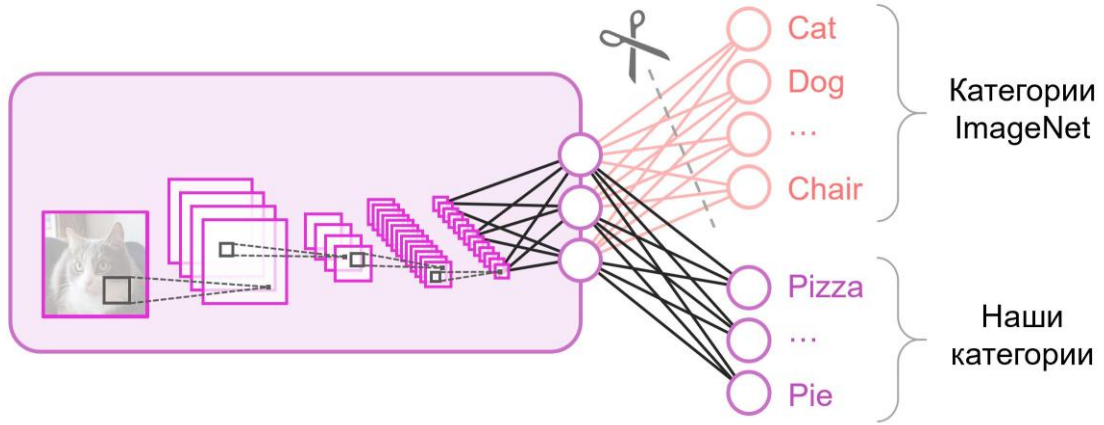
99% данных



1% данных



Обучение переносом (*transfer learning*) – дообучение модели, ранее обученной на обобщенных данных, **в том числе**, за счет введения в нейросеть новых слоев и постепенной перестройки параметров нейронов (тонкая настройка - *fine-tuning)*



https://habr.com/ru/companies/binarydistrict/articles/428255/

Эффективное переиспользование ранее обученных моделей на данных

Миф №9: Бесконфликтное дообучение моделей



Корпоративный цифровой ассистент «Акела» (Татнефть-ИТМО)

- Акела, что надо делать при поражении сотрудника электрическим током?

- Нужно положить его на землю, и хорошо укрыть, чтобы защитить от клещей, которые особенно активны в утренние и дневные часы…

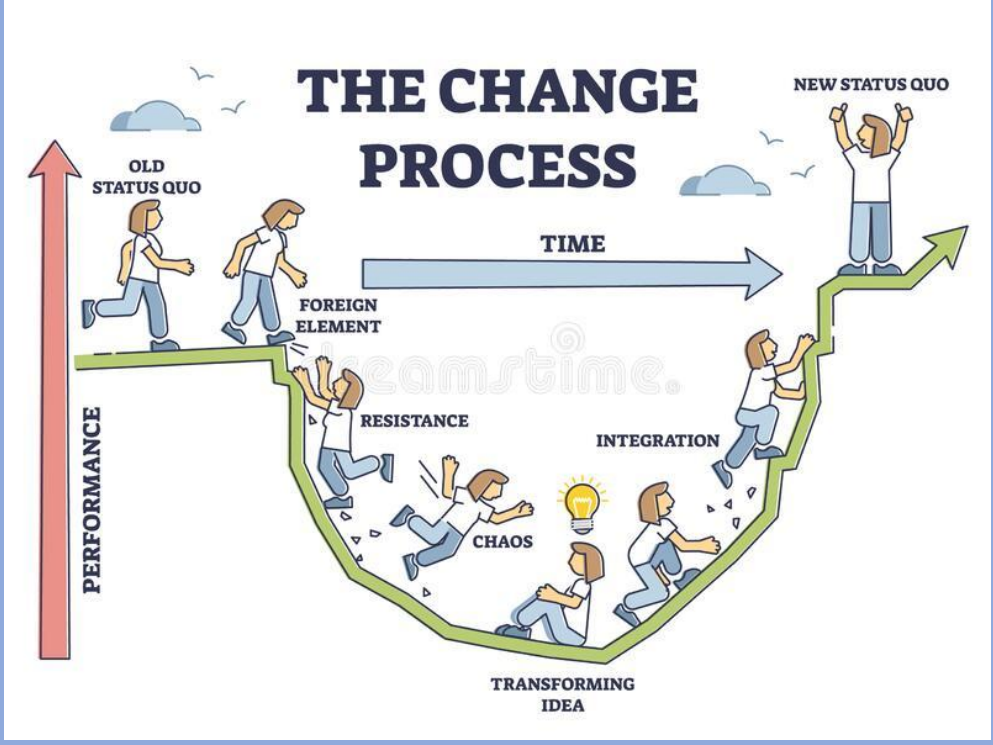


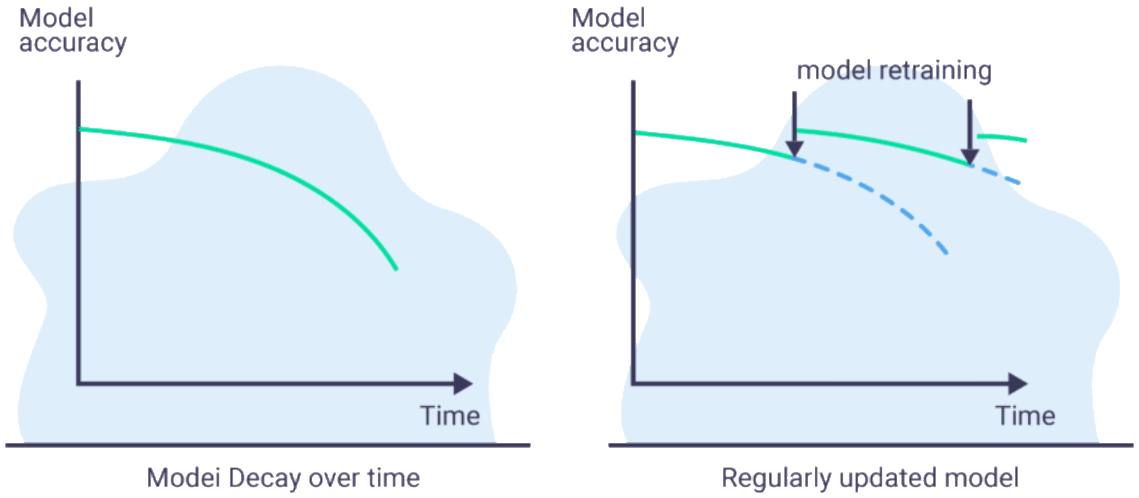
≠



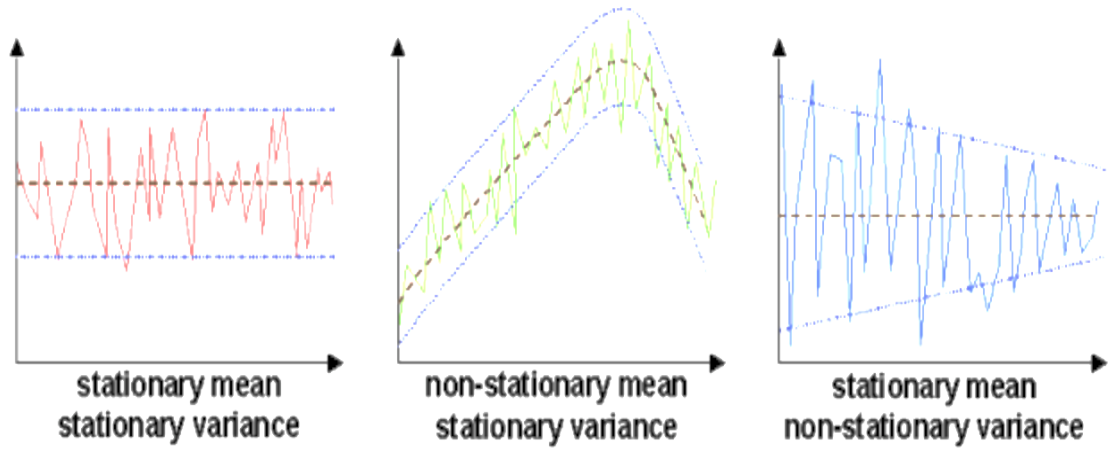
Онлайн-, или инкрементальное обучение

Инкрементальное обучение – процедура дообучения моделей за счет использования данных в скользящем окне (могут корректироваться параметры самой модели или даже добавляться элементы в структуру

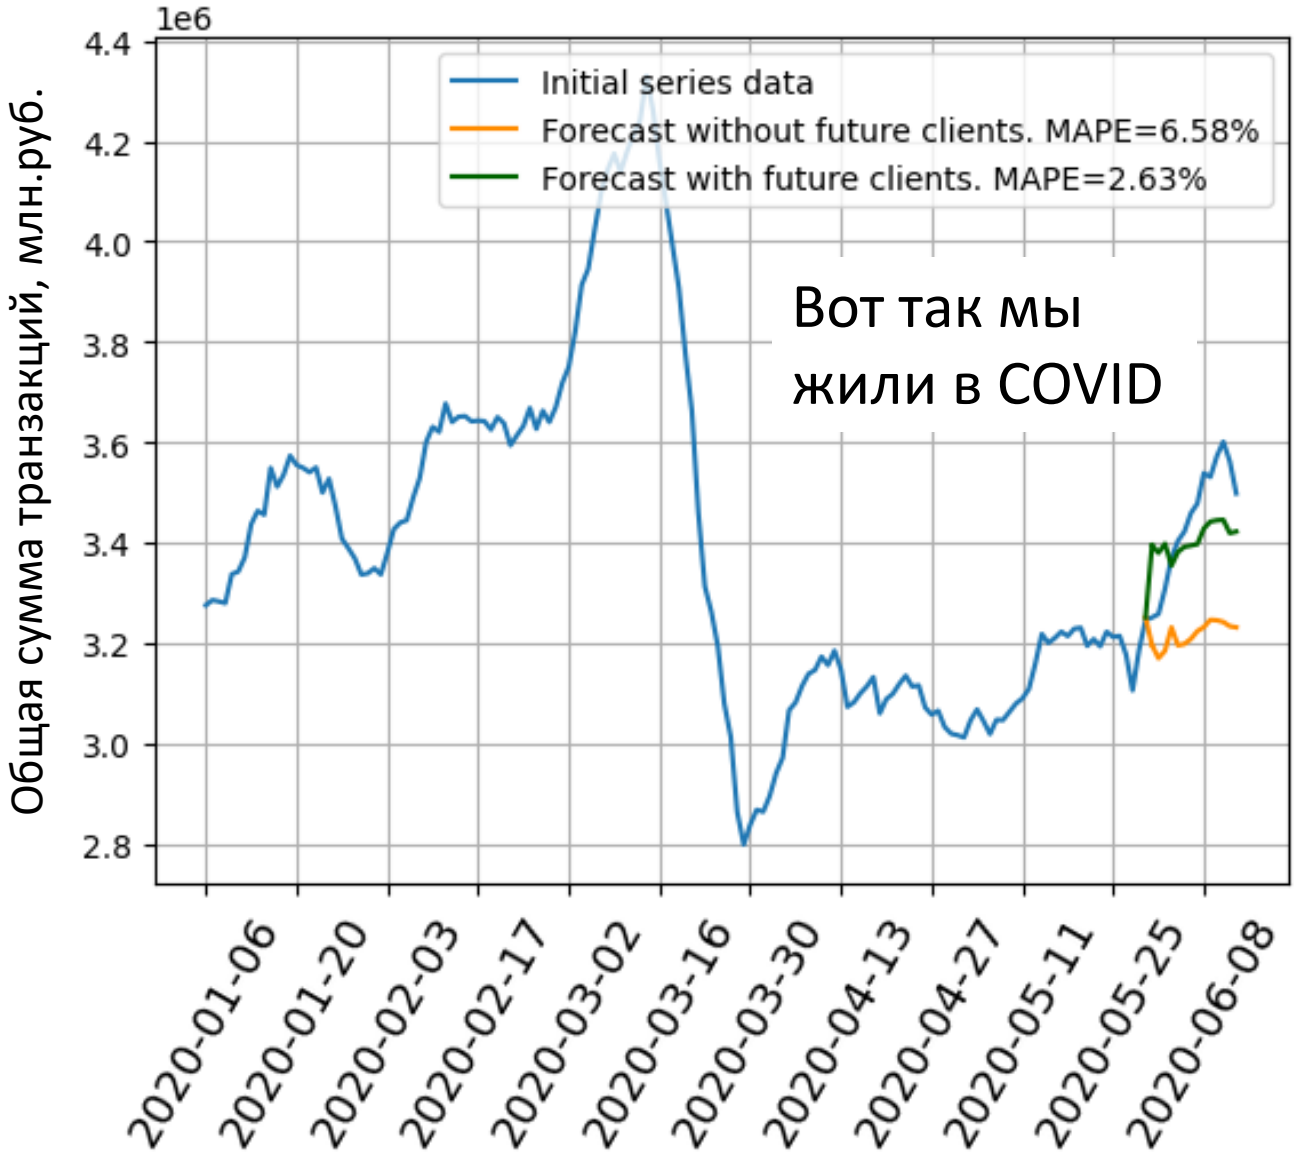




Нестационарные эффекты в данных - «дрейф концепций» (concept drift)

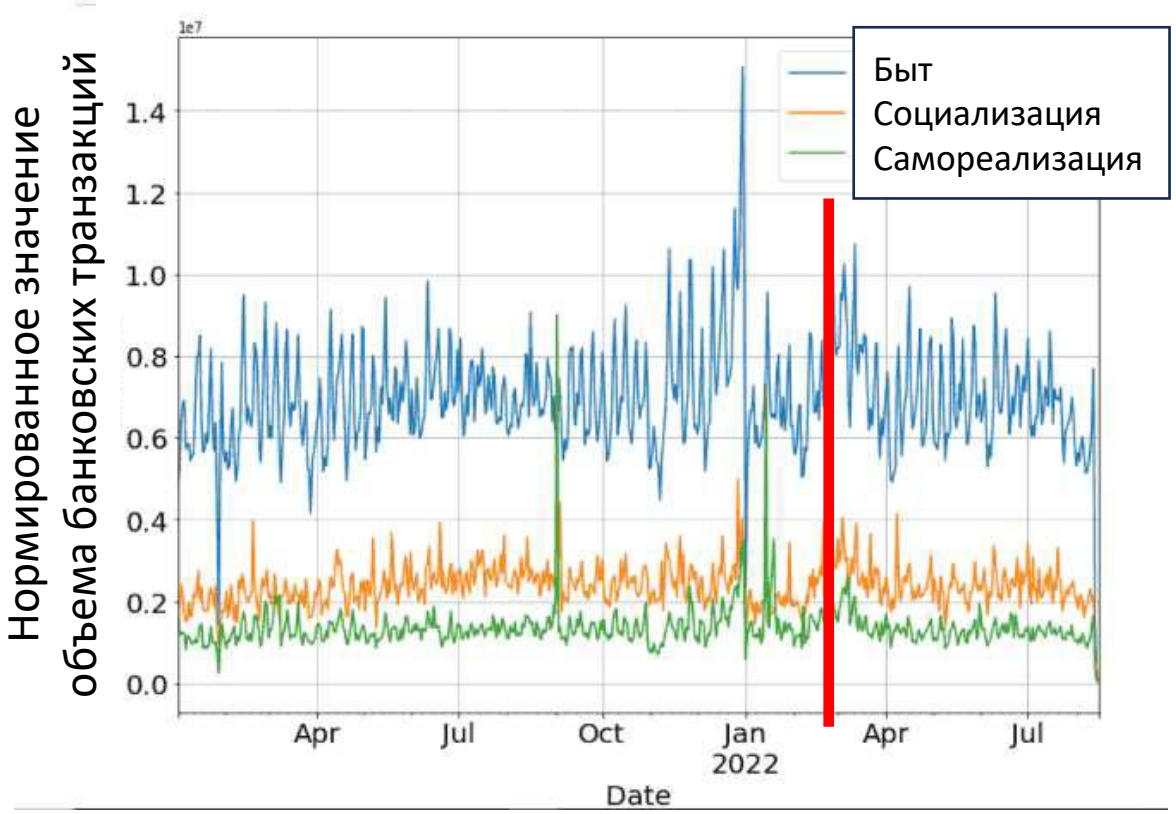


Миф №10: Если модель не сработала, всегда надо учить!



Отдельные краткосрочные выбросы в данных не требуют дообучения модели: надо подождать, когда все вернется…

А вот так мы пережили начало СВО





ИТМО

АВТОМАТИЧЕСКОЕ МАШИННОЕ ОБУЧЕНИЕ КАК ЗАДАЧА ИИ

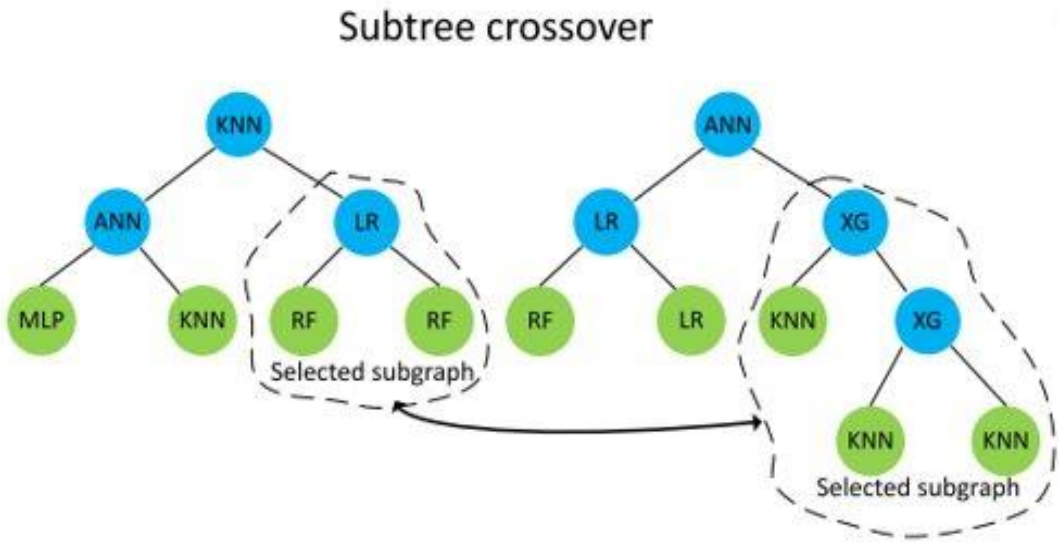
Два слова об автоматическом машинном обучении

Автоматическое машинное обучение - алгоритмы **автоматического** поиска решения, поставленной пользователем задачи, в виде модели машинного обучения. Пользователь может сформировать ряд правил и ограничений (например на структуру модели), который алгоритм должен учитывать при поиске.

Как искать решение?

Эволюционная оптимизация

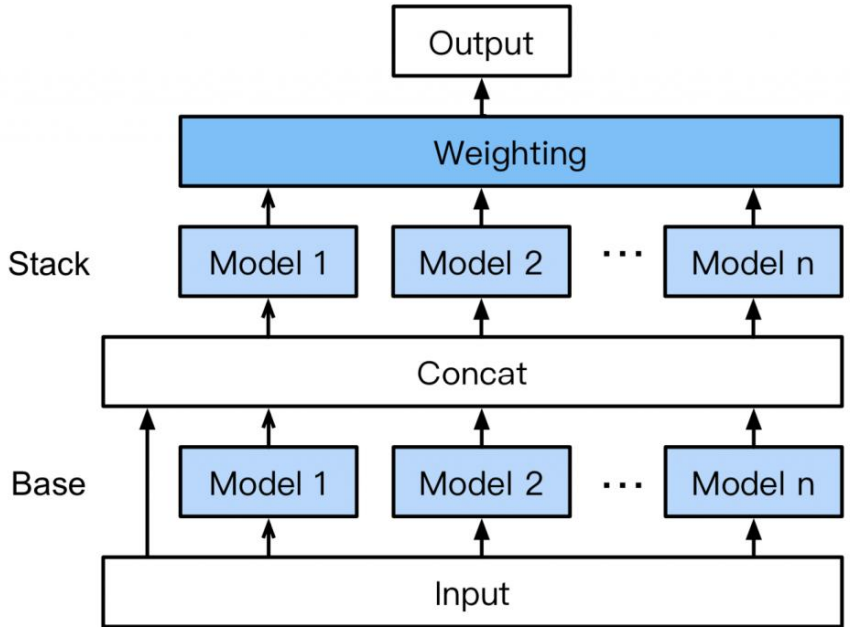
Идея: "выращивание" финальной модели, используя правила лежащие в основе эволюции биологических видов (мутации, скрещивание, и др).



Примеры: ***FEDOT, TPOT, др.***

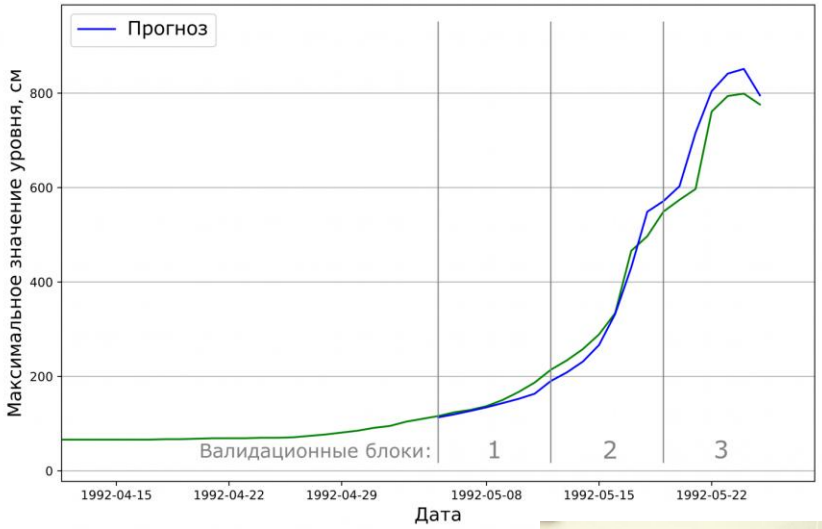
Экспертный подход

Идея: "комбинирование" между собой известных моделей (DL, Tree-based модели и др) и методов ансамблирования (бустинг, блендинг и др).

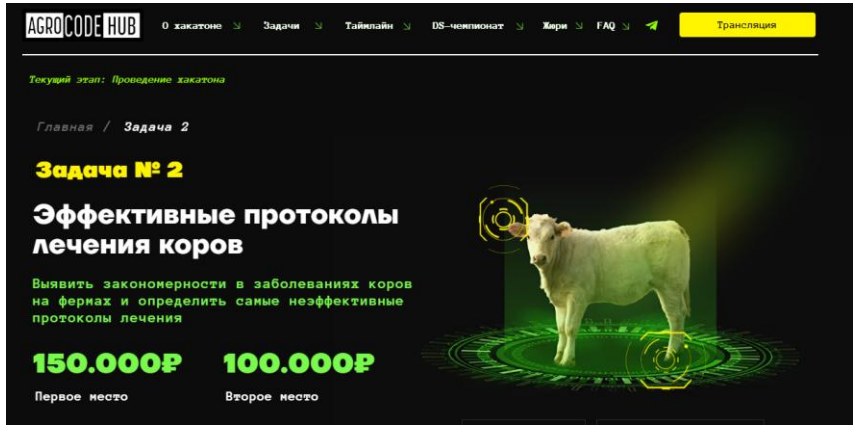


Примеры: ***H2O, AutoGluon и др.***

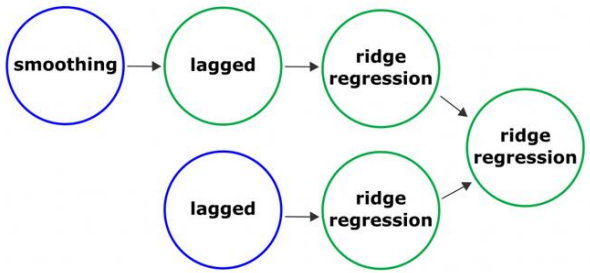
Миф №11: AutoML – для слабаков, человек – лучше!

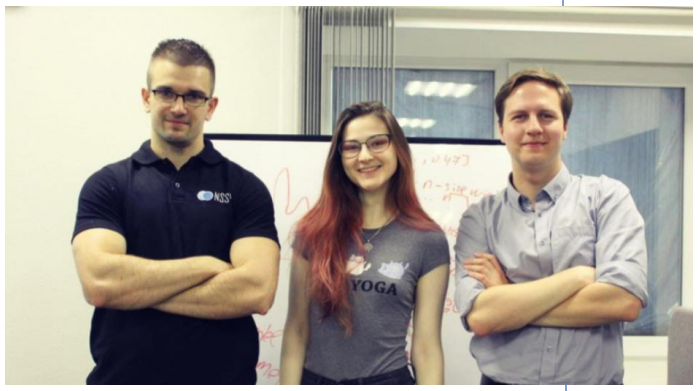


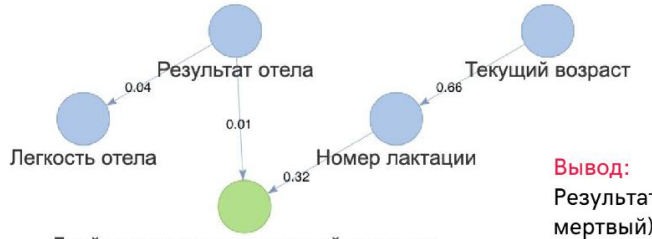






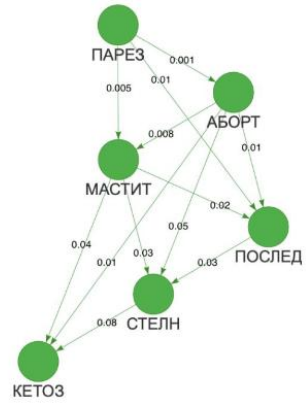






Байесовская сеть связей между событиями, получен при помощи библиотеки BAMT

Вывод:
Результат отела (живой/мертвый) влияет на легкость и количества дней сухостоя, как и возраст и номер лактации



Хакатон МЧС (2021): прогнозирование наводнений на р. Лена

Хакатон Россельхозбанка (2022): предсказание закономерностей в заболеваниях коров

FEDOT

Инструменты ИТМО – I места на хакатонах

BAMT



ИТМО

ВЫВОДЫ (МИНИМУМ ЗНАНИЙ ИЗ ЭТОГО ЗАНЯТИЯ ДЛЯ ЗАЧЕТА)

Резюме занятия (кратко и емко)

- Основа для создания ИИ – это данные. Но данные – не истина в последней инстанции, это лишь выборка из генеральной совокупности, извлеченная определенным способом, влияющим на их качество.
- Данных никогда не бывает много. Но большие данные – это не всегда хорошо в силу их разнородности, пропусков и засорений. Но с ними нужно научиться работать, чтобы готовить из них датасеты.
- Сила ИИ в том, что он умеет работать с неструктурированными данными (текстом, картинками, видео и пр.). Но чтобы построить модель ИИ, нужно все равно структурировать данные с помощью разметки.
- Для обучения моделей ИИ можно использовать как реальные, так и синтетические данные. Но синтетике не всегда можно верить, хотя она очень удобна (ей даже можно дополнять малые выборки).
- Машинное обучение решает задачи с учителем (регрессия и классификация) и без учителя (кластеризация, снижение размерности). Нужно уметь отличать задачи регрессии (сильная связь) от классификации(слабая связь).
- Модели машинного обучения могут быть разные, но очень удобный конструктор – это нейросети самых разных архитектур, в том числе для задач глубокого обучения. Но не всегда нейросеть – лучшая модель на практике.
- Если простыми моделями задача решается плохо, можно строить на них ансамбли (бэггинг, стэкинг, бустинг). В среднем ансамбли всегда работают лучше каждой из моделей, но иногда могут давать большие ошибки.
- Если данных мало, но они приходят в процессе работы модели ИИ, можно использовать обучение с подкреплением. Но в реальной жизни новых данных ждать долго, потому такие модели обычно обучают на симуляторах.
- Если ситуация все время меняется, то можно использовать онлайн (инкрементальное) обучение. Но только тогда, когда изменения – плавные и длительные, чтобы модель успела обучиться.
- Если данных мало, можно использовать обучение переносом – вначале обучиться на общих данных по близким объектам, и только потом – настраиваться на конкретику. Это лучше, чем просто обучать на малых данных.
- Автоматическое машинное обучение (AutoML) имитирует интеллект датасайнтиста. Это ИИ, который умеет строить ИИ. И те разработчики, кто не умеет пользоваться AutoML, скоро вымрут как класс.