ИТМО

Занятие 3. Оценка качества систем ИИ

Александр Валерьевич Бухановский

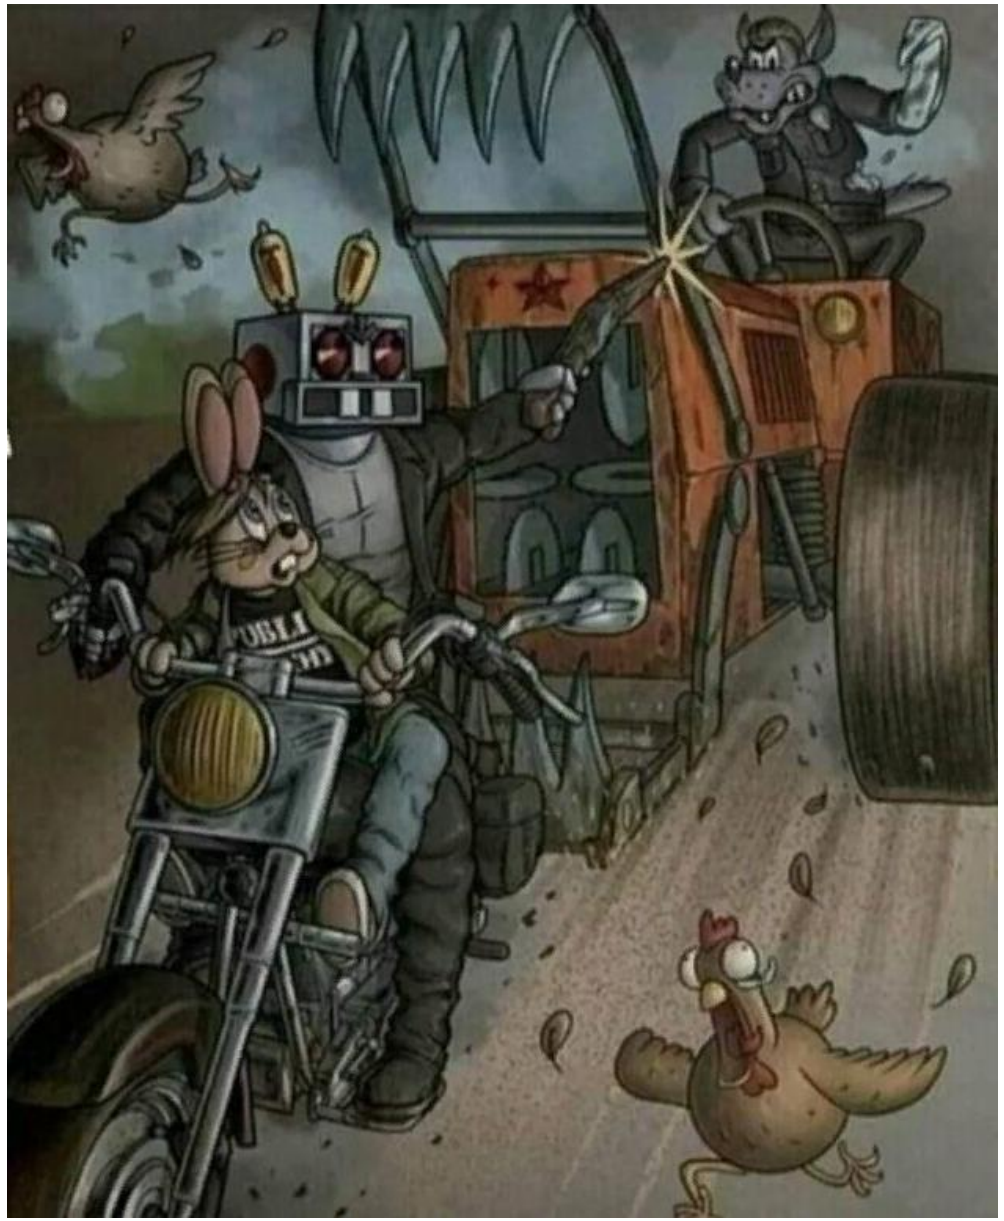
Доверяй, но проверяй: о качестве решений ИИ

1) **Контролируемое окружение** (фильтрация «информационного шума», создаваемого за счет того, что ИИ мыслит быстрее, чем человек)

2) **Контролируемое качество** (уверенность в мере отклонения от истины)

3) **Контролируемая логика** (возможность объяснения вывода ИИ в «человеческих терминах»)

4) **Контролируемый результат** (понимание, что ИИ выполняет именно твою задачу, а не какую-то свою собственную)



ИИ объективно имеет право на ошибку
– ее нельзя устранить, но можно оценить...
и смириться ☺

Формальное определение качества систем ИИ

ФЕДЕРАЛЬНОЕ АГЕНТСТВО

ПО ТЕХНИЧЕСКОМУ РЕГУЛИРОВАНИЮ И МЕТРОЛОГИИ

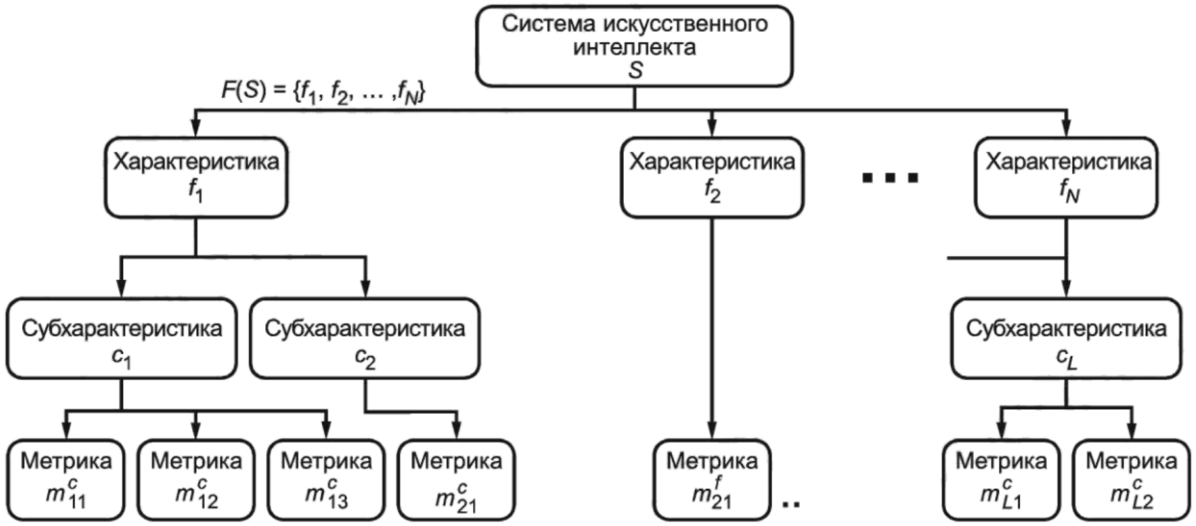
НАЦИОНАЛЬНЫЙ СТАНДАРТ РОССИЙСКОЙ ФЕДЕРАЦИИ

ГОСТ Р 59898— 2021

ОЦЕНКА КАЧЕСТВА СИСТЕМ ИСКУССТВЕННОГО ИНТЕЛЛЕКТА

Общие положения

В качестве характеристик – точность, производительность, устойчивость, эргономичность, и даже… этичность!



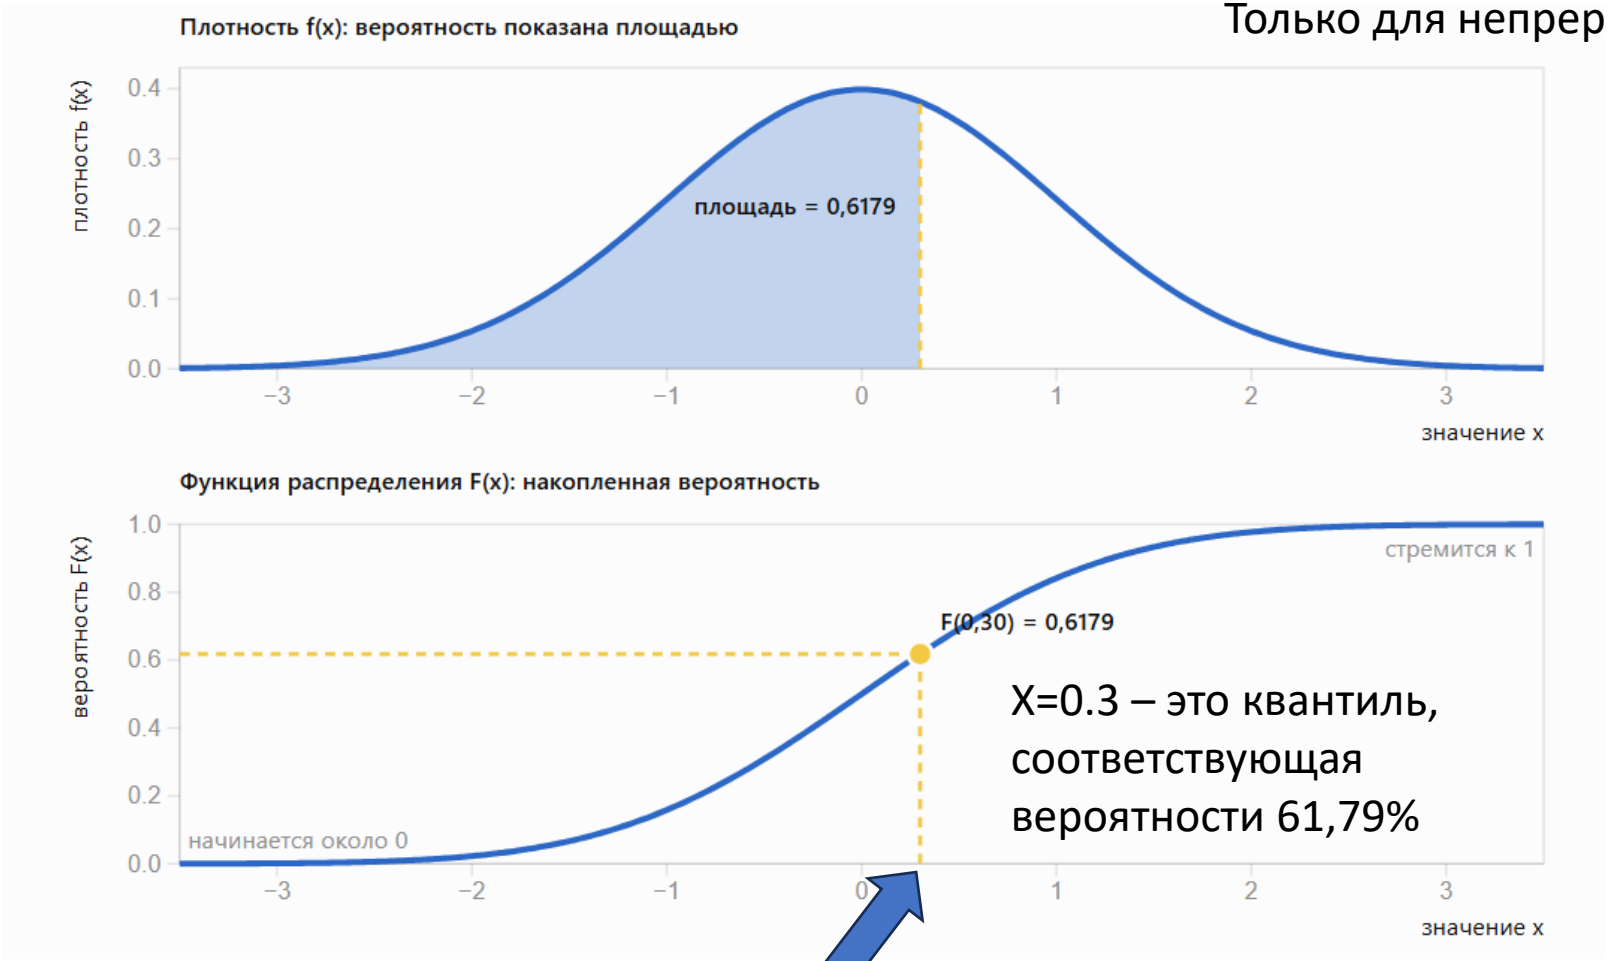
Для системы ИИ качество = {набор характеристик объекта техники и технологий}, для модели ИИ качество – точность решения задачи на данных, на которых система не обучалась



ИТМО

ОСНОВЫ ИНТЕРВАЛЬНОГО ОЦЕНИВАНИЯ НА НА ДАННЫХ

Функция и плотность распределения вероятностей



Только для непрерывных случайных величин

Плотность распределения:

$$f_\xi(x) = \frac{dF_\xi(x)}{dx}$$

Функция распределения:

$$F_\xi(x) = P(\xi \le x)$$

X=0.3 – это квантиль, соответствующая вероятности 61,79%

p%-квантиль (процентиль):

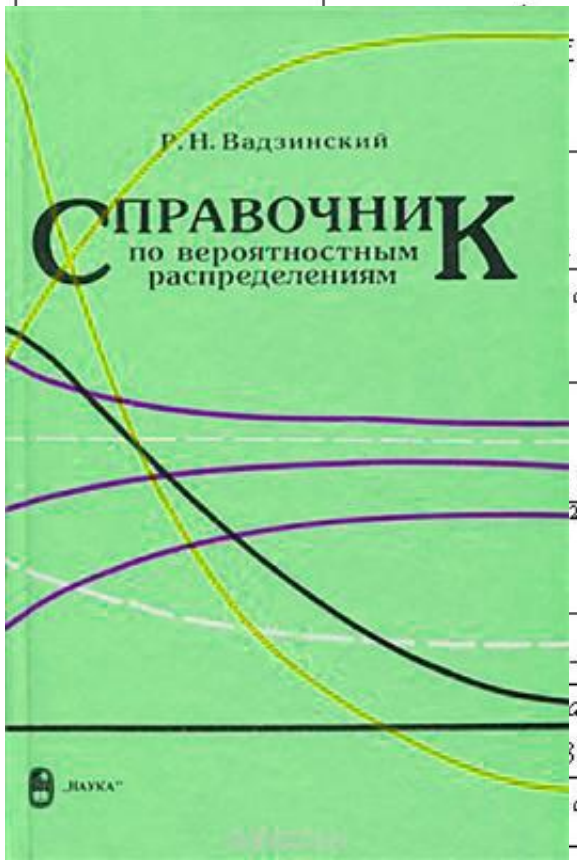
$$x_p: \quad F_\xi(x_p) = p$$

Понятие квантили – ключевое для исчисления вероятностей случайных величин: весь мир описывается биекцией $x_p \leftrightarrow p$

Такие разные распределения

http://izmerenee.ucoz.org/index/4_9_zakony_raspredelenija_sluchajnykh_pogreshnostej/0-24

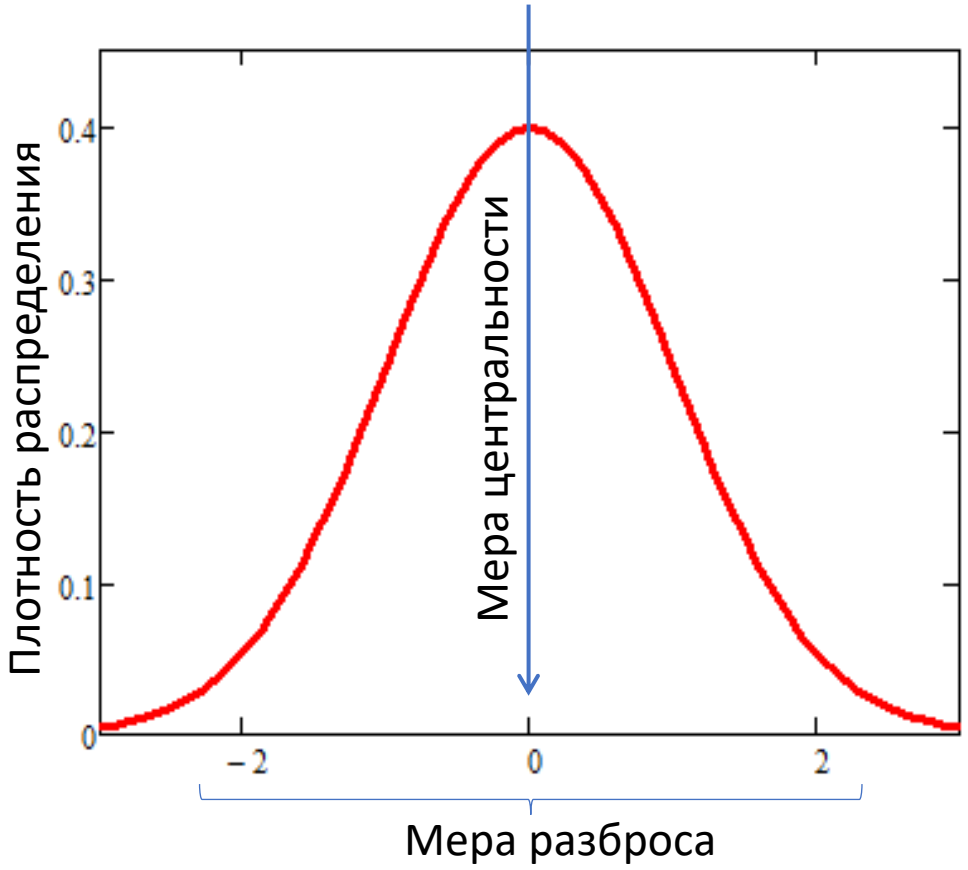
Закон распределения	Аналитическая зависимость	Область определения	Соотношения между параметрами	Гр… фун…
		$\|x\| \le a$	$a = 3\sigma$	
		$\|x\| \le a$	$a = 1{,}73\sigma$	
		$\|x\| \le a$	$a = 2{,}45\sigma$	
		$\frac{a}{3} \le \|x\| \le a$ $\|x\| \le \frac{a}{3}$	$a = 2{,}32\sigma$	



Тип и функция плотности распределения	Математическое ожидание m_1, дисперсия m_2, асимметрия $b_1 = m_3/m_2^{3/2}$, эксцесс $b_2 = m_4/m_2^2$
Нормальное $\frac{1}{\sigma\sqrt{2\pi}}\exp(-(x-\mu_1)^2/(2\sigma^2))$, $-\infty < x < \infty$	$m_1 = \mu_1, \quad m_2 = \sigma^2 = \mu_2,$ $b_1 = 0, \quad b_2 = 3$
Логарифмически нормальное $\frac{1}{\sigma x\sqrt{2\pi}}\exp\left(-\frac{(\ln x-\mu_1)^2}{2\sigma^2}\right), \; x > 0,$ $0, \qquad x \le 0$	$m_1 = \exp(\mu_1 + 0{,}5\mu_2),$ $m_2 = \exp(2\mu_1+\mu_2)(\exp(\mu_2)-1),$ $b_1 = (\exp(\mu_2)+2)\sqrt{\exp(\mu_2)-1},$ $b_2 = \exp(4\mu_2)+2\exp(3\mu_2)+$ $+3\exp(2\mu_2)-3$
Экспоненциальное $\lambda\exp(-\lambda x), \quad x \ge 0,$ $0, \qquad x < 0$	$m_1 = 1/\lambda, \quad m_2 = 1/\lambda^2,$ $b_1 = 2, \quad b_2 = 9$
Вейбулла $\frac{\beta}{\delta}\left(\frac{x}{\delta}\right)^{\beta-1}\exp\left(-\left(\frac{x}{\delta}\right)^{\beta}\right), \; x \ge 0,$ $0, \qquad x < 0$ $\delta > 0, \beta > 0$	$m_1 = \delta g_1, \quad m_2 = \delta^2(g_2 - g_1^2),$ $b_1 = (g_3 - 3g_1g_2 + 2g_1^3)/(g_2-g_1^2)^{3/2},$ $a = (g_4 - 4g_1g_3 + 6g_2g_1^2 - 3g_1^4),$ $b_2 = a/(g_2-g_1^2)^2,$ $g_i = \Gamma(1+i/\beta)$
Гамма $\frac{\lambda^{\nu}}{\Gamma(\nu)}x^{\nu-1}\exp(-\lambda x), \quad x \ge 0,$ $0, \qquad x < 0$	$m_1 = \nu/\lambda \quad m_2 = \nu/\lambda^2,$ $b_1 = 2/\sqrt{\nu},$ $b_2 = 3(\nu+2)/\nu$

http://opds.sut.ru/old/electronic_manuals/oed/f05.htm

Количественные характеристики распределения



Мера центральности (например, математическое ожидание):

$$M_\xi = \int_{-\infty}^{+\infty} x f_\xi(x) dx$$

Дисперсия: $D_\xi = \int_{-\infty}^{+\infty} (x - M_\xi)^2 f_\xi(x) dx$

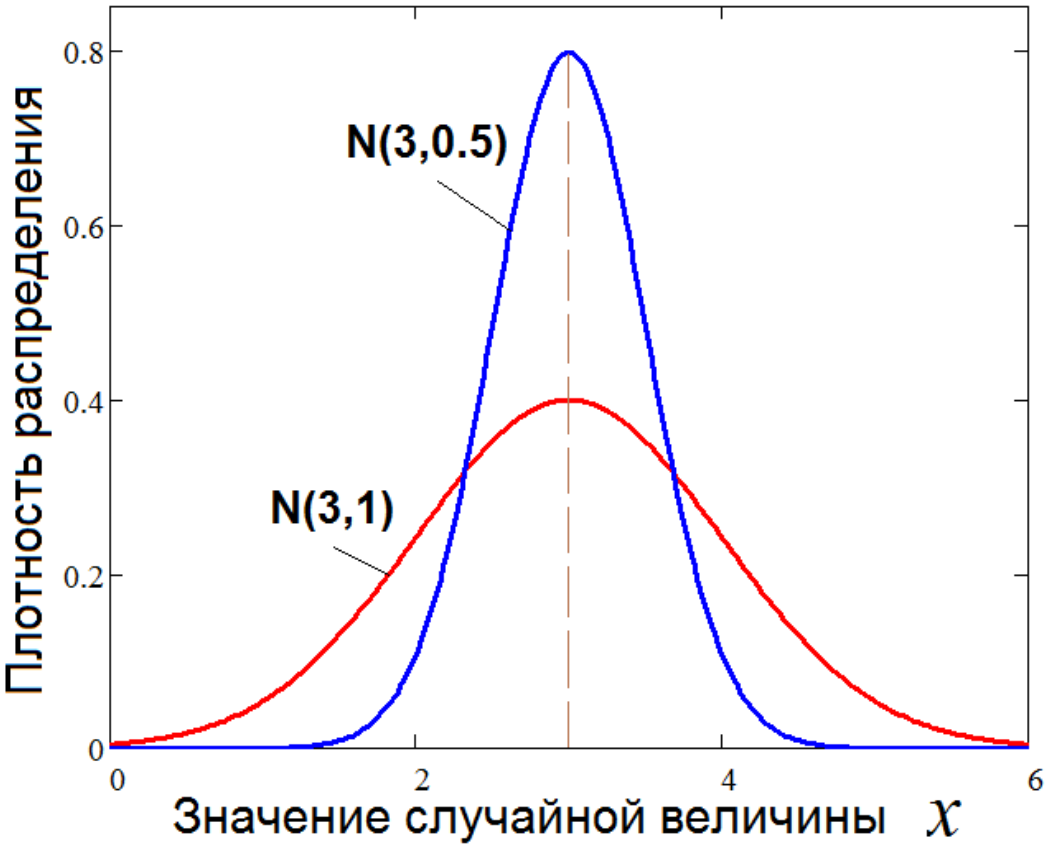
Мера разброса (например, среднеквадратичное отклонение, СКО): $\sigma_\xi = \sqrt{D_\xi}$

В аналитической модели распределения параметры формулы однозначно связаны с математическим ожиданием, дисперсией и квантилями

Полезное распределение: модель Гаусса

Плотность распределения: $$f_\xi(x) = \frac{1}{\sqrt{2\pi}\sigma_\xi} exp\left[-\frac{(x - M_\xi)^2}{2\sigma_\xi^2}\right]$$

Обозначение: $\boldsymbol{N}(M_\xi, \sigma_\xi)$



Расчет p%-квантили распределения Гаусса:

$$x_p = M_\xi + \sigma_\xi u_p$$



Характерные квантили нормированного распределения Гаусса

p	75%	90%	95%	97.5%	99%
u_p	0.674	1.282	1.645	1.960	2.236

Точечное оценивание в статистике

Статистика – правило определения характеристики Ξ по выборке $(x_1, \dots, x_N)$ при заданной вероятностной мере P :

$$\Xi^* = T_P(x_1, \dots, x_N)$$



Результат применения статистики – оценка Ξ^* характеристики Ξ

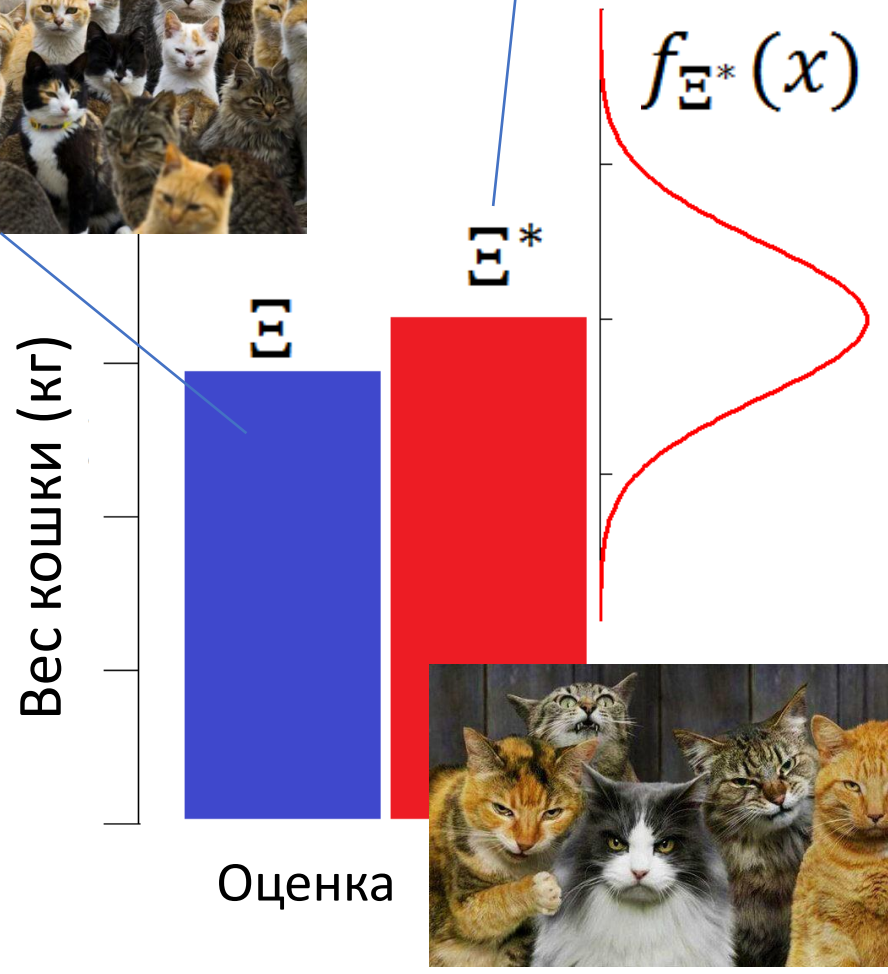


Оценка Ξ^* - случайная величина с функцией распределения $F_{\Xi^*}(x)$ и плотностью распределения $f_{\Xi^*}(x)$

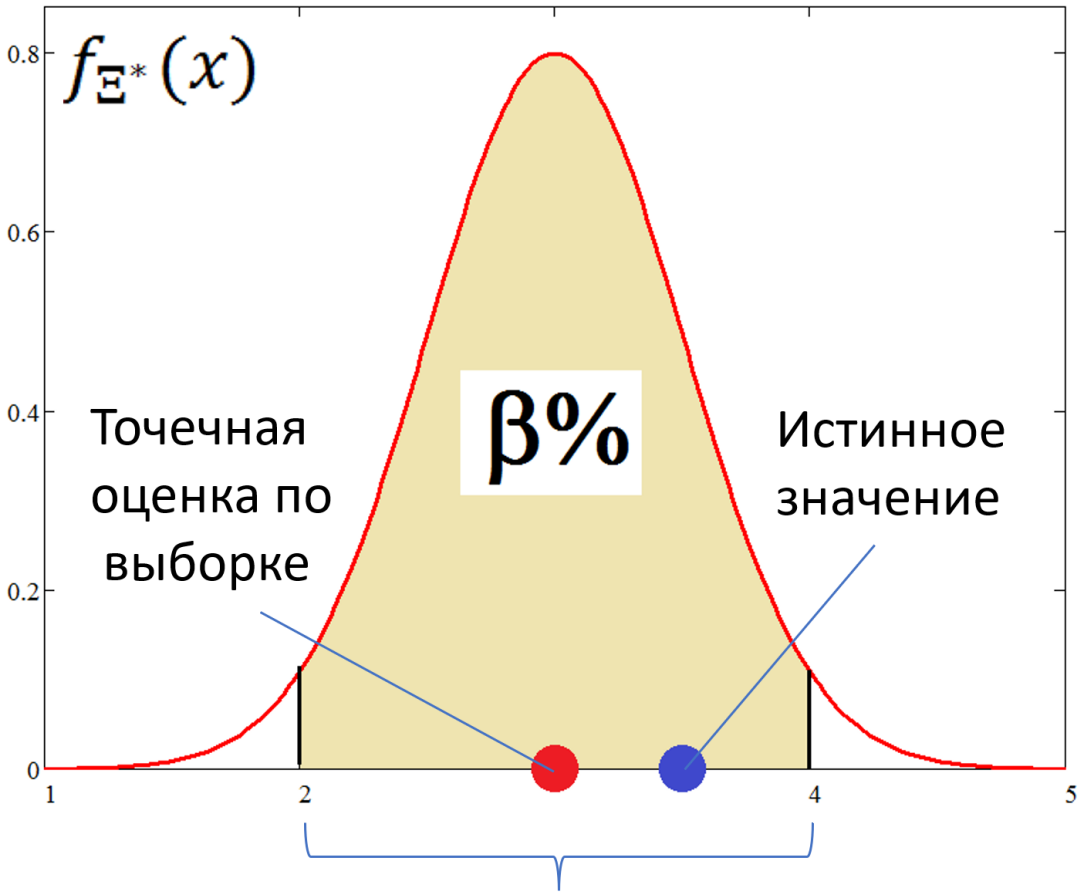
Истинное значение (вся совокупность)



Точечная оценка по выборке



Вероятностный и доверительный интервалы



β% *двусторонний* доверительный интервал

Вероятностный интервал (ВИ) $[I_1, I_2]$:

$$F_{\Xi}(I_2) - F_{\Xi}(I_1) = \beta$$

Односторонний ВИ (или/или):

$$F_{\Xi}(I_1) = \beta, \;\; I_2 \sim +\infty \quad \text{(правый)}$$

$$F_{\Xi}(I_2) = \beta, \;\; I_1 \sim -\infty \quad \text{(левый)}$$

Двусторонний (симметричный) ВИ:

$$F_{\Xi}(I_1) = (1-\beta)/2$$

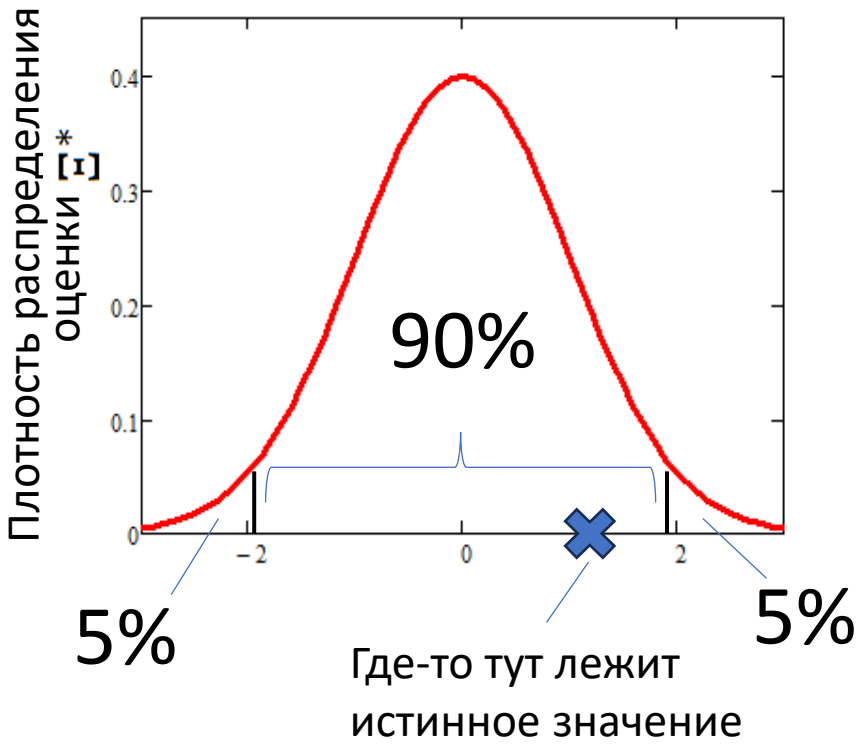
$$F_{\Xi}(I_2) = (1+\beta)/2$$

Доверительный интервал – это **вероятностный** интервал для статистической оценки

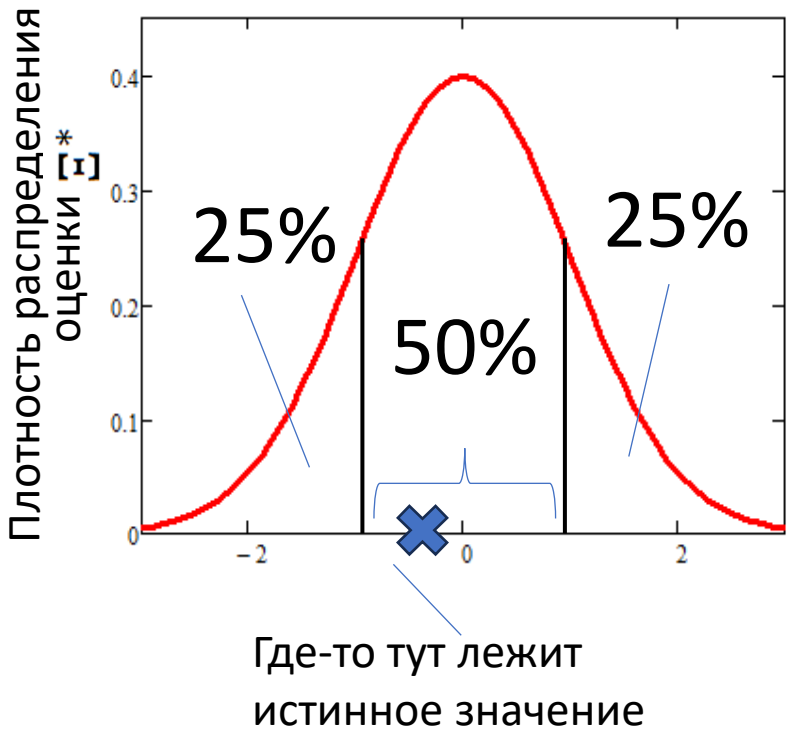
Примеры доверительных интервалов

Задача: по выборке найти интервальную оценку статистики $\Xi^* = T_P(x_1, \ldots, x_N)$
- например, математического ожидания (как среднего арифметического).

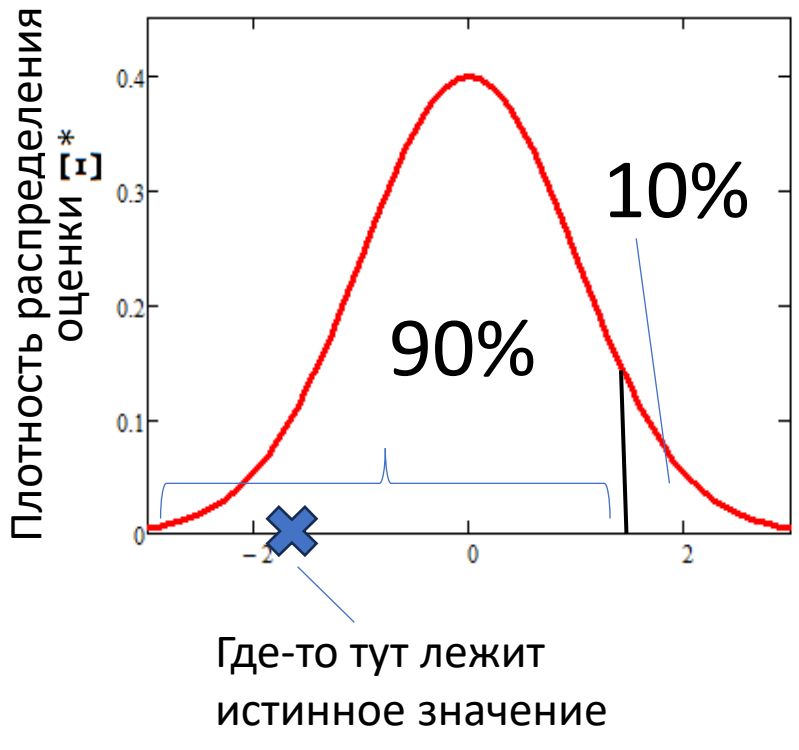
(а) – 90% - доверительный интервал



(б) – 50% - доверительный интервал



(в) – Односторонний 90% - доверительный интервал



Чем больше % в доверительном интервале, тем больше гарантий, что мы им накрываем истинное значение нашей величины

Пример: частота как оценка вероятности

Дано: выборка $(x_1, \dots, x_N)$ реализаций случайного события («орел», «решка»,«на ребро»)

Событие *A* реализуется в выборке *k* раз



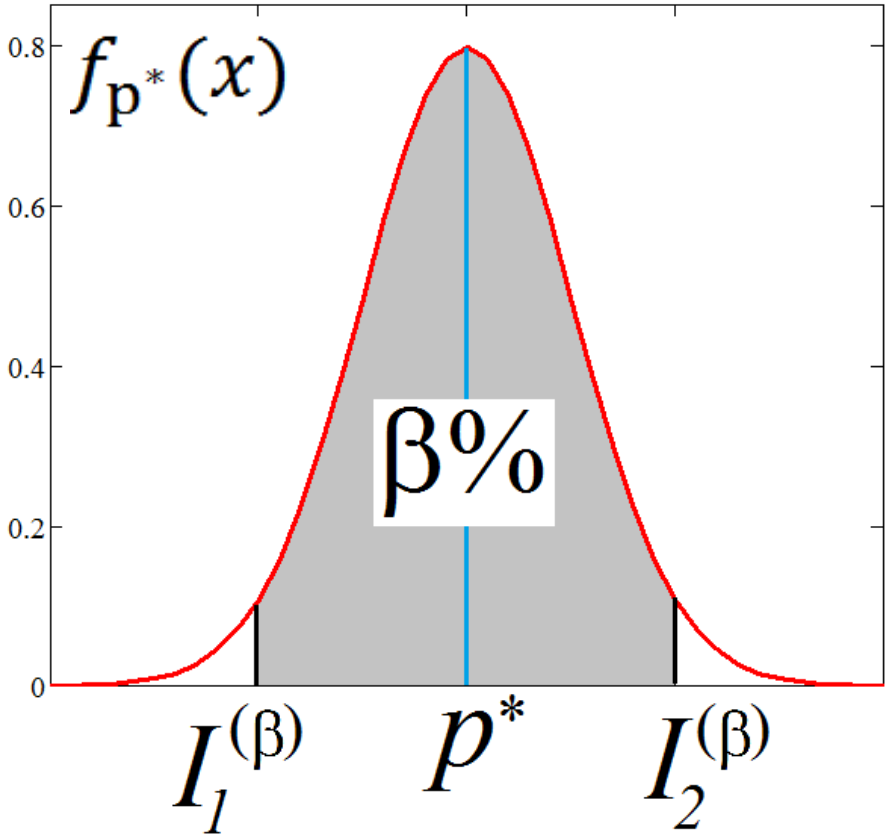
Частота реализации события *A* (выборочная оценка вероятности):



$$p^* = \frac{k}{N}$$

Несмещенность гарантирована $M_{p^*} = p$

Интервальная оценка вероятности



β%-доверительный интервал:

$$I_{1,2}^{(\beta)} = p^* \pm u_\beta \sigma_{p^*}$$

Для **бесконечно большой** генеральной совокупности:



$$\sigma_{p^*} \cong \sqrt{\frac{p^*(1-p^*)}{N}}$$

Если генеральная совокупность **конечна** (размером $\hat{N} > N$):

$$\sigma_{p^*} \cong \sqrt{\frac{p^*(1-p^*)}{N}} \cdot \sqrt{1-\frac{N}{\hat{N}}}$$

Интервал сокращается



Задача на понимание интервалов

В группе 100 человек, из них 70 мальчиков и 30 девочек. Постройте 95%-доверительный интервал для вероятности, что выбранный наугад студент – девочка ☺

1) Найдем точечную оценку вероятности «быть девочкой»: $p^* = \frac{30}{100} = 0{,}3$

$$\sigma_{p^*} \cong \sqrt{\frac{p^*(1-p^*)}{N}}$$

2) Найдем среднеквадратичное отклонение оценки вероятности : $\sigma_{p^*} = \sqrt{\frac{0{,}3 \cdot (1-0{,}3)}{100}} = 0.046$

$$I_{1,2}^{(\beta)} = p^* \pm u_\beta \sigma_{p^*}$$

3) Определим границы интервала через квантили распределения Гаусса:

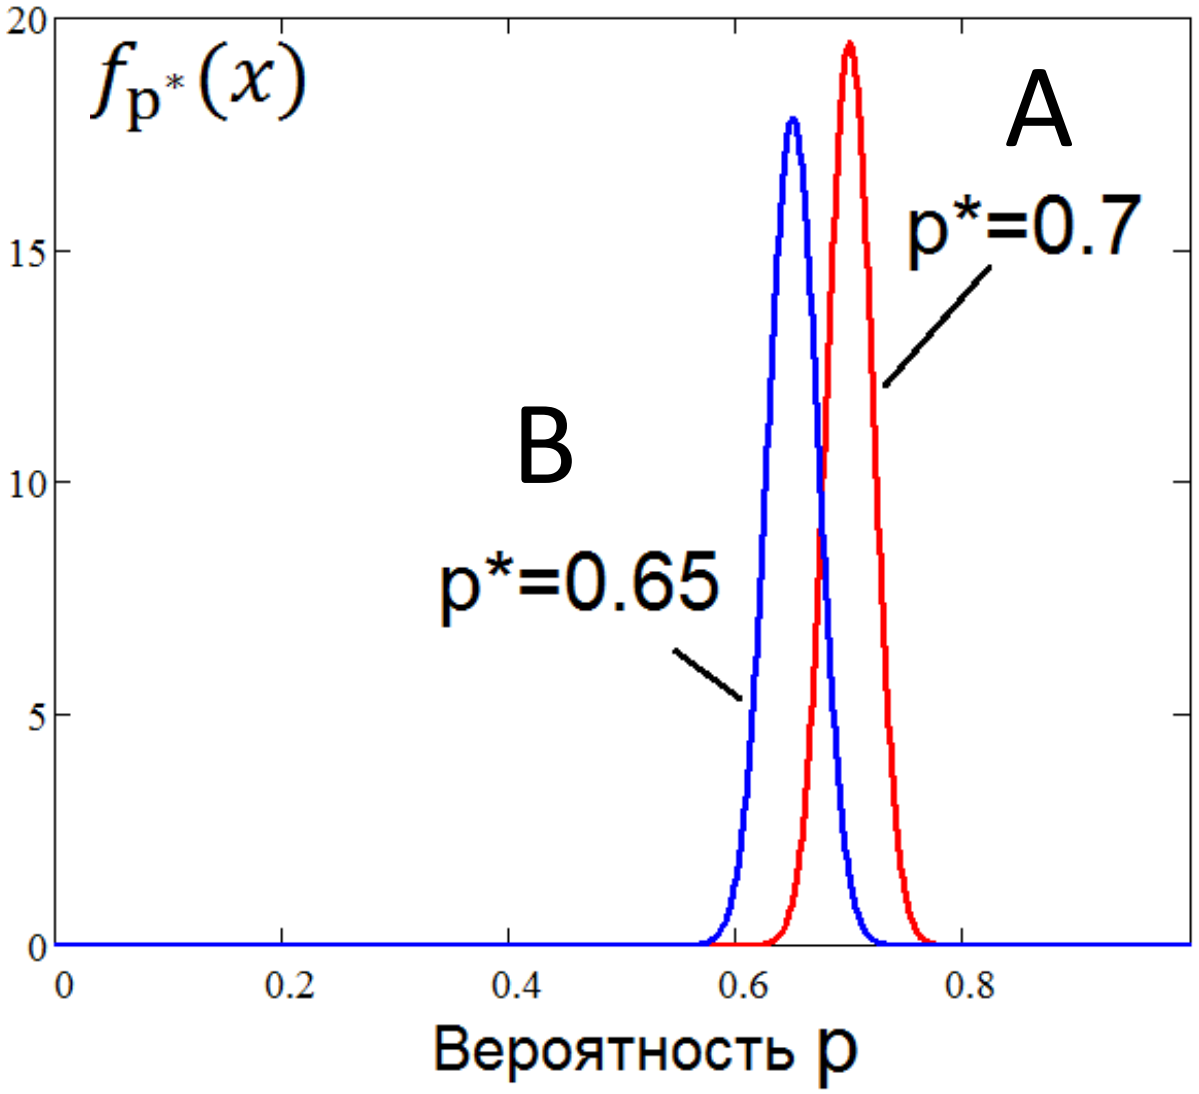
$$\beta = 95\% \quad p = 0{,}30 \pm 1{,}96 \cdot 0{,}046 \quad [0{,}21\,;0{,}39]$$

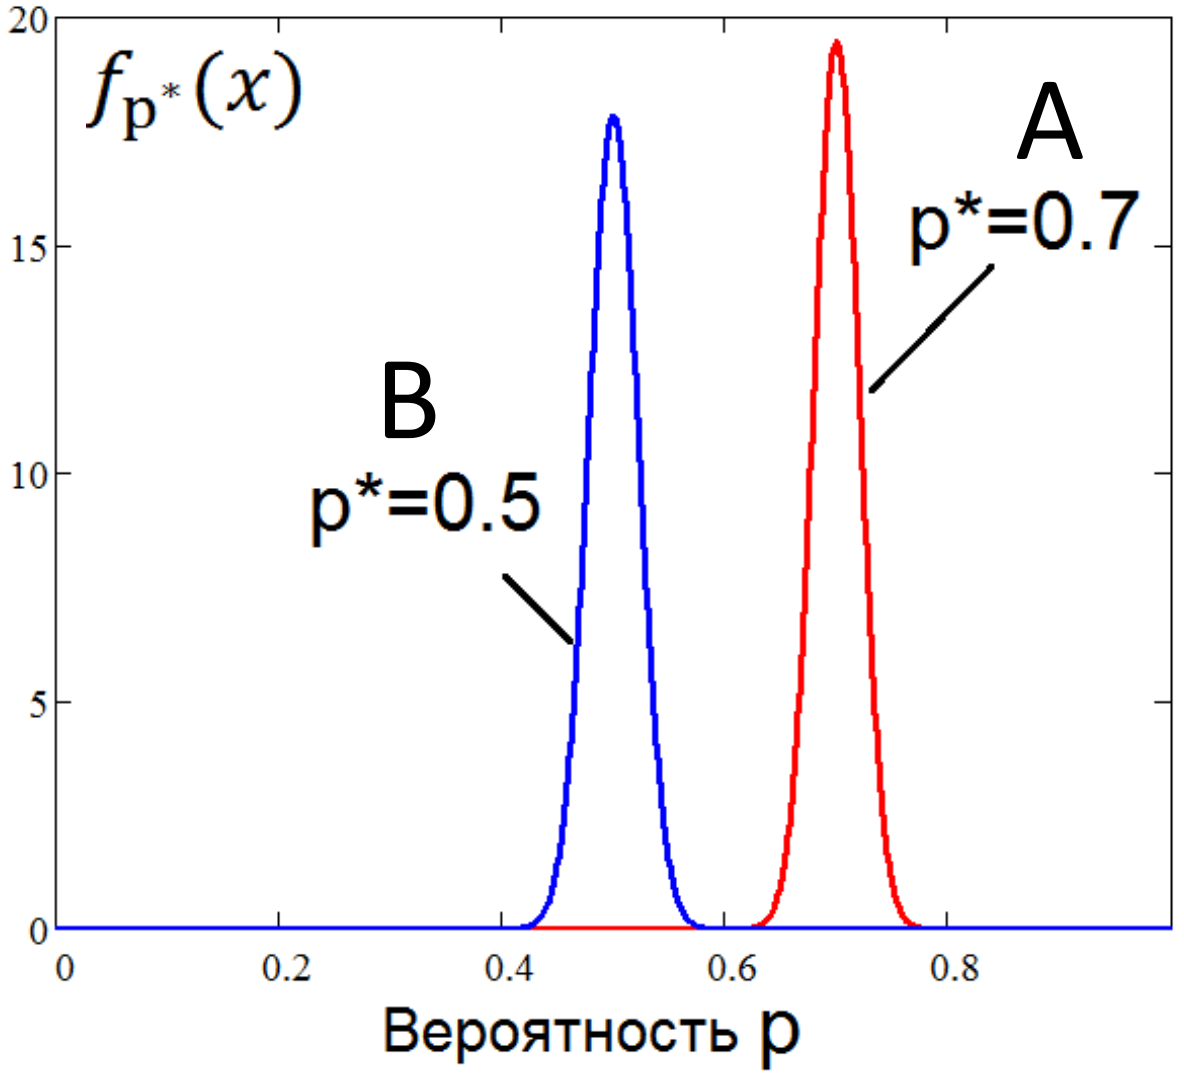
По 2,5% слева и справа

Характерные квантили нормированного распределения Гаусса

p	75%	90%	95%	97.5%	99%
	0.674	1.282	1.645	1.960	2.236

Суждение о равновероятных событиях





Если интервалы пересекаются – декларировать различие оценок **нельзя**

Сколько данных нужно для требуемой точности?



По гарантированному (с вероятностью β%) значению *абсолютного отклонения* Δ_p :

$$N = \frac{u_\beta^2 (1-p)}{p\Delta_p^2 + \frac{u_\beta^2 (1-p)}{\widehat{N}}}$$

По гарантированному (с вероятностью β%) значению *относительного отклонения* $\delta_p = \sigma_p / p$

$$N = \frac{1-p}{p\delta_p^2 + \frac{(1-p)}{\widehat{N}}}$$

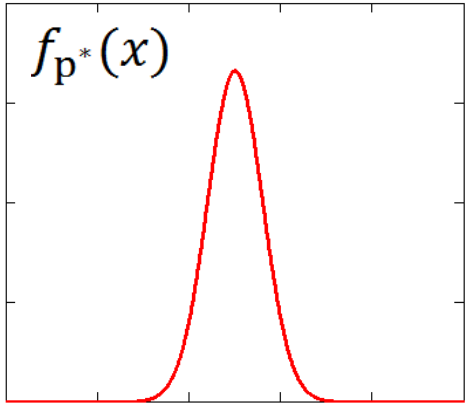
При расчетах $p \cong p^*$

Суждение о равновероятных событиях

Однородность



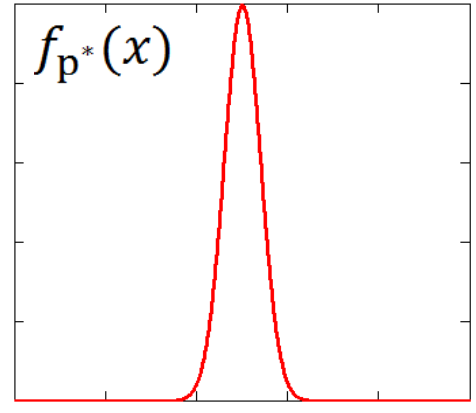
Интервальная оценка по выборке



Однородность сохраняется



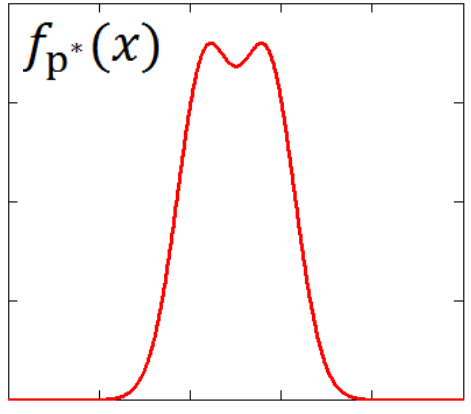
Интервал сокращается



Однородность **НЕ** сохраняется







Интервалы по выборке: порядковые статистики

Преобразование выборки в *вариационный ряд:*

$$sort(x_1, \dots, x_N) \rightarrow (x_{(1)} \leq x_{(2)} \dots \leq x_{(i)} \dots \leq x_{(N)})$$

Исходная выборка

i-я *порядковая статистика*

экстремумы (крайние члены) выборки



Точечная оценка p%-квантили как порядковой статистики:

$$x_p^* = x_{(\lfloor Np \rfloor + 1)}$$



Асимптотическая несмещенность оценки: $M_{x_p^*} = x_p, N \gg 1$

Задача на понимание порядковых статистик

Исходная выборка: X = (2, 7, 2, 1, 4, 3, 5) N=|X| =7

Вариационный ряд (sort): X = (1, 2, 2, 3, 4, 5, 7)

Характерные квантили:

$$x_p^* = x_{(\lfloor Np \rfloor + 1)}$$

Min(X) = 1

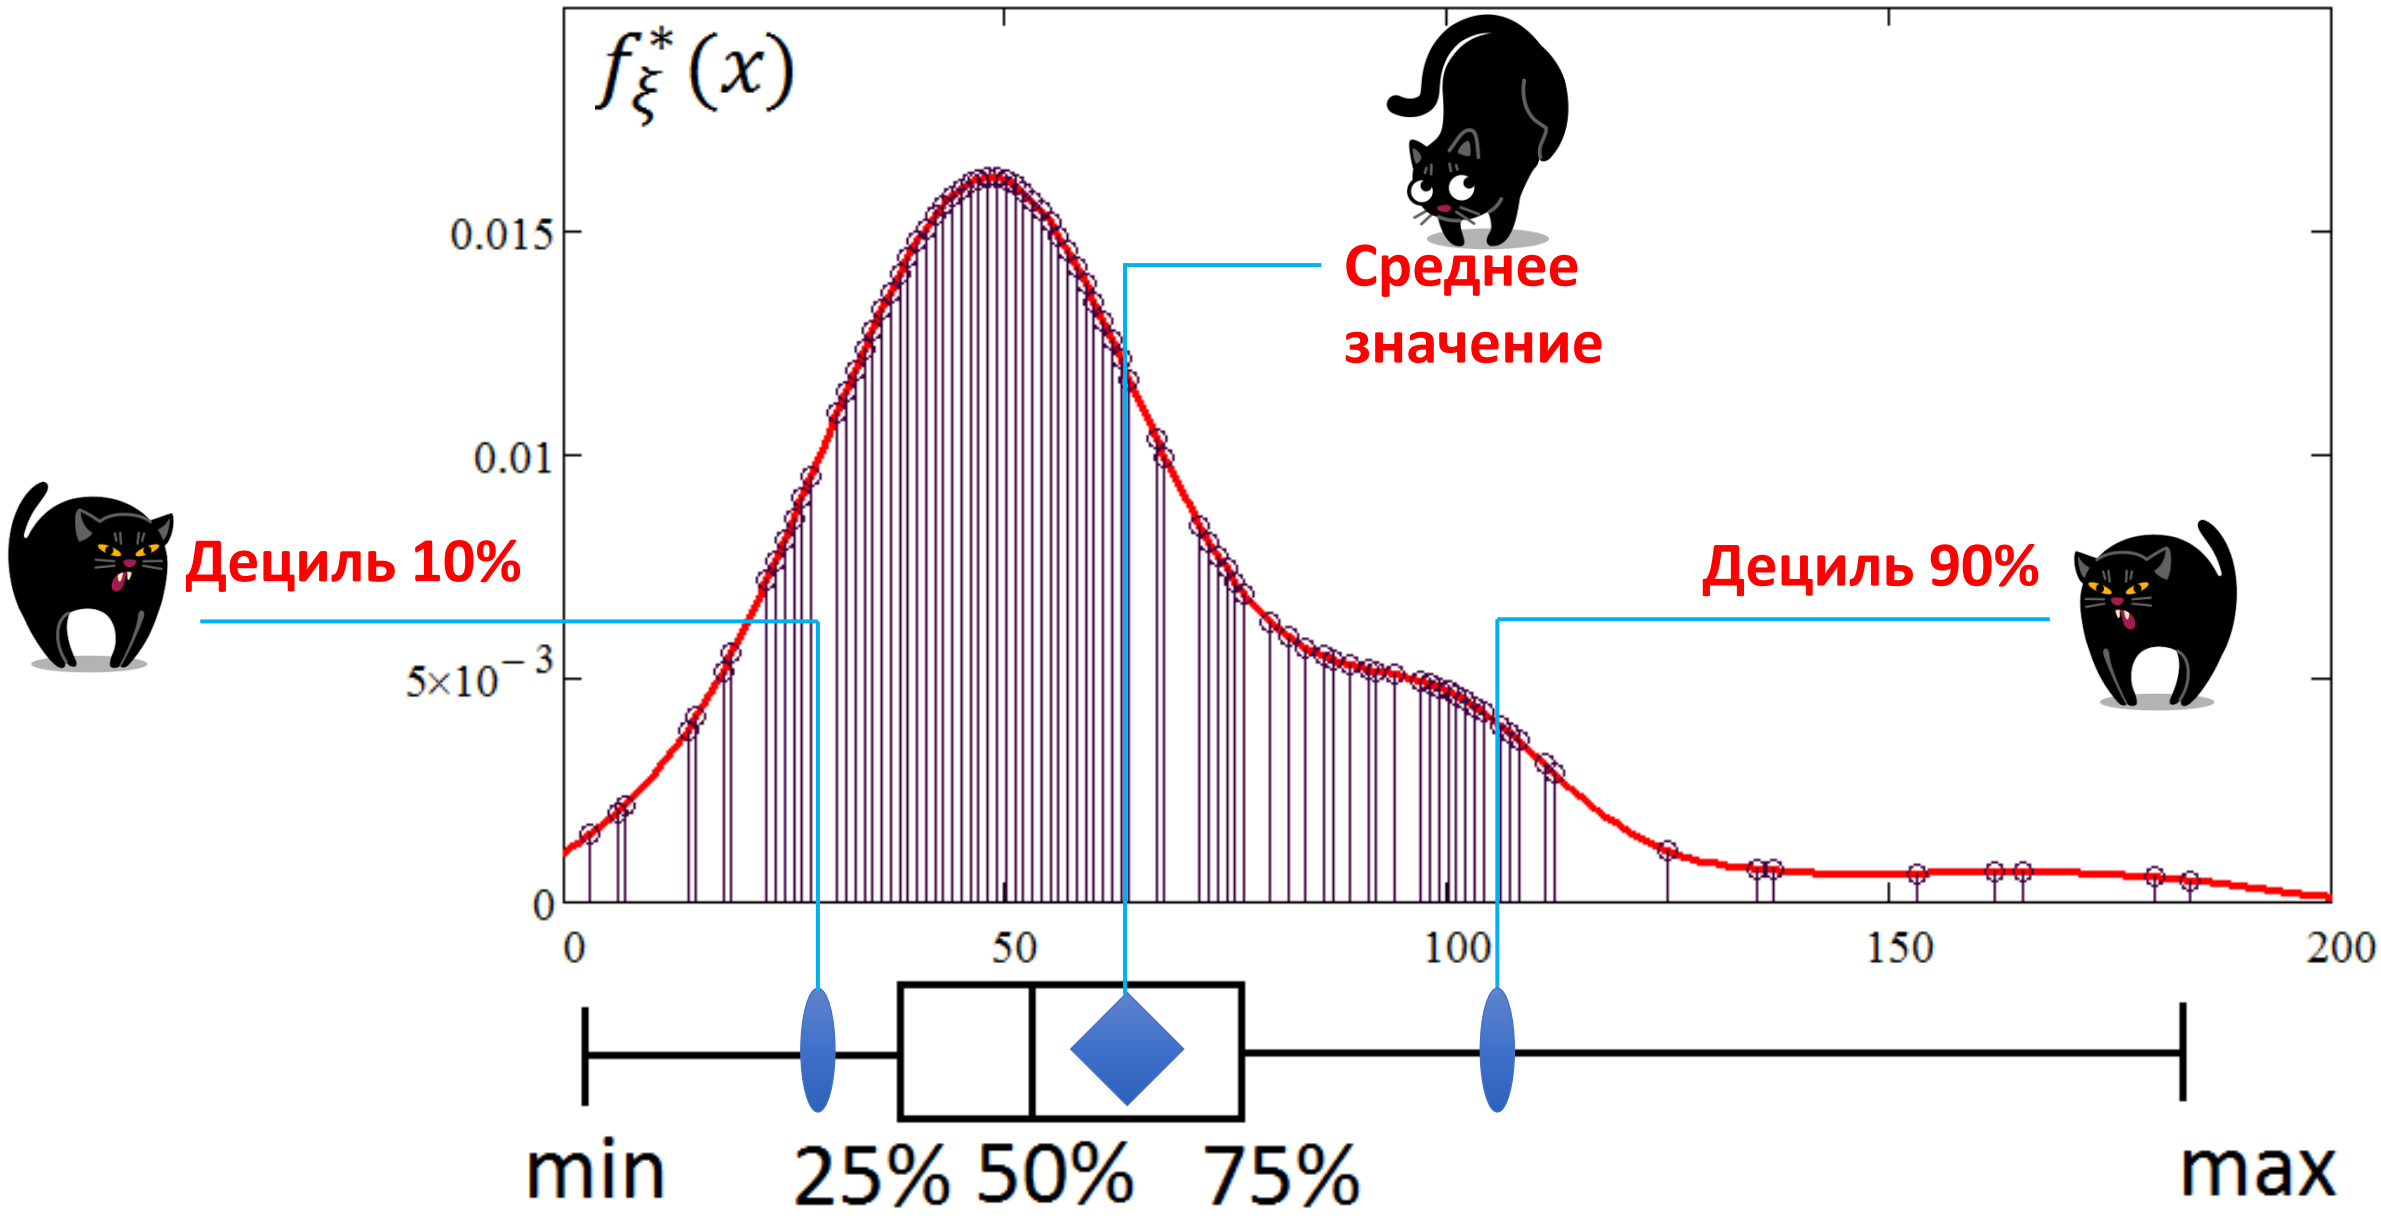
Max(X) = 7

Квантиль 50% = 3 - член вар.ряда № $\lfloor 7 \cdot 0{,}5 \rfloor + 1 = 4$

Квантиль 75% = 5 - член вар.ряда № $\lfloor 7 \cdot 0{,}75 \rfloor + 1 = 6$

Квантиль 25% = 2 - член вар.ряда № $\lfloor 7 \cdot 0{,}25 \rfloor + 1 = 2$

Картирование квантилей: ящики с усами





ИТМО

ОЦЕНКА ТОЧНОСТИ МОДЕЛЕЙ ИИ НА ДАННЫХ

Статистическое обучение и неопределенность

Статистическое обучение - определение структуры и (или) параметров определение модели машинного обучения на данных в предположении, что они описываются некоторой вероятностной моделью

Для статистического обучения принципиально: наличие датасета, который соответствует соответствовать неизменным условиям наблюдений (концепции задачи)



Неопределенность: мера сомнения в достоверности результата, характеризующее диапазон значений, в которых находится истинная величина, определяемая посредством статистического обучения (~ГОСТ 34100.3—2017)

В детерминированных причинно-следственных моделях: чем точнее получается результат – тем лучше

В моделях на основе статистического обучения: есть абсолютный предел точности (что сверх того – то объективная неопределенность)

Неопределенность – всегда измерима

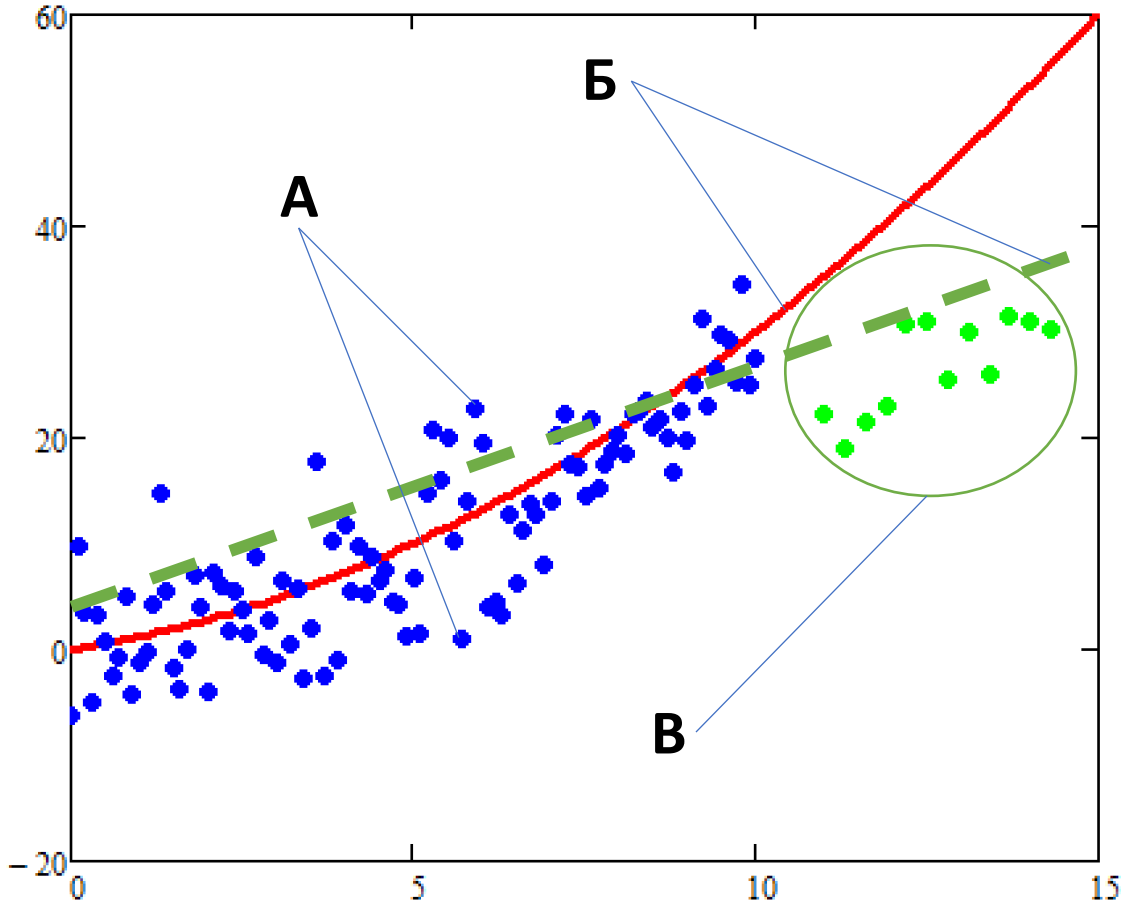
Виды и причины возникновения неопределенности

«А». Ограниченный объем датасета (исходной выборки)

«Б». Выбор модели машинного обучения

«В». Изменение свойств моделируемого явления (дрейф концепций)

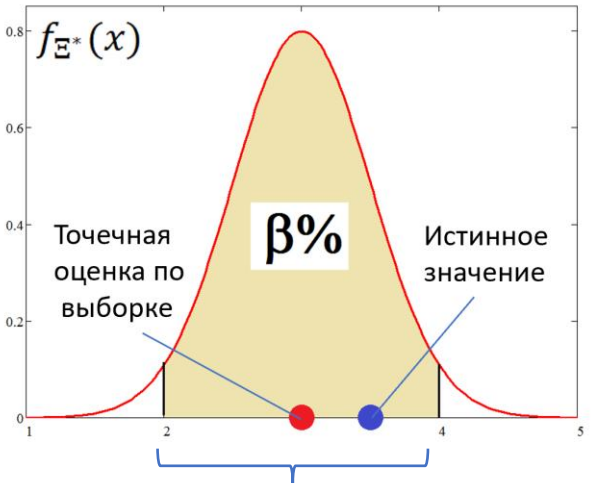
«Б» и «В» корректируются методически. «А» - объективна; ее нужно уметь измерять с помощью **математической статистики**



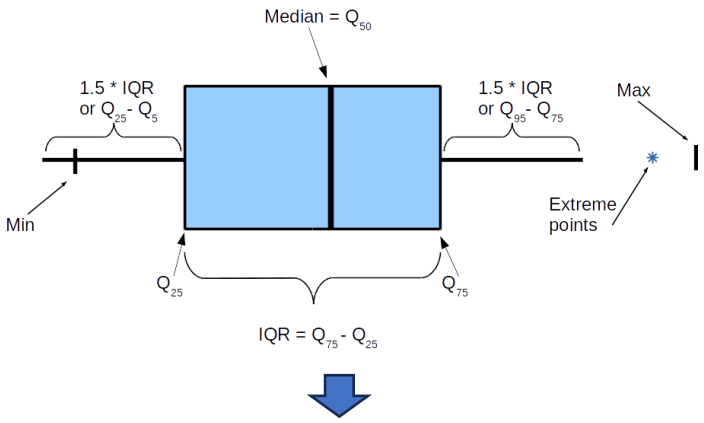
Алеаторная неопределенность – недостаток знаний о природе объекта, условий наблюдения или концепции задачи машинного обучения

Эпистемологическая неопределенность – ограниченность данных для обучения моделей

Чем измеряют неопределенность в системах ИИ



β% доверительный интервал



Характерные метрики распределения ошибки **(проще, чем ящик с усами рисовать)**

Для задачи регрессии (предсказание f на основе данных y)

1) Среднее смещение (BIAS):

$$BIAS = \frac{\sum_{i=1}^{n}(y_i - f_i)}{n}$$

2) Средняя абсолютная интегральная ошибка (MAE):

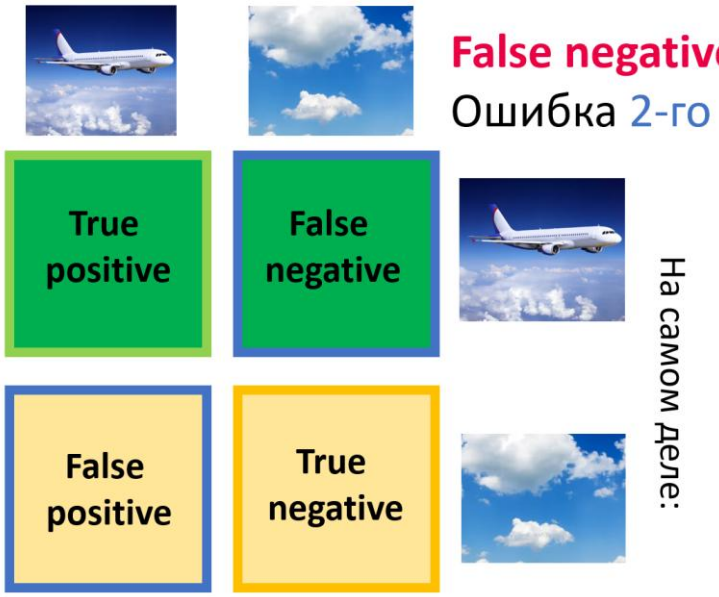
$$MAE = \frac{\sum_{i=1}^{n}|(y_i - f_i)|}{n}$$

3) Среднеквадратичная ошибка (RMSE – аналог СКО):

$$RMSE = \sqrt{\frac{\sum_{i=1}^{n}(y_i - f_i)^2}{n}}$$

MAE – робастная метрика, а RMSE – нет!
(робастность = устойчивость к выбросам и засорениям данных)

Усложняем: метрики качества для классификации



В разных задачах «цена» ошибок первого и второго рода разная!

Доля правильных ответов модели (accuracy):

$$accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

Точность (precision) – это доля случаев, действительно принадлежащих данному классу относительно всех случаев, которые модель отнесла к этому классу.

$$Precision = \frac{TP}{TP + FP}$$

Полнота (recall) – это доля найденных классификатором случаев принадлежащих классу относительно всех истинных случаев этого класса.

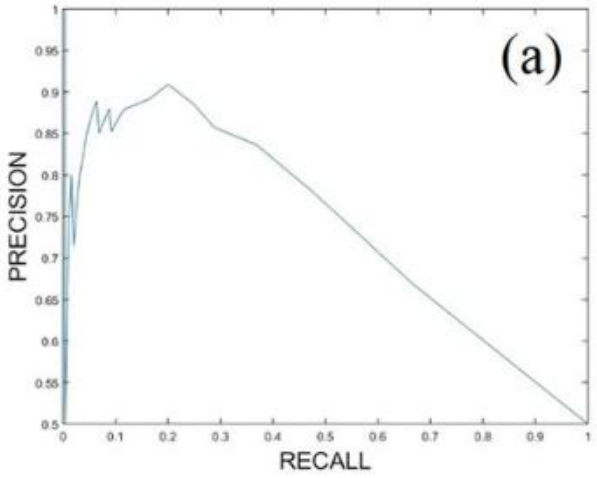
$$Recall = \frac{TP}{TP + FN}$$

https://habr.com/ru/articles/661119/

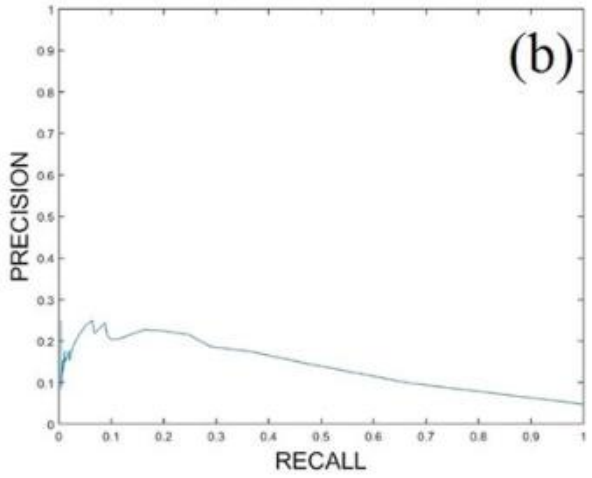
Интегральные метрики качества для классификации

Precision-Recall кривая

Сбалансированные данные



Несбалансированные данные

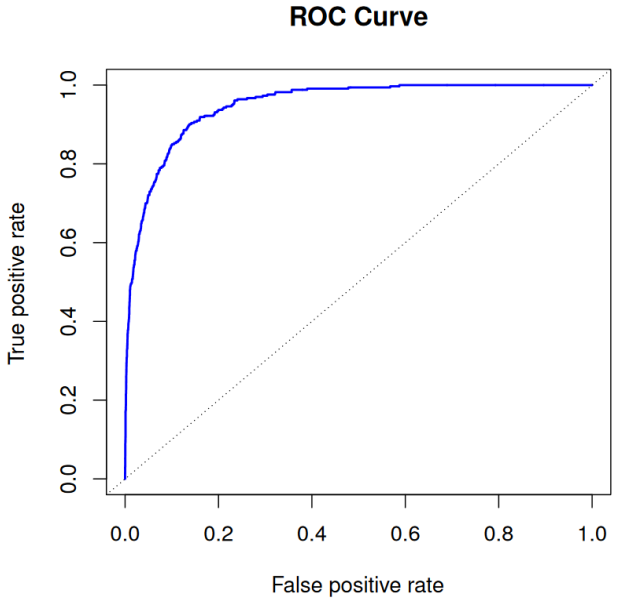


Recall демонстрирует способность алгоритма обнаруживать данный класс вообще, а Precision — способность отличать этот класс от других классов.

F1 мера – баланс между Precision и Recall

$$F_1 = 2 * \frac{Precision * Recall}{Precision + Recall}$$

AUC-ROC (или ROC AUC) — площадь (*A*rea *U*nder *C*urve) под кривой ошибок (*R*eceiver *O*perating *C*haracteristic curve). Данная кривая представляет из себя линию от (0,0) до (1,1) в координатах True Positive Rate (TPR) и False Positive Rate (FPR):



$$TPR = \frac{TP}{TP + FN}$$

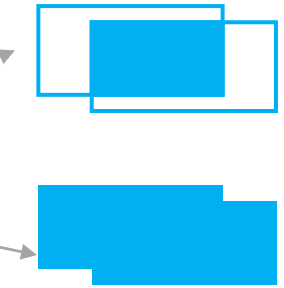
$$FPR = \frac{FP}{FP + TN}$$

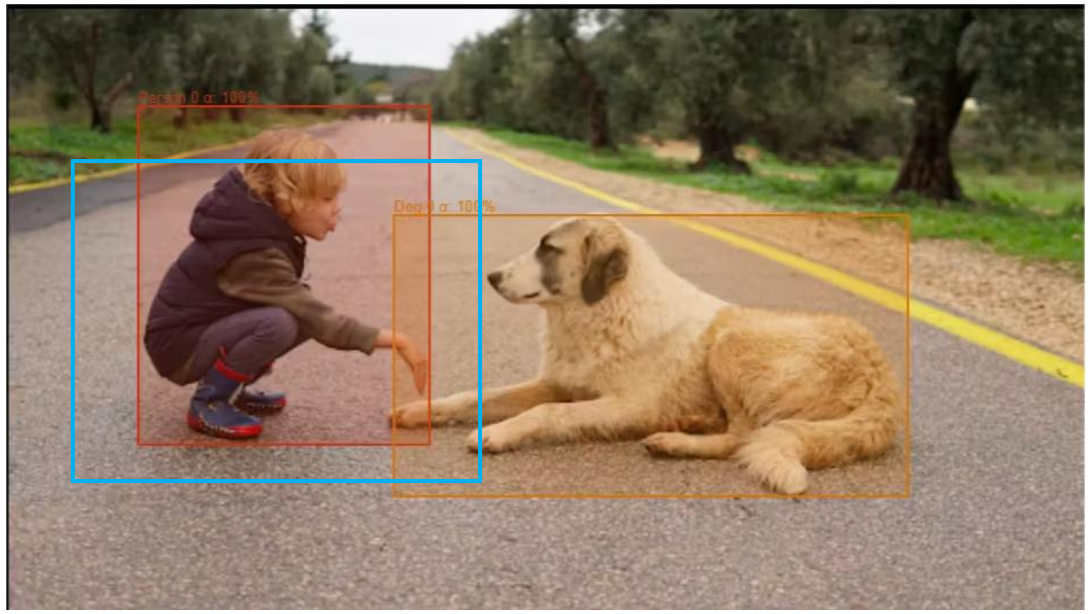
Специфические метрики для CV

IoU (Intersection over Union) – мера того, насколько границы объекта, выявленные алгоритмом, и размеченные границы объекта совпадают.

$$IoU = \frac{S\ \text{пересечения}}{S\ \text{объединения}} = \frac{TP}{TP + FP + FN}$$

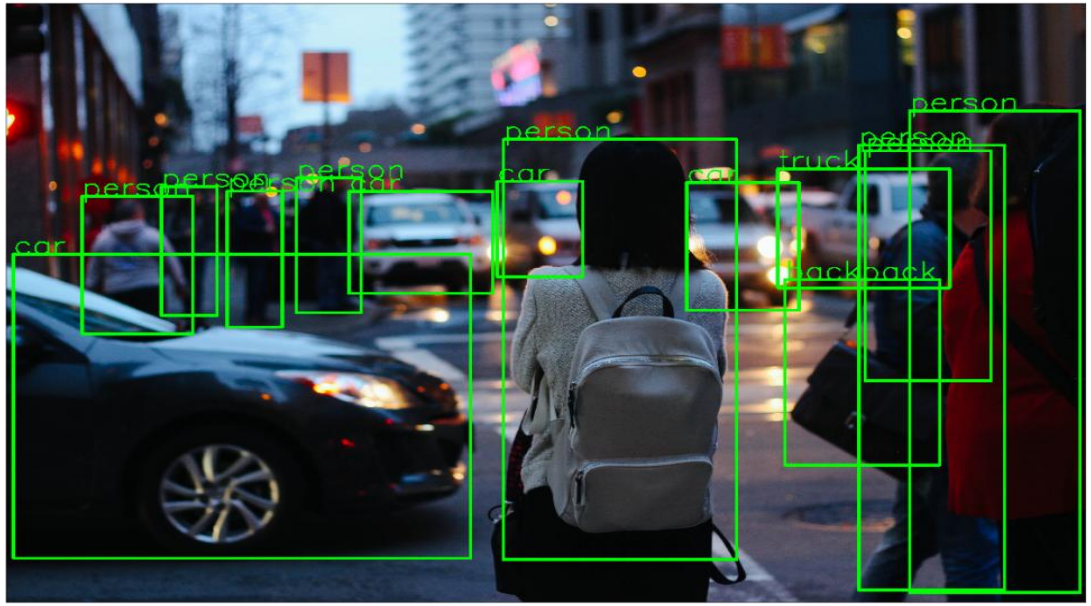
попиксельно





mIoU (Mean Intersection over Union) – усредненная по k классам мера совпадения размеченных и выявленных алгоритмом границ.

$$mIoU = \frac{\sum_k IoU_i}{k}, i = 1 \ldots n$$

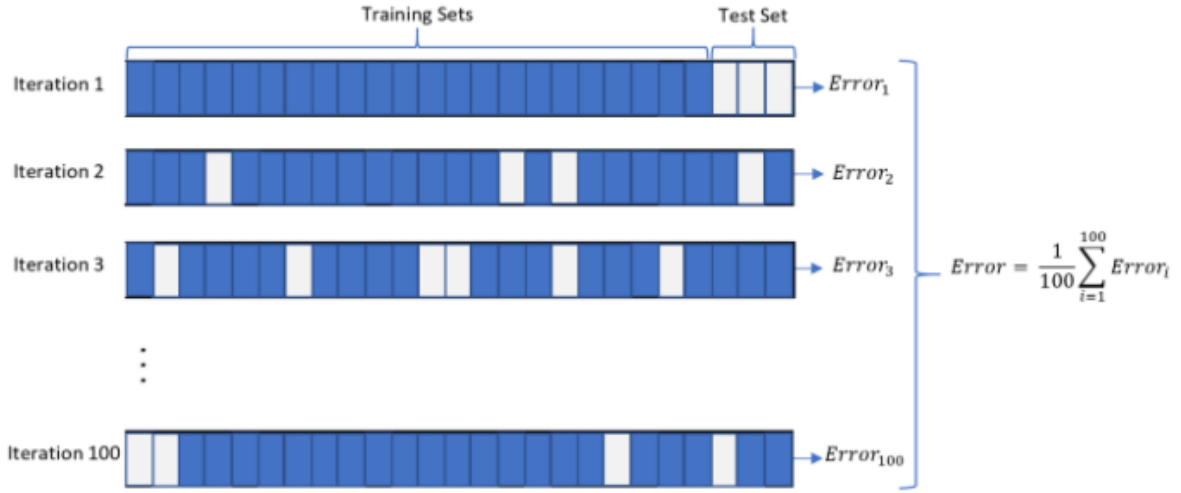


Оценка метрик с помощью кроссвалидации

Метод оценки моделей МО, при котором данные разбиваются на k частей, затем на k−1 частях данных производится обучение модели, а оставшаяся часть используется для тестирования.



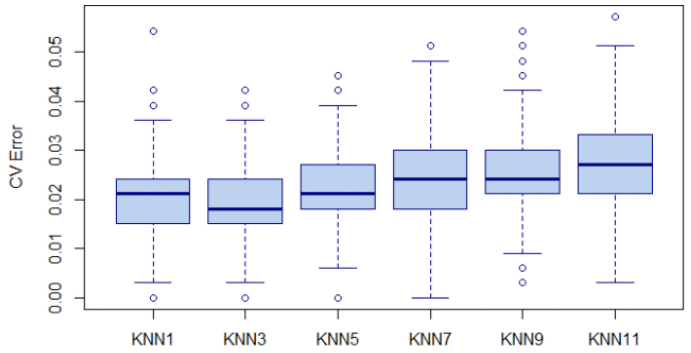
или



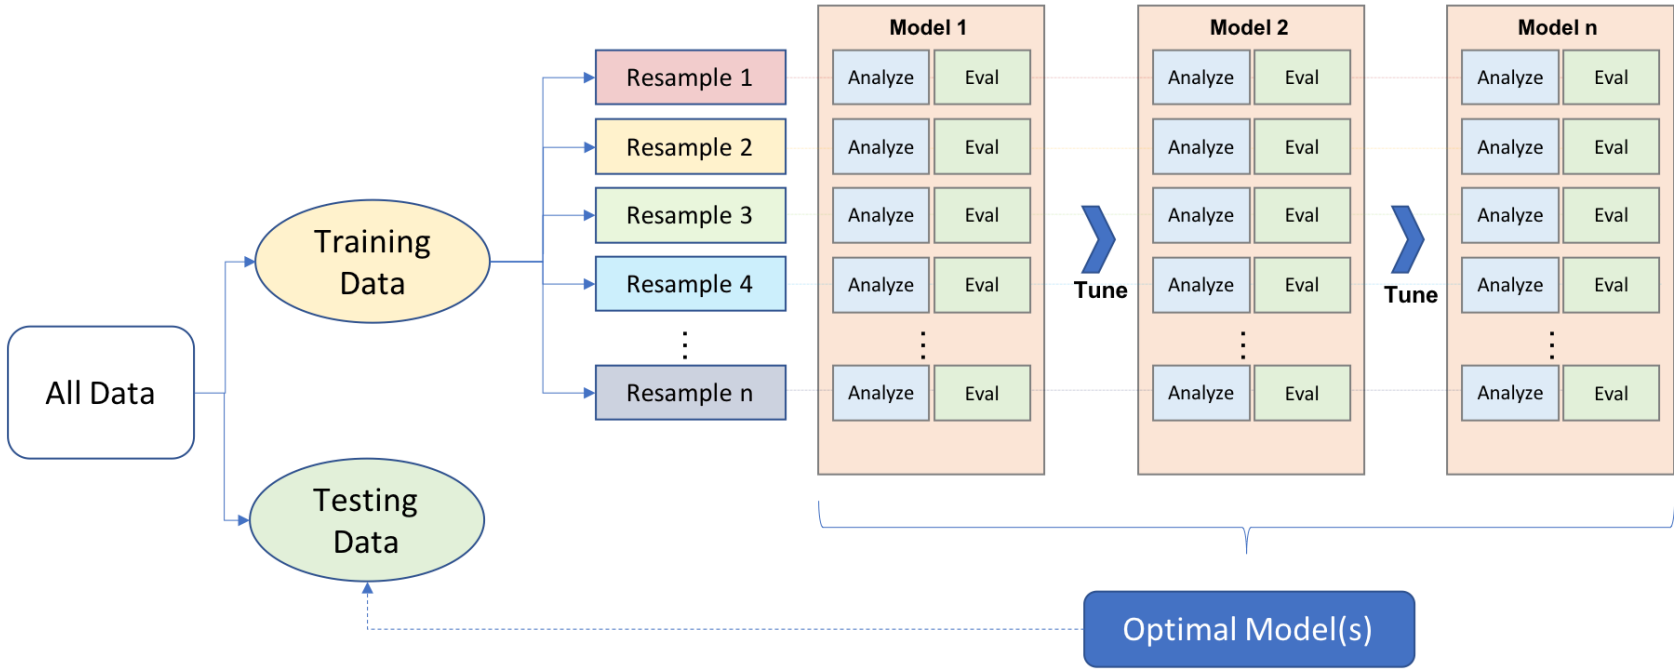
- Недостаточно для интервальной оценки
- Недостаточная точность оценки среднего

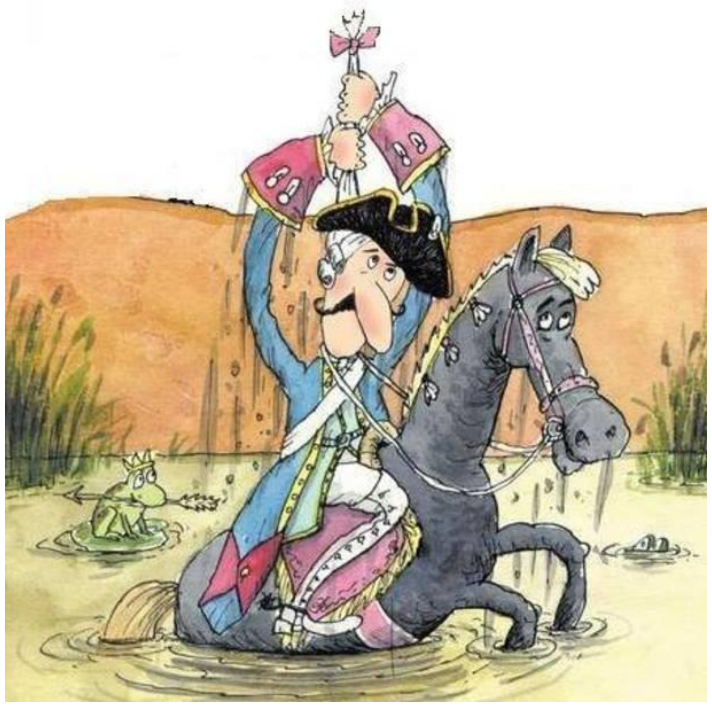
Monte Carlo CV, Iterations = 100

Интервальная оценка метрик:



Бутстреп: аугментация данных «из шерсти родителей»







Идея бутстрепа: формирование M ***псевдовыборок***

$$\left(x_1^{(j)}, \ldots, x_N^{(j)}\right), j = 1 \ldots M$$

на основе случайного ***выбора с возвращением*** из исходной выборки:

Задача на понимание бутстрепа

Задача – рассчитать оценку математического ожидания по выборке (как среднего значения)

Исходная выборка: X = (2, 7, 2, 1, 4, 3, 5), N = |X|=7

Оценка (среднее значение): $m^* = \frac{1}{N}\sum_{i=1}^{N} x_i = 3{,}43$

Вариационный ряд (sort): X = (1, 2, 2, 3, 4, 5, 7)

Псевдовыборка №1: X = (1, 2, 2, 3, 4, 2, 7) $m^* = 3{,}00$

Псевдовыборка №2: X = (4, 2, 2, 3, 4, 5, 7) $m^* = 3{,}86$

Псевдовыборка №3: X = (1, 2, 2, 3, 4, 5, 3) $m^* = 2{,}86$

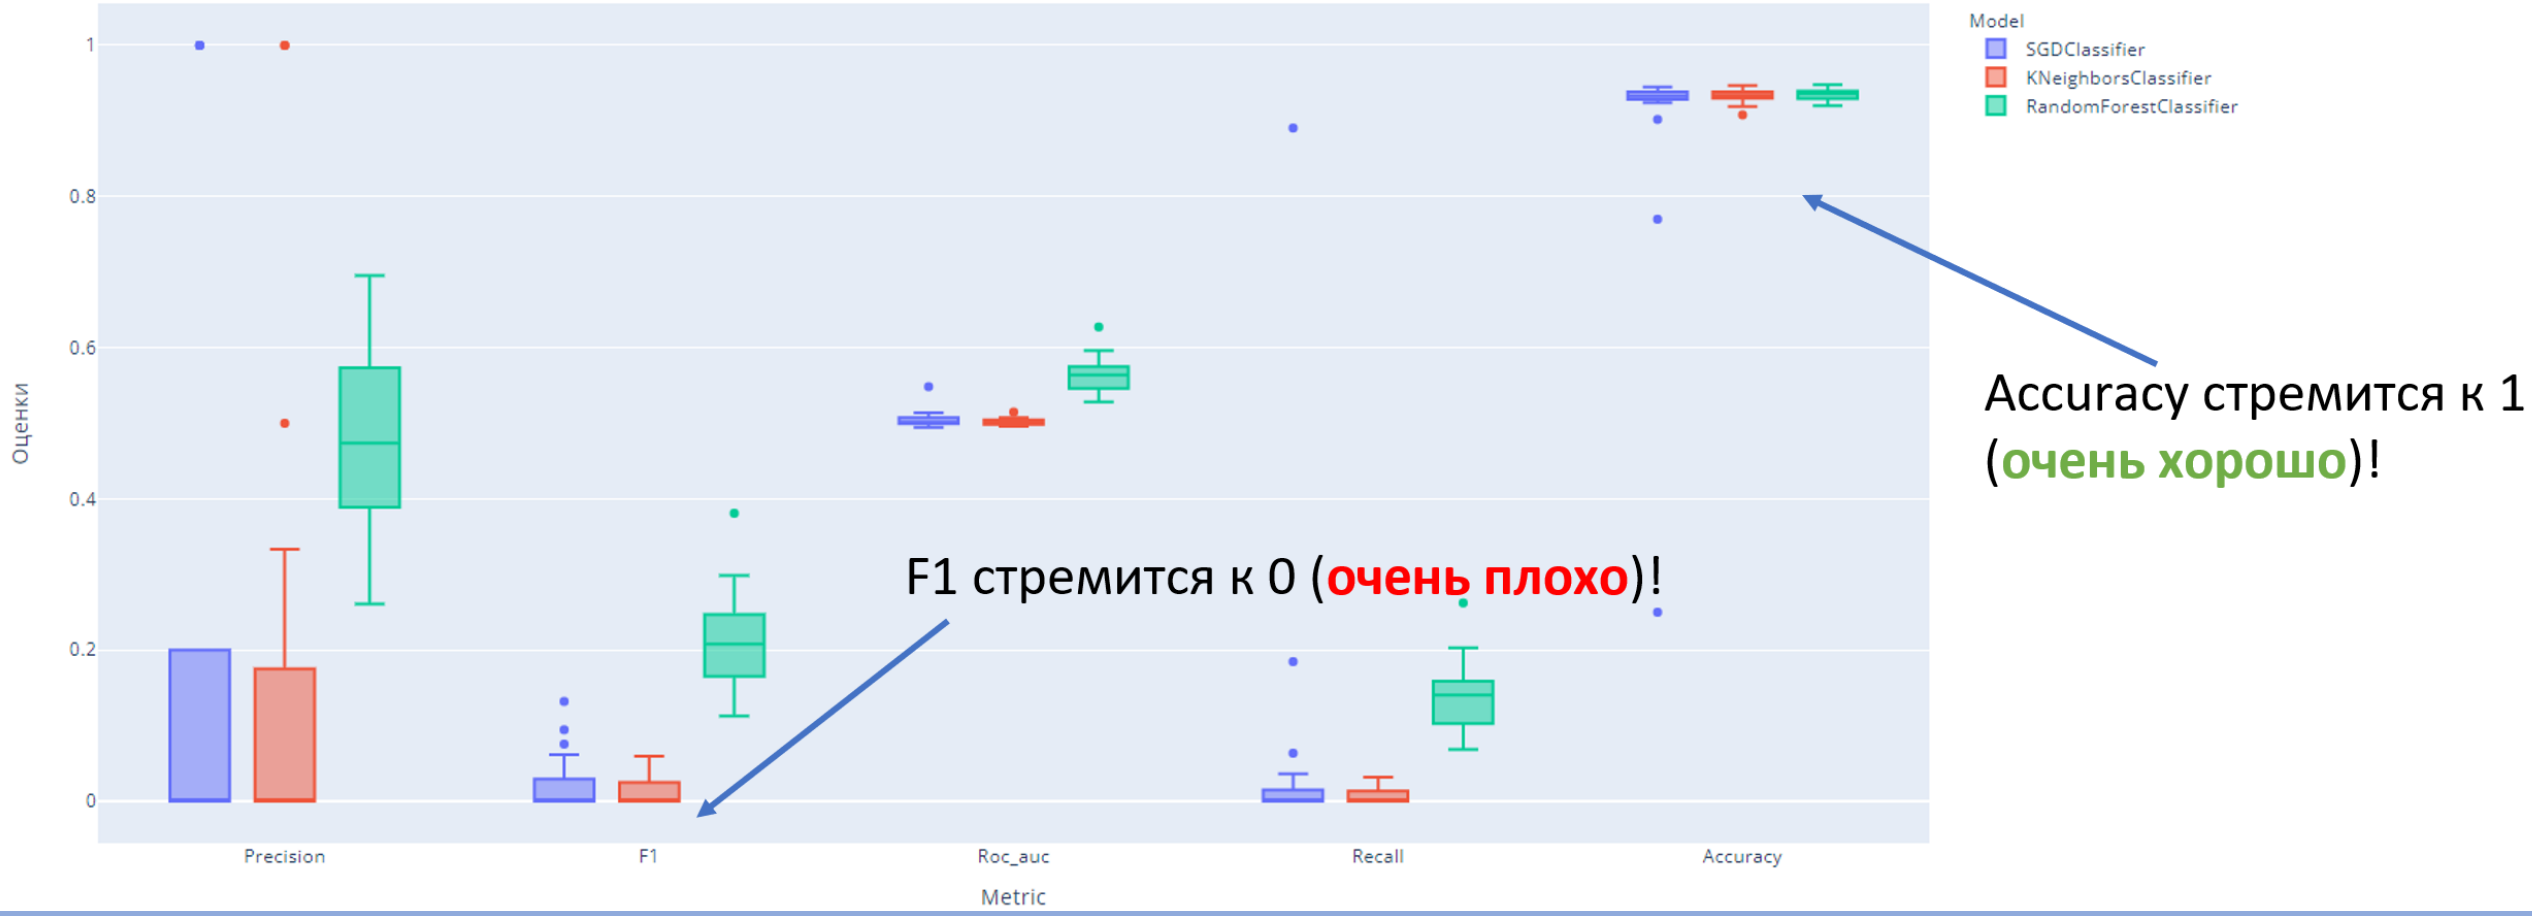
Псевдовыборка №4: X = (7, 2, 2, 3, 4, 5, 7) $m^* = 4{,}29$

Псевдовыборка №5: X = (1, 2, 2, 3, 4, 5, 7) $m^* = 3{,}43$

Итого – выборка случайных оценок: X = (2.86, 3.00, 3.43, 3.86, 4.29) ➡ Ящик с усами!

Устойчивость: зачем нужны интервальные метрики

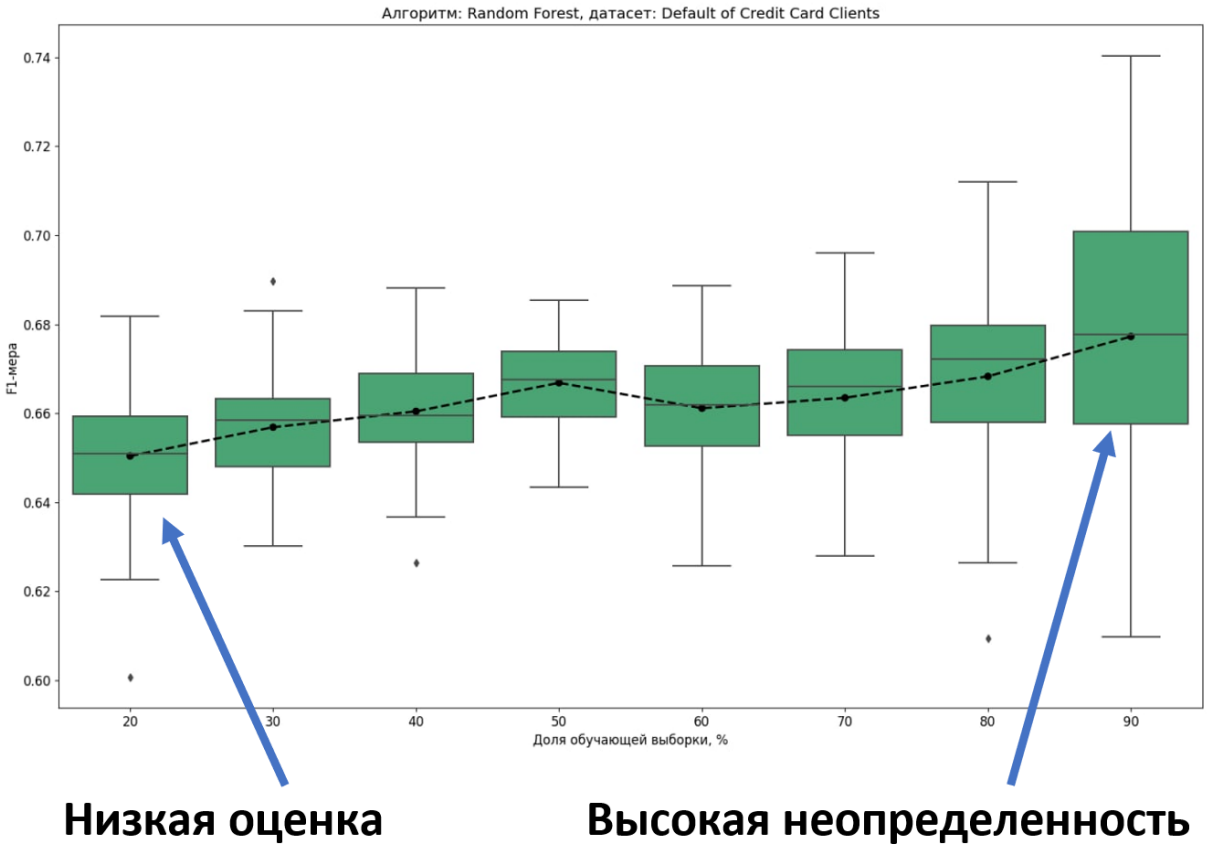
Сравнение трех моделей классификации на основе бутстрепированных данных



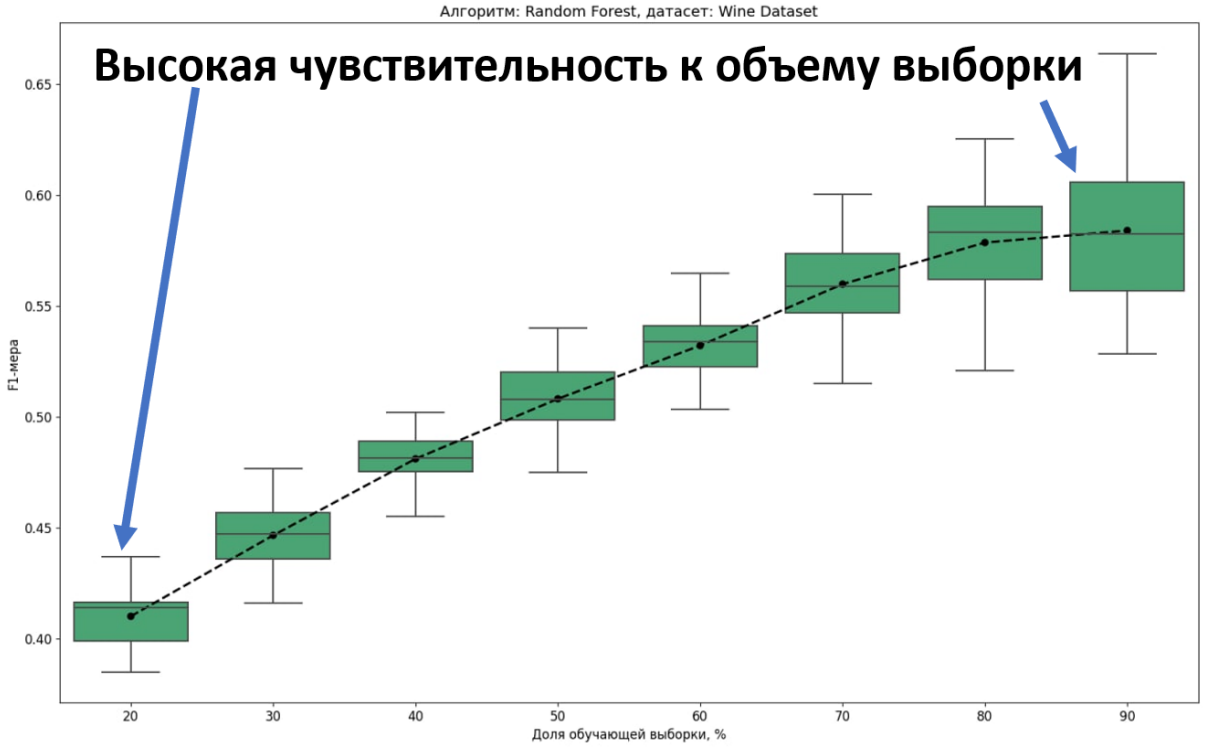
Для оценки качества модели важны не сами значения метрик, а мера их разброса для разных наборов данных. Чем выше разброс – тем хуже устойчивость!

Миф: Данных больше – качество выше

Модель кредитного скоринга в банке



Модель классификации для … вина ☺



Новые данные могут включать в себе редкие ситуации, которые «ломают» исходную модель!

Как сравниться с эталоном, когда его нет?



Бенчмарк – средство для оценки моделей ИИ, состоит из элементов:

- задача;
- тестовый набор данных;
- метрика оценки качества решения задачи;
- [опционально] обучающий набор данных;
- [опционально] бейзлайн.



Бейзлайн –

- модель/алгоритм решения задачи, служащая отправной точкой для разработки новых моделей/алгоритмов;
- значение метрики оценки качества базовой модели/алгоритма.



SOTA (State-of-the-Art) модель/алгоритм (для данного бенчмарка) - модель/алгоритм, достигающий наивысшего значения метрики оценки качества на данном бенчмарке на данный момент времени.

Вчерашний SOTA – сегодняшний бейзлайн

Когда можно сравнивать оценки без округления

Примеры из многочисленных статей по сравнению моделей ИИ

Table 2. DesignQA evaluation (per-subset metrics and macro average). The table reports the comparison between two model families, GPT-4 and Qwen-2.5-VL-7b, under three progressively richer evidence conditions: Base(original questions and images), Page-Augmented Retrieval(PAR) and Localized Fragment Augmentation(LFA). Reported metrics are Retrieval (F1, bag-of-words), Compilation (F1 over rule identifiers), Definition (F1, bag-of-characters), and Presence / Dimension / Functional (binary accuracy). Overall denotes the macro average across these six subset scores.

Model	Config	Retrieval	Compilation	Definition	Presence	Dimension	Functional	Overall
GPT-4	Base	0.7502	0.2981	0.4707	0.6295	0.5335	0.5634	0.5409
GPT-4	PAR	0.8623	0.4527	0.4812	0.6614	**0.5631**	0.6025	0.6039
GPT-4	LFA	**0.8841**	**0.5029**	**0.4928**	**0.6832**	0.5437	**0.6236**	**0.6217**
Qwen-2.5-VL-7b	Base	0.0319	0.0034	0.3853	0.5968	0.3500	0.3125	0.2800
Qwen-2.5-VL-7b	PAR	0.1217	0.0725	0.3959	0.6218	**0.3612**	0.3416	0.3191
Qwen-2.5-VL-7b	LFA	**0.1634**	**0.0928**	**0.4121**	**0.6612**	0.3319	**0.3474**	**0.3348**

- Когда сравниваются модели на одинаковых бенчмарках – можно использовать разумное число знаков
- Когда оцениваются характеристики модели на некоторой случайной выборке – нужно пользоваться правилами округления, как с погрешностями (см. **ГОСТ Р 8.736-2011, приложение Е)**

Не нужно показывать длину бревен до миллиметров… если только вы не сравниваете дальномеры!

Как оценить границы применимости модели ИИ?

Проблемы:

- искажение данных слишком большое
- пришли данные, на которых модель не должна работать

ID







OOD



cat or dog?



Задача OOD (Out-of-Distribution)-детекции: оценка работоспособности модели ИИ в случае, когда в нее поступают новые данные, которые слишком «далеки» от обучающей выборки

OOD – демонстрирует «живучесть» модели и ее поведение в нестандартных случаях



ИТМО

ИНЫЕ ВОЗМОЖНЫЕ МЕТРИКИ КАЧЕСТВА СИСТЕМ ИИ

Немного про этику систем на основе сильного ИИ

1) Разграничение ответственности за функционирование технологических решений на основе сильного ИИ
2) Правосубъектность систем на основе сильного ИИ
3) Охраноспособность РИД, автоматически сгенерированных системами ИИ, и составных РИД на их основе;
4) Цифровое неравенство и цифровая конкуренция: пользователи систем сильного ИИ приобретают неоспоримые преимущества
5) Дискриминация посредством систем ИИ



Прежде, чем что-то внедрять, надо серьезно подумать о последствиях!

Пример: вопросник по оценке этичности ИИ от ИТМО

1. **Возможно ли пользование ИИ-сервисом без ознакомления с условиями и правилами его использования (пользовательское соглашение, политика обработки персональных данных и т.п.)?**

0 - условия и правила не опубликованы, либо опубликованы в неочевидном или труднодоступном для пользователя месте / формате

1 - условия и правила опубликованы и доступны для пользователя, но их предварительный просмотр не предлагается

2 - условия и правила опубликованы, но предупреждение о необходимости с ними ознакомиться носит формальный характер (например, “продолжая пользование сервисом, вы подтверждаете согласие на…”)

3 - для того, чтобы продолжить пользование сервисом необходимо подтвердить ознакомление (согласие) с условиями и правилами

4 - перед тем, как начать пользоваться сервисом, требуется полностью просмотреть условия и правила

2. **Понятны ли вам правила и условия пользования (при наличии) или они изложены “тяжелым” юридическим языком, понять который сложно при отсутствии специальных знаний?**

0 - правила и условия неясно сформулированы, понимание их смысла затруднено или невозможно и они допускают две и более трактовки

1 - ознакомление с условиями и правилами затруднительно ввиду как сложности текста, так и его объема

2- правила и условия сформулированы корректно, но для их полноценного изучения требуются специальные юридические знания

3 - условия и правила представляют собой значительный объем текста, с которым сложно ознакомиться

4 - правила и условия абсолютно понятны, их объем оптимален

3. **Если в ИИ-сервис можно загрузить “чувствительные данные” (персональные, конфиденциальные, содержащие коммерческую тайну и т.п.), доступно ли пользователю предупреждение о необходимости воздержаться от их загрузки или, по крайней мере, о возможных рисках и последствиях?**

0 - предупреждение отсутствует

1 - предупреждение присутствует, но сформулировано труднодоступным для рядового пользователя образом и располагается в труднодоступном для пользователя месте

2 - предупреждение заметно для пользователя, но сформулировано труднодоступным для него образом

3 - предупреждение сформулировано понятным для пользователя образом, но располагается в труднодоступном для него месте

4 - предупреждение заметно для пользователя и сформулировано понятным для него образом

4. **Насколько доступна пользователю информация о том, что будет происходить с его персональными данными, которые окажутся в “информационном контуре” ИИ-сервиса?**

0 - информация недоступна для пользователя

1 - информация расположена в труднодоступном для пользователя месте и сформулирована сложным и (или) непонятным для рядового пользователя языком

2 - информация расположена в труднодоступном для пользователя месте

3 - информация сформулирована сложным и (или) непонятным для рядового пользователя языком

4 - информация расположена в доступном для пользователя месте и сформулирована понятным для рядового пользователя языком

Два слова про безопасность систем ИИ

Эта футболка со странными рисунками сделает вас невидимым для камер наблюдения

13 мая 2020, Ася Чертовских, 6



«Отравление» моделей ИИ, атаки уклонения, зловредный код

ИИ всегда работает в условиях неопределенности – и потому имеет объективное «право на ошибку»

Реверс-инжиниринг систем ИИ на основе открытых кодов и данных для обучения, и состязательные примеры

Что размещаем в открытых репозиториях: открытый код, или … код с оговорками? (двойные стандарты продвижения СПО)

Чуть-чуть про ангажированность: рексервисы на базе ИИ

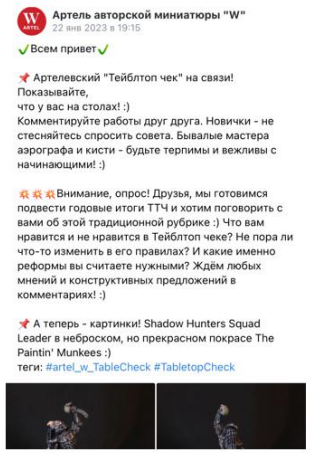
Содержательные рекомендации, ассоциированные с конкретными интересами пользователя



50-60%

Различные инструменты манипуляции пользователем

Реклама вне интересов



5-6%

Скрытая монетизация



5-8%

Юмор



21-22%

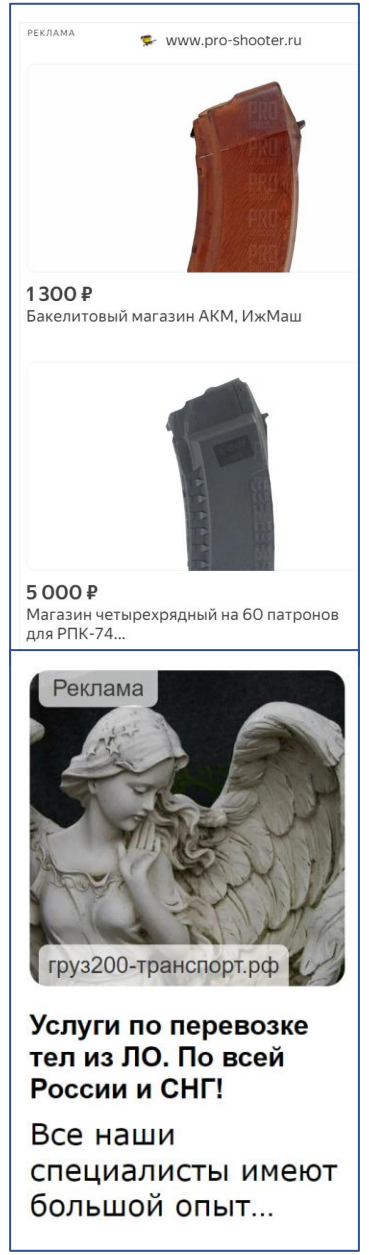
Промоушн



6-9%

Результаты анализа данных (2023)

Рекомендации, полученные автором лично ☺



Рексервисы нужны владельцам не только для оптимизации выбора пользователя, но и для его удержания и манипуляций

Резюме занятия (кратко и емко)

- Качество ИИ – понятие пространное, хотя и гостированное. Качество модели ИИ – это точность (близость к истине). А вот качество системы ИИ, кроме точности, может быть связано с производительностью, этичностью и безопасностью.
- Для того, чтобы описать точность моделей ИИ, используются методы математической статистики – интервальное оценивание. Интервальное оценивание – это построение доверительных интервалов для любых характеристик, полученных по выборкам. А границами таких интервалов являются квантили распределения оценки.
- Только в самых простых случаях мы можем знать аналитическое распределение оценки. Например, для оценки вероятности, математического ожидания или дисперсии. И тогда доверительные интервалы находятся просто по формулам, через табличные квантили распределения Гаусса.
- Если мы ничего не знаем о распределениях оценки, то доверительные интервалы можно найти только приближенно. С помощью порядковых статистик – оценок квантилей. А визуализировать их можно в виде ящиков с усами.
- Имея доверительные интервалы, можно сравнивать характеристики по разным наборам данных: если интервалы пересекаются, то они не различимы статистически (т.е. данные можно считать однородными).
- В моделях на данных, которые строятся методами машинного обучения, точность связана с неопределенностью. А неопределенность бывает из-за недостатка данных, неудачно выбранной модели, а также дрейфа концепции.
- Для модели регрессии точность – это одна характеристика ошибки, распределение которой характеризуется такими метриками, как MAE, BIAS и RMSE. А для модели классификации есть уже две характеристики точности – ложно-положительные и ложно отрицательные ошибки (и метрики Accuracy, Recall, Precision и др.).
- Чтобы получить доверительные интервалы для значений метрик точности моделей, используются методы кросс-валидации. А когда данных мало – метод бутстреп. Результаты строятся в виде ящиков с усами.
- Для точности ИИ нет эталона. И потому все методы сравниваются на бенчмарках. Нижнюю границу точности задают модели-бейзлайны, а верхнюю – модели SOTA.
- Можно построить и другие метрики качества, связанные с этичностью, безопасностью и ангажированностью ИИ.